

Universidade POSITIVO

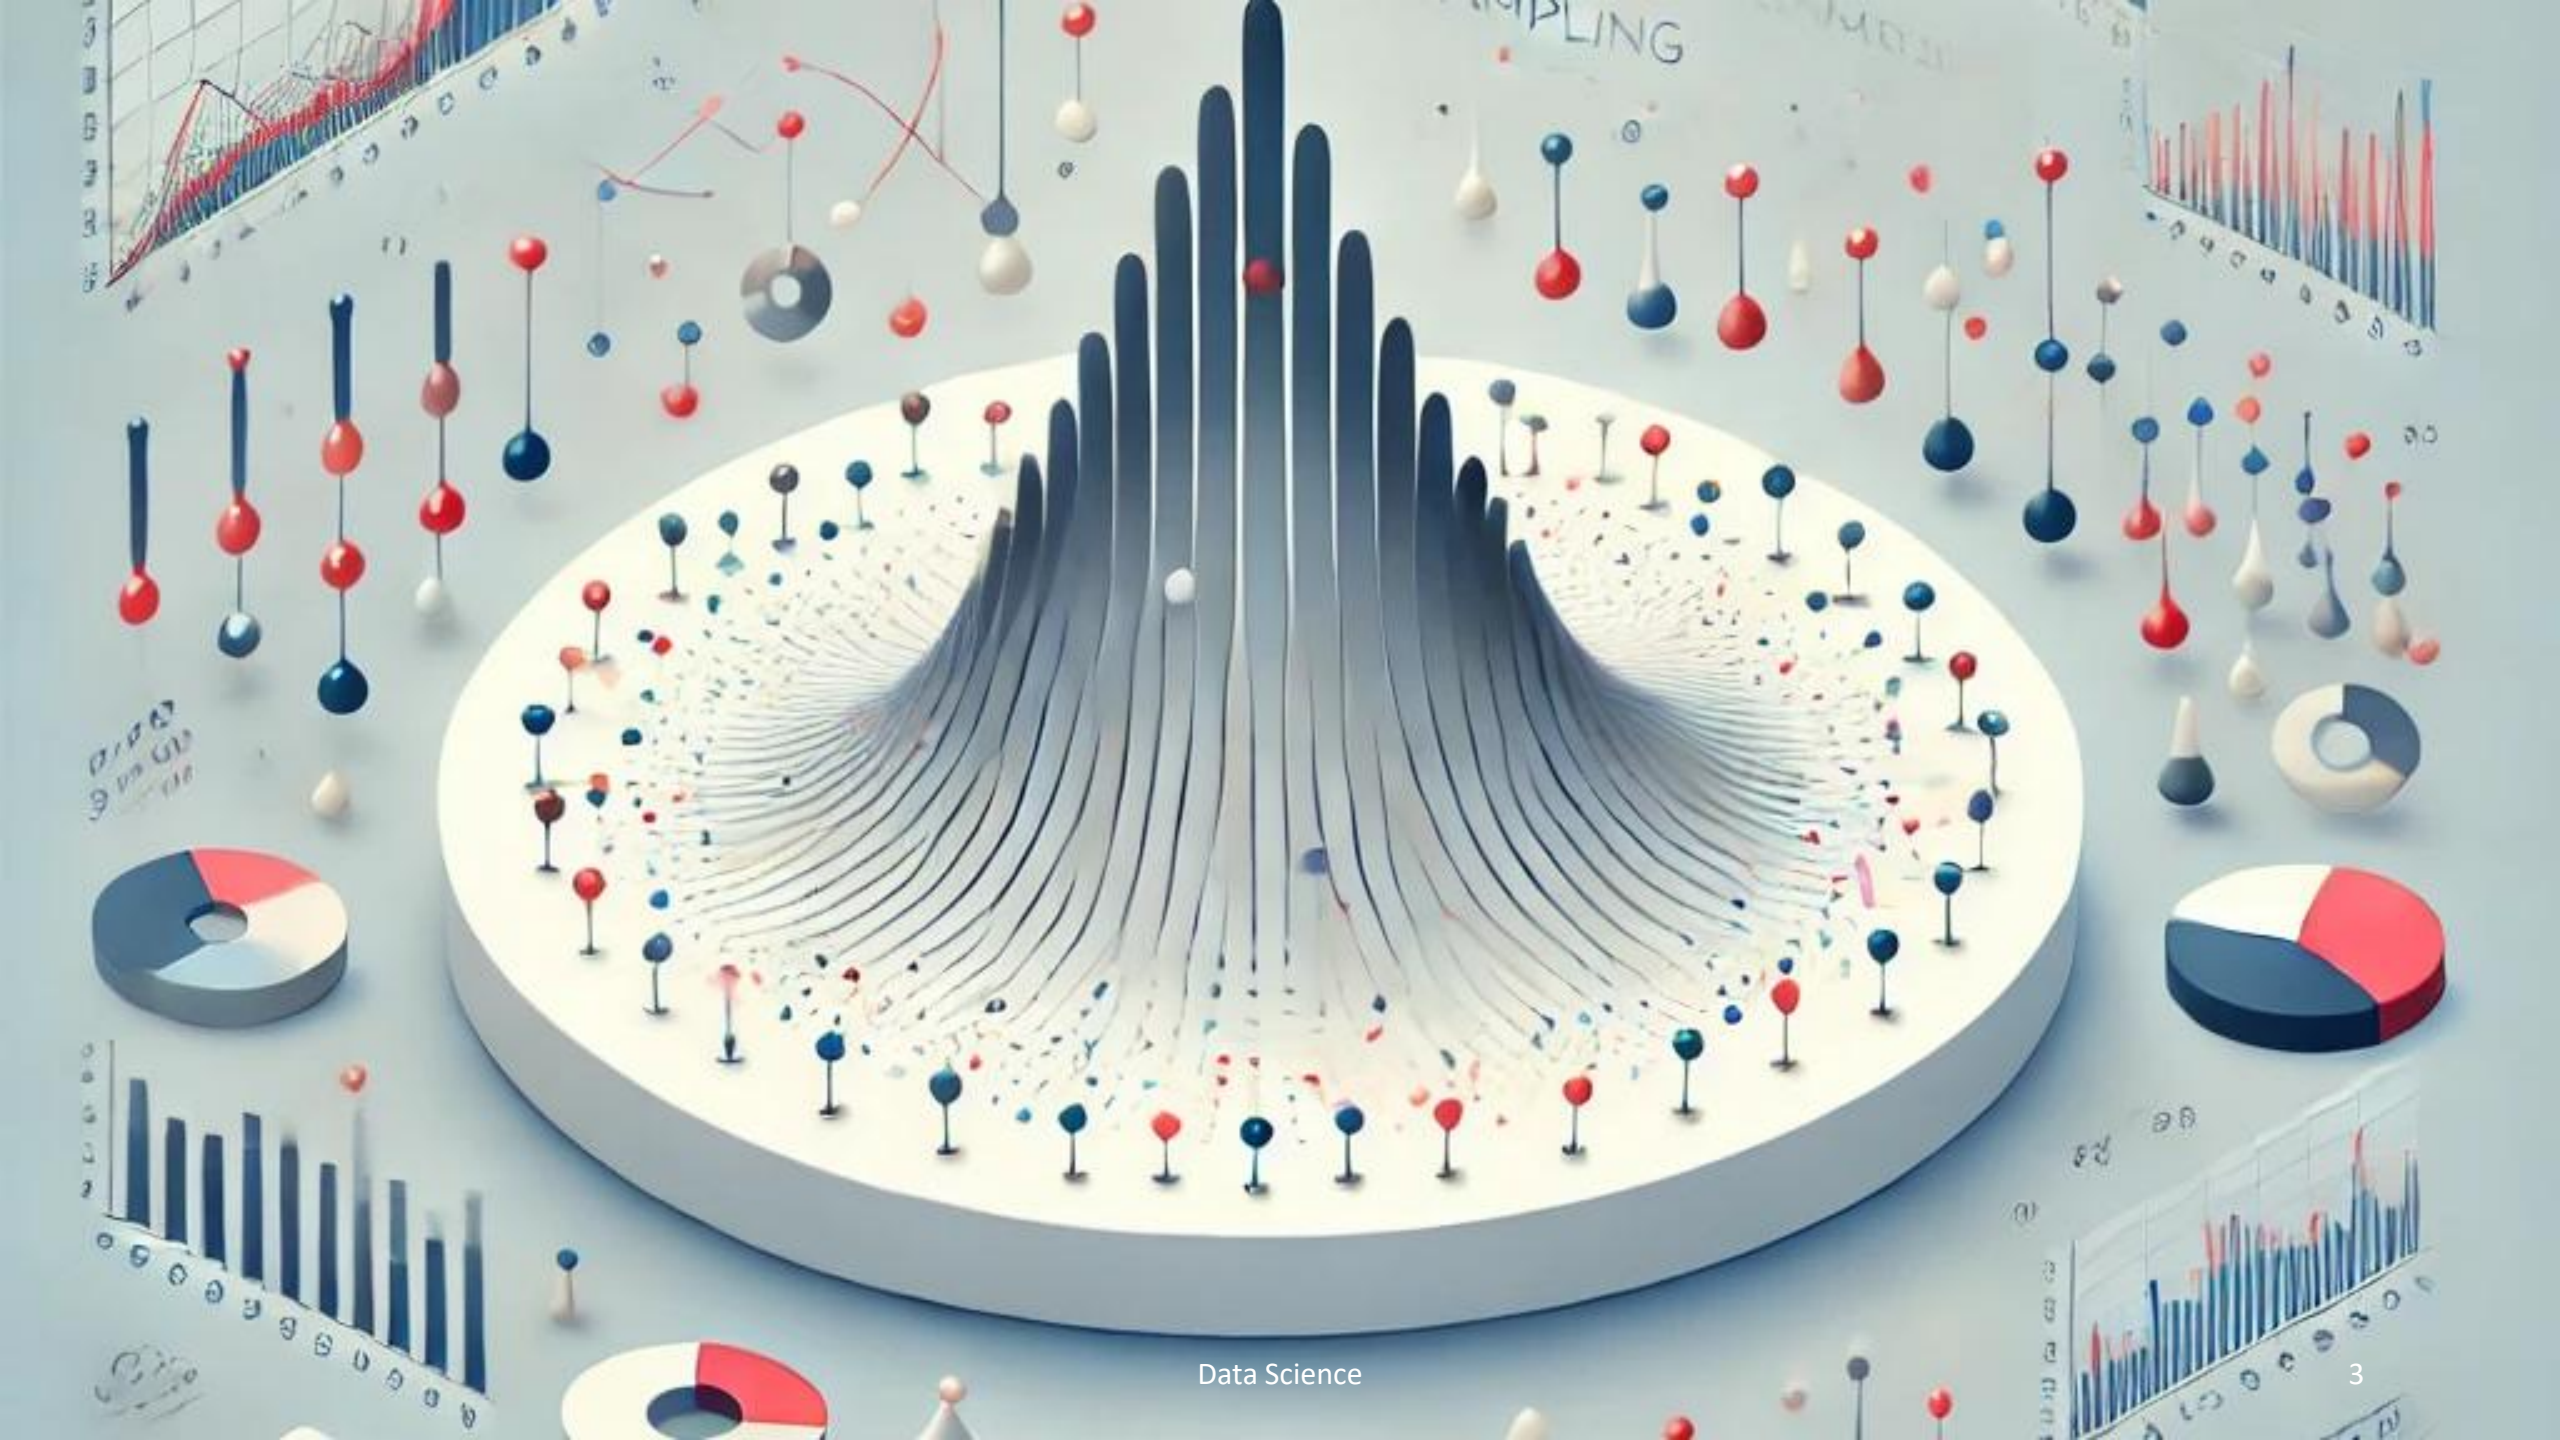
Data Science

Prof.: MSc. Alex Junior Nunes

pfsalexnunes@gmail.com

Data Science

Amostragem e Normalidade Amostral

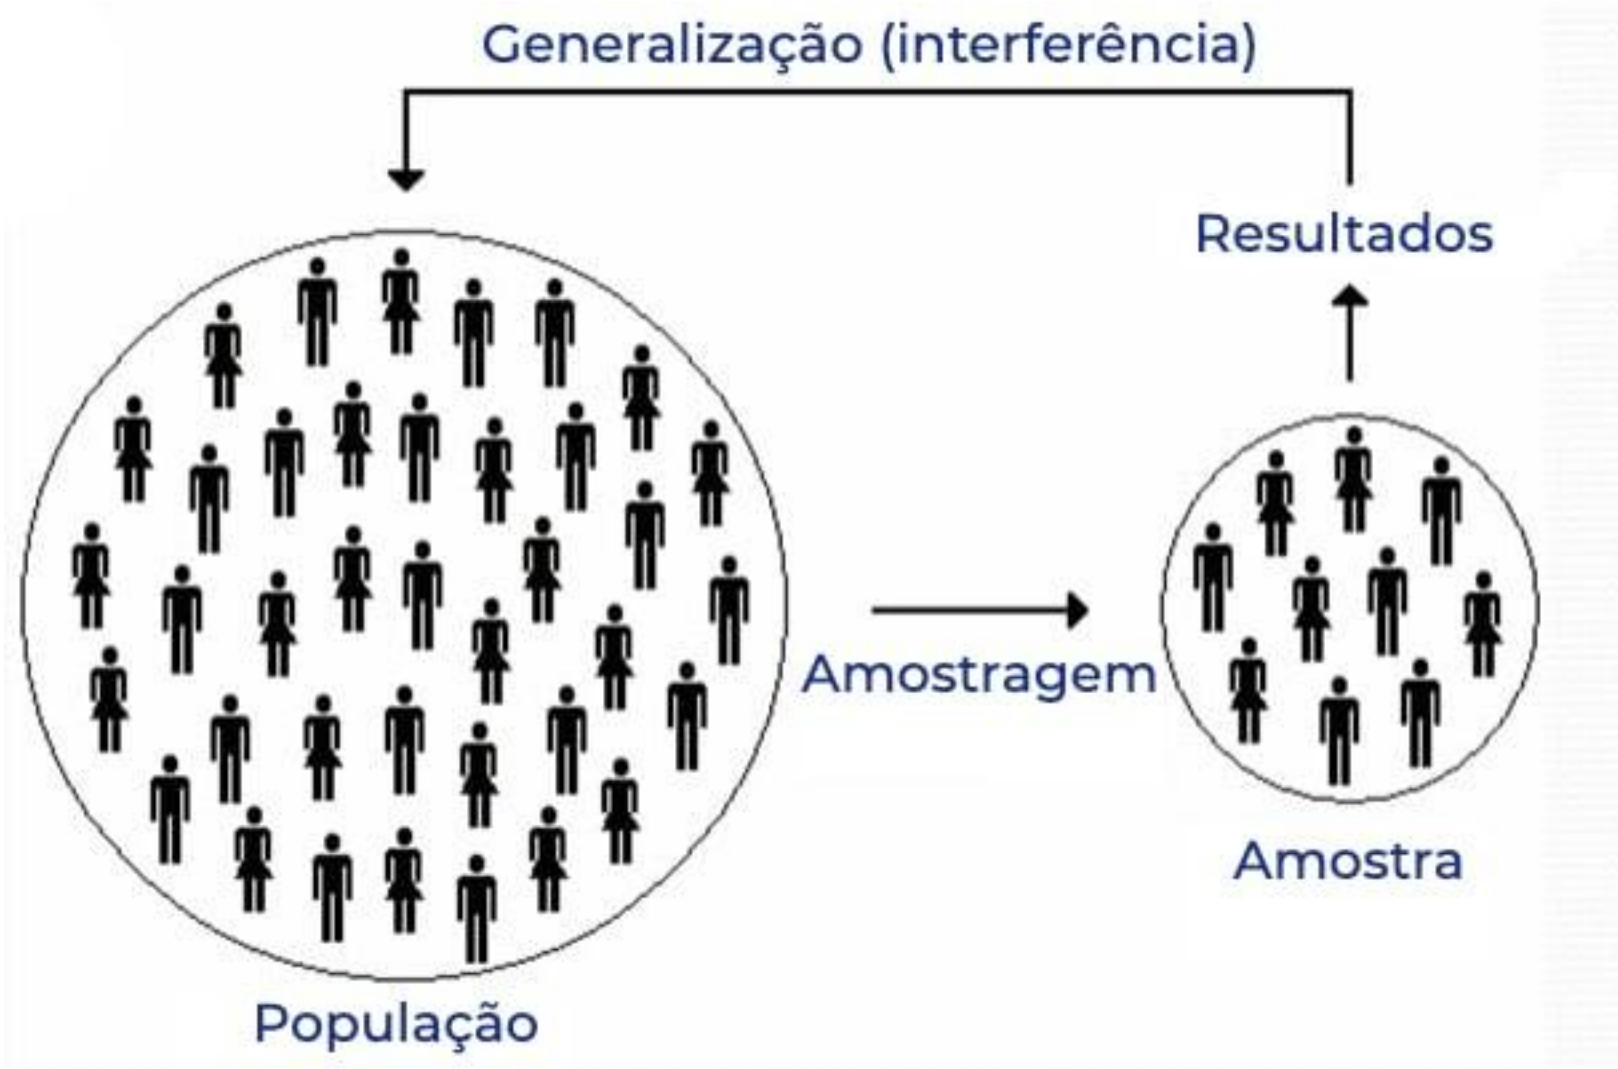


Introdução

- A estatística é uma ferramenta poderosa que nos permite extrair informações valiosas de dados.
- No entanto, muitas vezes é inviável ou impraticável coletar dados de toda uma população.
- É aí que entra a amostragem, um processo de selecionar um subconjunto representativo da população para fazer inferências sobre o todo.

Amostragem

- **População vs. Amostra:** A população é o conjunto completo de indivíduos ou objetos de interesse, enquanto a amostra é um subconjunto selecionado dessa população.
- Por que amostrar? A amostragem é utilizada quando:
  - A população é muito grande.
  - A coleta de dados de toda a população é cara ou demorada.
  - O processo de coleta de dados é destrutivo.


Generalização (interferência)
Resultados
Amostragem
Amostra
População

POPULAÇÃO



amostragem

inferência

AMOSTRA



Tipos de Amostragem

- **Amostragem probabilística:** Cada elemento da população tem uma chance conhecida e diferente de zero de ser selecionado.
- Exemplos incluem:
  - **Amostragem aleatória simples** - cada membro da população tem igual chance de ser escolhido.
  - **Amostragem estratificada** - a população é dividida em subgrupos, e amostras são tiradas de cada subgrupo.
  - **Amostragem sistemática** - seleção de cada k-ésimo indivíduo da população.
  - **Amostragem por conglomerados** - a população é dividida em clusters, e amostras são tiradas de cada cluster.

Tipos de Amostragem

- **Amostragem não probabilística:** A seleção dos elementos da amostra é baseada em critérios subjetivos ou de conveniência.
- Exemplos incluem:
  - **Amostragem por conveniência -** amostras são escolhidas de acordo com a conveniência do pesquisador.
  - **Amostragem por julgamento** - o pesquisador seleciona os elementos da amostra com base em seu julgamento pessoal sobre quais indivíduos ou grupos são mais representativos ou mais relevantes para o estudo.
  - **Amostragem por cotas** - a população é dividida em subgrupos (ou cotas) com base em características específicas, como idade, gênero, renda, etc., e então é selecionado um número predefinido (cota) de indivíduos de cada subgrupo para compor a amostra.

Amostragem na Prática: Um Exemplo de Cada Tipo

- **Aleatória simples** — sortear 50 alunos de uma lista com todos os 2.000 matriculados da faculdade, numerados e sorteados por um gerador aleatório.
- **Estratificada** — dividir os alunos por curso (ADS, Engenharia de Software, IA) e sortear proporcionalmente dentro de cada curso, respeitando o tamanho de cada turma.
- **Sistemática** — usar a lista de chamada e entrevistar 1 a cada 10 alunos (o 5º, o 15º, o 25º...), a partir de um ponto de partida aleatório.
- **Por conglomerados** — sortear 3 salas de aula inteiras entre as 40 salas do campus, e entrevistar TODOS os alunos dessas 3 salas.
- **Por conveniência** — entrevistar os primeiros 50 alunos que passarem na cantina às 12h (mais fácil, porém nada representativo).

Amostragem na Prática: Um Exemplo de Cada Tipo

- **Por julgamento** — o professor escolhe "os 10 alunos mais engajados" para dar opinião sobre uma mudança curricular.
- **Por cotas** — entrevistar exatamente 25 homens e 25 mulheres, respeitando a proporção real da turma, mas escolhendo livremente quem entrevistar dentro de cada cota.

Normalidade Amostral

- **Teorema Central do Limite (TCL):** O TCL é um dos teoremas mais importantes da estatística.
- **Na prática (a fórmula):** a distribuição das médias amostrais se aproxima de uma Normal com média μ (igual à média da população) e desvio-padrão σ/√n (o "erro padrão"). Regra prática: costuma-se considerar n ≥ 30 suficiente para a aproximação funcionar bem.
- Ele afirma que, independentemente da forma da distribuição da população, a distribuição amostral da média tende a uma distribuição normal à medida que o tamanho da amostra aumenta.

Normalidade Amostral

- **Importância da Normalidade Amostral:** A normalidade amostral nos permite:
  - Fazer inferências sobre a população com base na amostra.
  - Construir intervalos de confiança para estimar parâmetros populacionais.
  - Realizar testes de hipóteses para verificar afirmações sobre a população.

Erro Amostral e Margem de Erro

- **A fórmula:** margem de erro (ME) = $z \times \sqrt{p \times (1-p) / n}$ — onde z depende do nível de confiança (z=1,96 para 95%), p é a proporção estimada (usa-se 0,5 no pior caso) e n é o tamanho da amostra.
- **Exemplo com n=100 (nossa dinâmica de hoje):** ME = $1{,}96 \times \sqrt{0{,}25/100} \approx 9{,}8$ pontos percentuais — uma margem enorme! Por isso os Grupos 1 e 2, mesmo sendo aleatórios, não bateram exatamente com o valor real (52,8%).
- **Exemplo com n=2.500 (institutos reais, como o Datafolha):** ME = $1{,}96 \times \sqrt{0{,}25/2.500} \approx 2{,}0$ pontos percentuais — batendo com a margem de ±2 pontos que institutos como o Datafolha realmente divulgam em pesquisas nacionais.
- **O ponto-chave:** essa fórmula só vale para amostras probabilísticas! O erro de mais de 20 pontos dos Grupos 3 e 4 não é "azar de amostragem" — é viés sistemático, e nenhuma fórmula de margem de erro corrige um viés de seleção.

Exemplos e Aplicações

- **Pesquisa de opinião:** Uma pesquisa de opinião utiliza uma amostra de eleitores para estimar a intenção de voto da população. Na prática, institutos como o Datafolha entrevistam entre 2.556 e 5.744 pessoas em pesquisas nacionais, usando amostragem estratificada por município (probabilidade proporcional ao tamanho) e cotas de sexo e idade — o que garante uma margem de erro de cerca de ±2 pontos percentuais, com 95% de confiança.
- **Controle de qualidade:** Em uma fábrica, uma amostra de produtos é inspecionada para verificar se a produção está dentro dos padrões de qualidade.
- **Pesquisa médica:** Um estudo clínico utiliza uma amostra de pacientes para avaliar a eficácia de um novo tratamento.

Dinâmica em Grupo

Pesquisa Eleitoral: Como (Não) Manipular uma Amostra

Caso Real: A Pesquisa Que Errou a Eleição (1936)

- **O que aconteceu:** em 1936, a revista Literary Digest enviou 10 milhões de cartões-postais e recebeu 2,4 milhões de respostas — a maior amostra eleitoral já feita até então.
- **A previsão:** a revista apontava Landon com 57% dos votos contra 43% de Roosevelt.
- **O resultado real:** Roosevelt venceu com 62% dos votos — um erro de 19 pontos percentuais, um dos maiores erros da história das pesquisas eleitorais.
- **A causa do erro:** a lista de contatos veio de listas telefônicas, assinantes de revistas e sócios de clube — em 1936, isso representava as famílias mais ricas, não a população em geral (viés de seleção).
- **O contraste:** George Gallup usou uma amostra muito menor (cerca de 50 mil pessoas), mas bem selecionada, e acertou o vencedor.

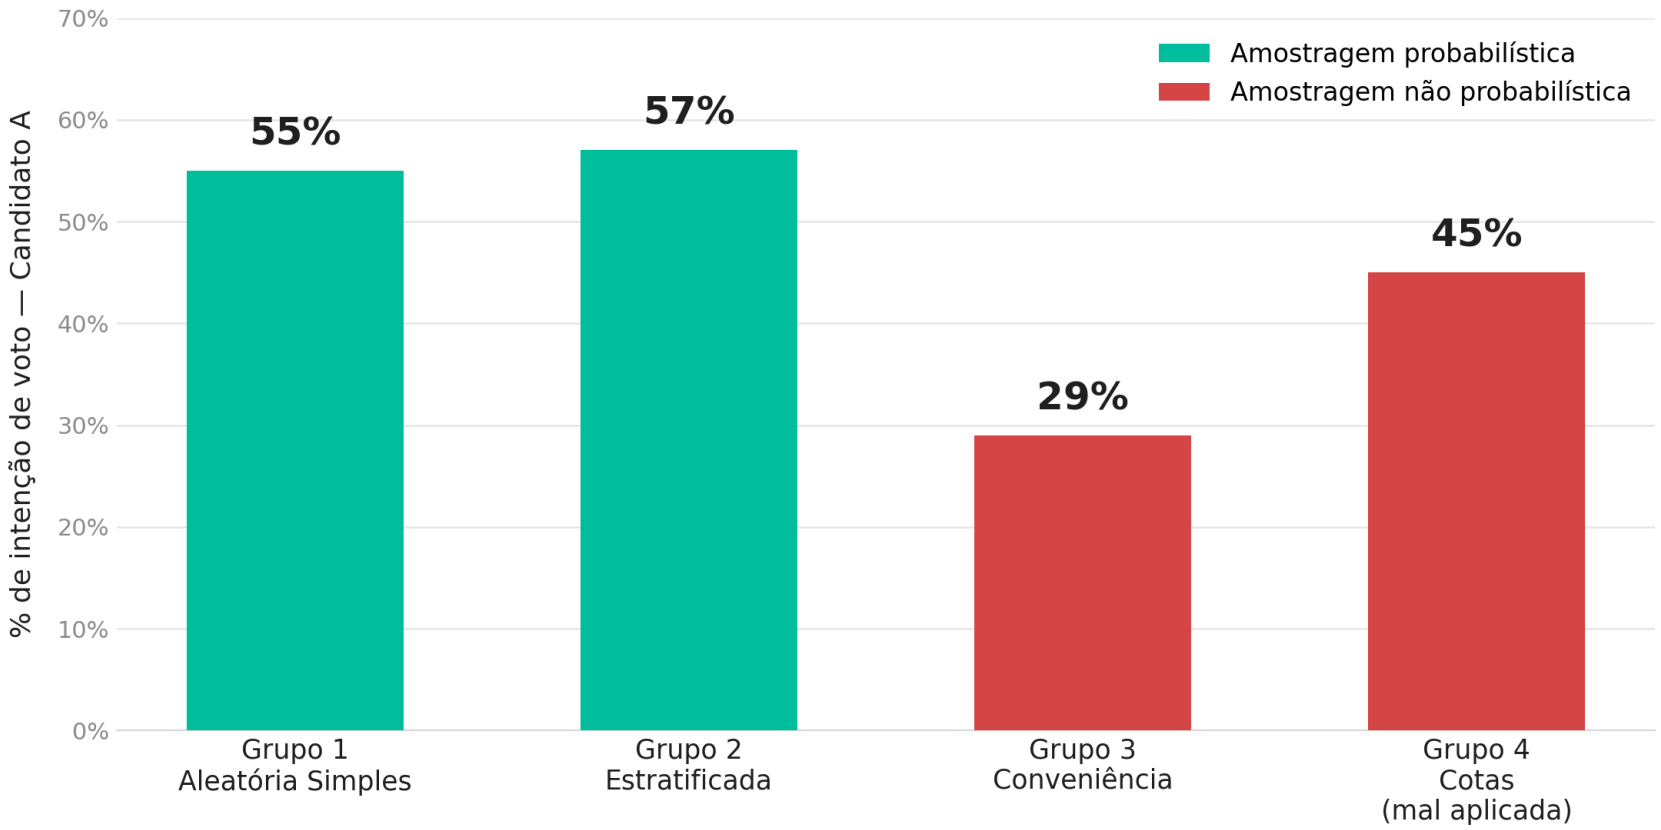
Atividade em Grupos (15–20 min)

- **O cenário:** a cidade fictícia de Serra Verde tem 3.000 eleitores decidindo entre o Candidato A e o Candidato B.
- **A divisão:** a turma se divide em 4 grupos. Cada grupo recebe, na planilha, uma amostra de 100 eleitores já coletada por um método diferente.
- **Os métodos:** Grupo 1 = aleatória simples · Grupo 2 = estratificada · Grupo 3 = conveniência (redes sociais) · Grupo 4 = cotas mal aplicadas.
- **Tarefa (8 min):** abram a aba do seu grupo, leiam o método usado, confiram o resultado calculado automaticamente e registrem no Painel Comparativo.

Pesquisa

- **Grupo 1** — Aleatória simples: todo eleitor tem a mesma chance de ser sorteado. Amostragem probabilística.
- **Grupo 2** — Estratificada: amostra respeita a proporção de cada zona da cidade. Amostragem probabilística.
- **Grupo 3** — Conveniência: pesquisa feita só com eleitores do Centro/Zona Sul com acesso à internet (link no WhatsApp/redes sociais). Amostragem não probabilística.
- **Grupo 4** — Cotas mal aplicada: cotas por idade corretas, mas só entrevistando no Centro/Zona Sul por comodidade. Amostragem não probabilística.

Vamos Comparar os Resultados dos Grupos



Vamos Comparar os Resultados dos Grupos

Grupo / População	Tipo	% Candidato A	% Candidato B	Acertou o vencedor?
POPULAÇÃO REAL (N=3.000)	—	52,8%	47,2%	—
Grupo 1 — Aleatória Simples	Probabilística	55,0%	45,0%	Sim
Grupo 2 — Estratificada	Probabilística	57,0%	43,0%	Sim
Grupo 3 — Conveniência	Não probabilística	29,0%	71,0%	Não (inverteu)
Grupo 4 — Cotas mal aplicada	Não probabilística	45,0%	55,0%	Não (inverteu)

Debate: O Que os Resultados Revelam?

- **O resultado real:** na população completa (N = 3.000), o Candidato A tem 52,8% e o Candidato B tem 47,2% — o Candidato A venceria a eleição.
- **Os grupos probabilísticos:** Grupos 1 e 2 (aleatória simples e estratificada) ficaram próximos do valor real e apontaram o candidato certo.
- **Os grupos não probabilísticos:** Grupos 3 e 4 (conveniência e cotas mal aplicadas) inverteram o resultado — apontaram o Candidato B como vencedor, exatamente como aconteceu com o Literary Digest em 1936.
- **Acaso ou viés?** com n=100, a margem de erro esperada é de ±9,8 pontos (slide "Erro Amostral e Margem de Erro"). Os Grupos 3 e 4 erraram por mais de 20 pontos — mais do que o dobro do que a margem de erro sozinha explicaria. Isso confirma: foi viés sistemático, não azar.
- **Para debater:** por que aumentar o tamanho da amostra não resolveria o problema dos Grupos 3 e 4? O que isso ensina sobre pesquisas que circulam nas redes sociais?

Conclusão

- A amostragem e a normalidade amostral são conceitos fundamentais na estatística.
- A amostragem nos permite obter informações sobre uma população de forma eficiente e econômica, enquanto a normalidade amostral nos fornece as ferramentas para fazer inferências confiáveis sobre a população com base na amostra.
- **O que a dinâmica de hoje mostrou:** tamanho de amostra e método de amostragem são coisas diferentes. O tamanho define a margem de erro (o "ruído" aleatório); o método define se existe viés sistemático — e nenhuma fórmula estatística corrige um viés de seleção.
- **Para levar:** antes de confiar em qualquer estatística — pesquisa eleitoral, enquete de rede social, avaliação de produto — pergunte sempre: como essa amostra foi coletada, e quem ela deixou de fora?