

Universidade POSITIVO

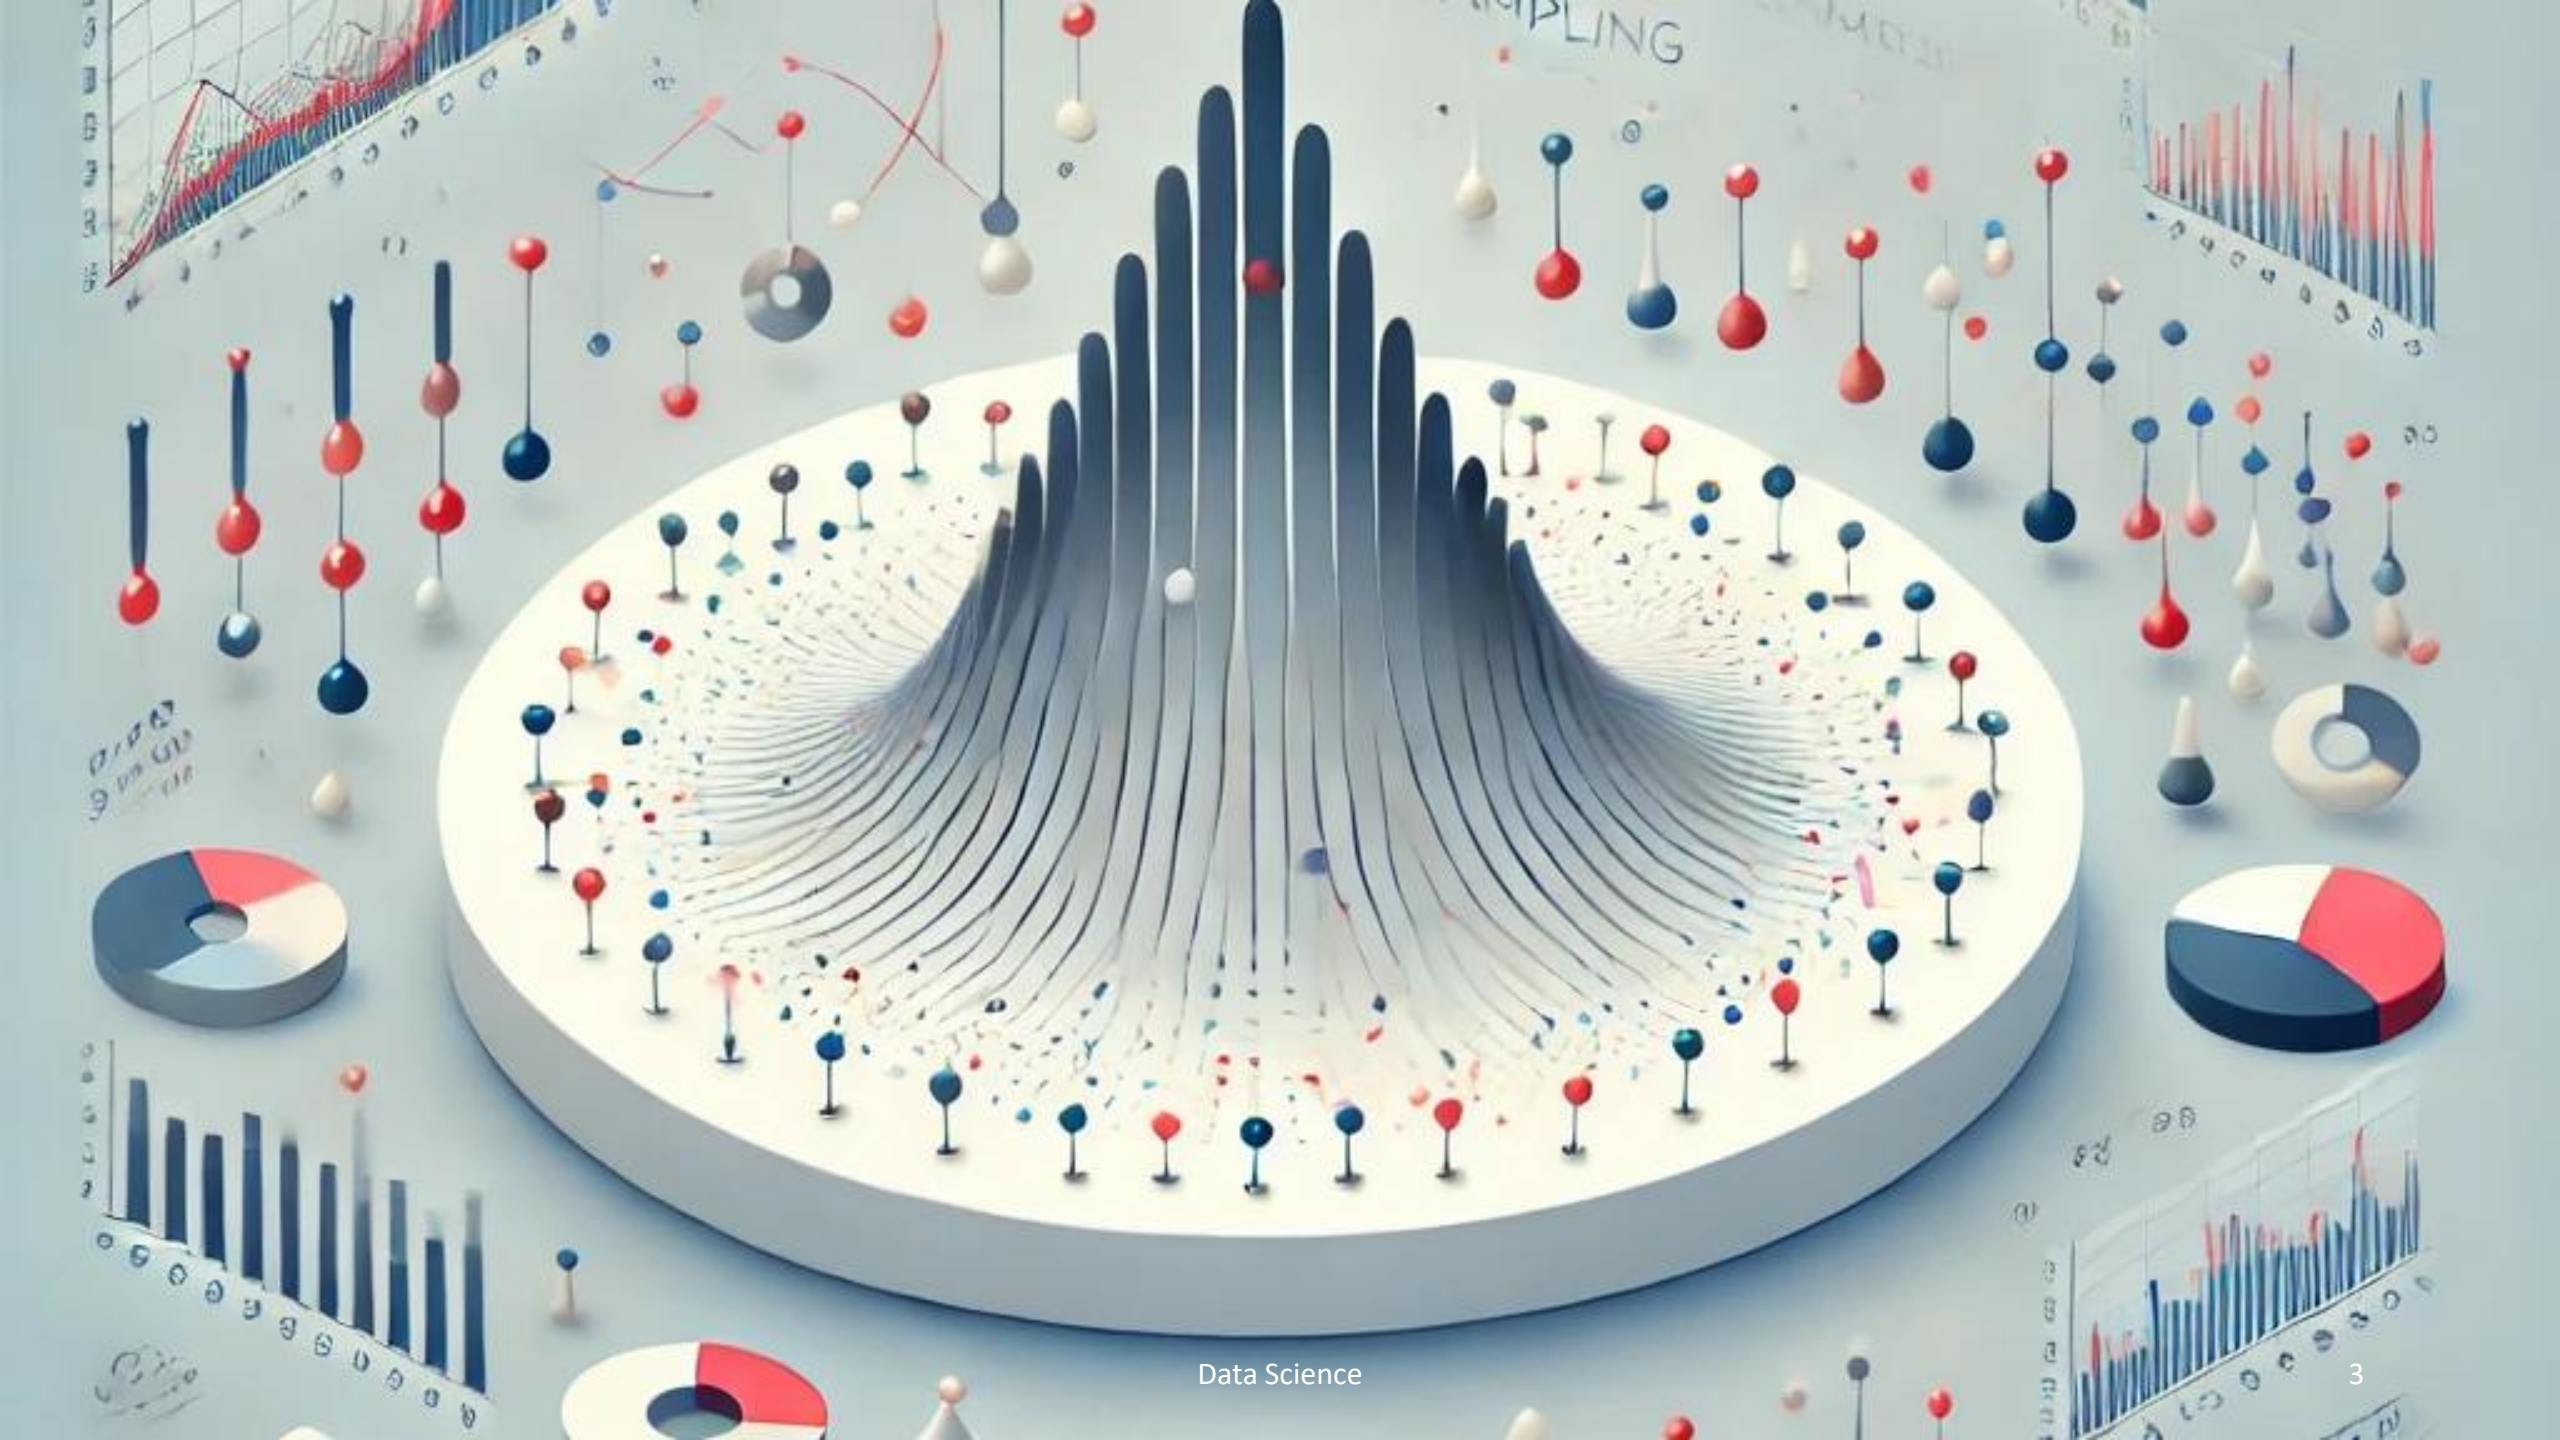
Data Science

Prof.: MSc. Alex Junior Nunes

pfsalexnunes@gmail.com

Data Science

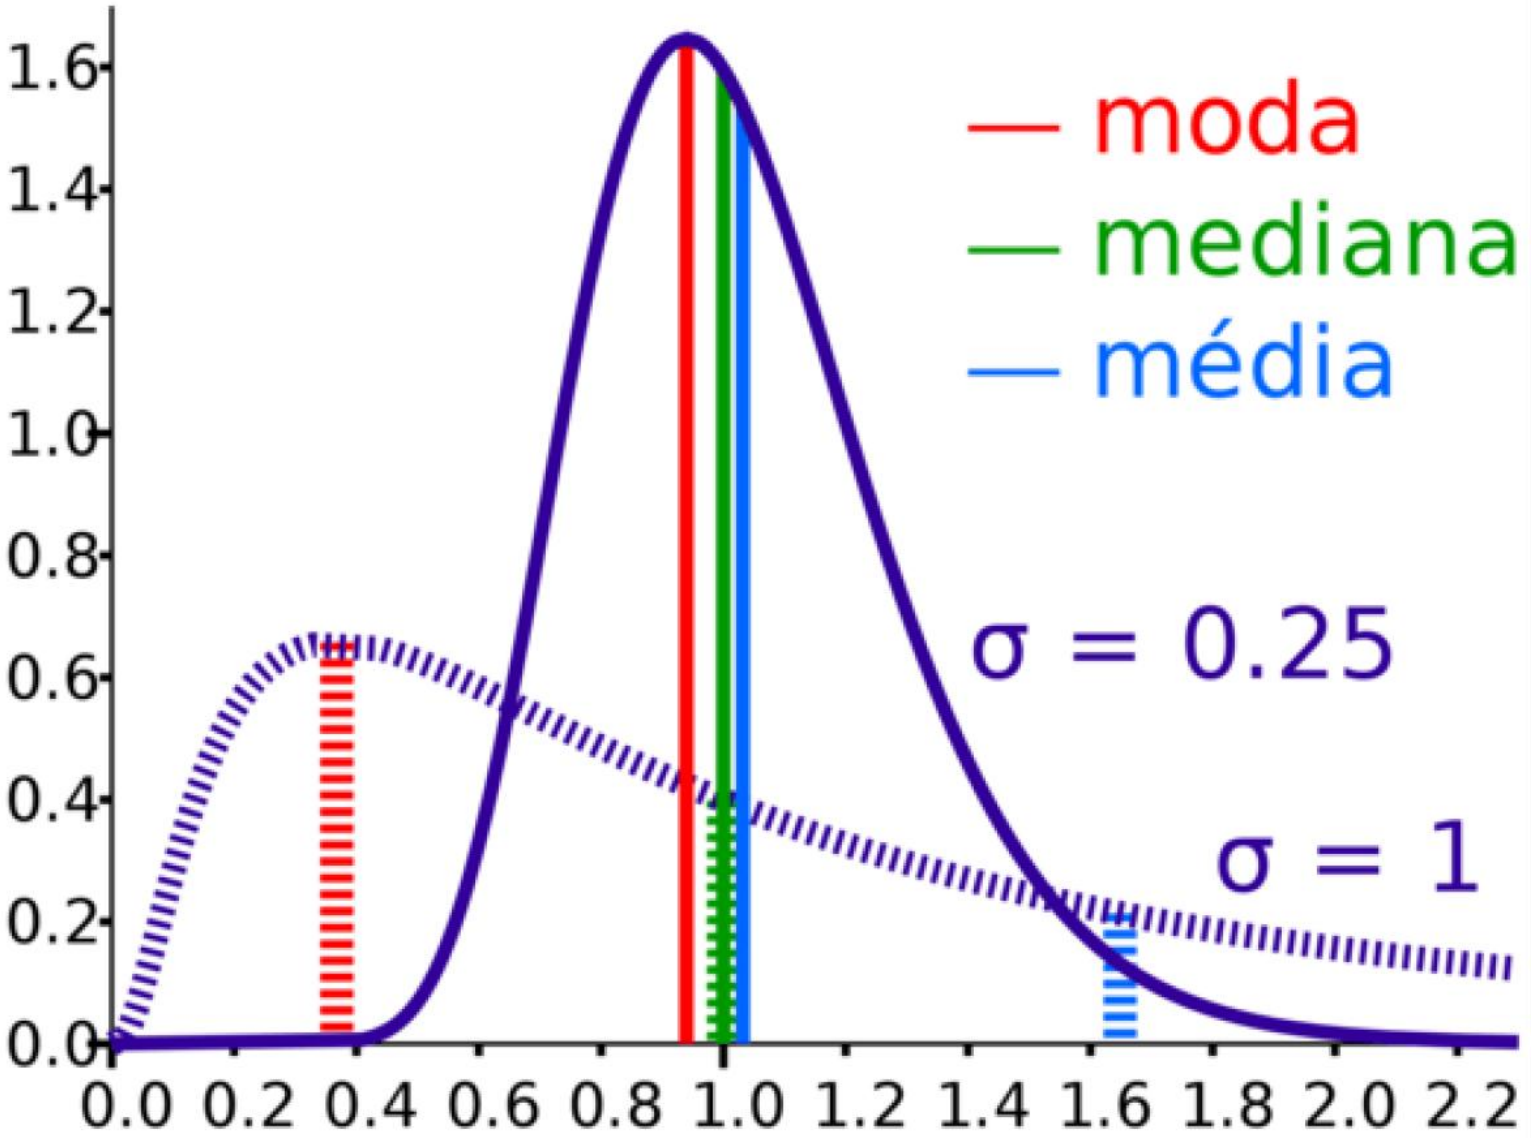
Média, Mediana, Variância e Desvio Padrão: Explorando a Estatística Descritiva



O que é Estatística Descritiva?

- A Estatística Descritiva é um ramo da Estatística que se concentra em resumir e descrever as características principais de um conjunto de dados.
- Ela nos ajuda a entender a distribuição dos dados, identificar tendências e comparar diferentes conjuntos de informações.
- As medidas de **tendência central** (média, mediana e moda) e as **medidas de dispersão** (variância e desvio padrão) são ferramentas essenciais da Estatística Descritiva.

Medidas de Tendência Central


1.6
1.4
1.2
1.0
0.8
0.6
0.4
0.2
0.0
0.0 0.2 0.4 0.6 0.8 1.0 1.2 1.4 1.6 1.8 2.0 2.2
moda
mediana
média
σ = 0.25
σ = 1

Média: O Ponto de Equilíbrio

- A média é a soma de todos os valores em um conjunto de dados dividida pelo número de observações.
- É uma medida de tendência central que representa o valor "típico" ou "esperado" dos dados.

- Atenção, pois é média é sensível a valores extremos!

- Fórmula: Média = (Soma de todos os valores) / (Número de valores)
- **Exemplo:** Calcular a média das idades de um grupo de pessoas.

Média: O Ponto de Equilíbrio - Exemplos

- **Notas escolares:** A média das suas notas em uma disciplina indica seu desempenho geral.
- **Consumo de combustível:** A média de quilômetros por litro do seu carro ajuda a estimar gastos com combustível em viagens.
- **Salário médio:** O salário médio de uma profissão dá uma ideia de quanto se espera ganhar naquela área. ☹
- **Temperatura média:** A temperatura média de uma cidade ao longo do ano ajuda a entender o clima local.

Média: O Ponto de Equilíbrio - Exemplos

- **Renda no Brasil:** segundo o IBGE (PNAD Contínua, 2025), o rendimento domiciliar per capita médio do país foi de R$ 2.316 — mas essa média esconde uma disparidade enorme entre regiões (veja o slide "Exemplo Real", mais adiante).

$$\overline{x} = \frac{(x_1 + x_2 + x_3 + \ldots + x_n)}{n}$$

$$\overline{x} = \frac{\sum x_i}{n}$$

Mediana: O Valor do Meio

- A mediana é o valor que divide um conjunto de dados ordenados em duas metades iguais.
- É uma medida de tendência central robusta a valores extremos, ou seja, não é afetada por outliers.
- **Como calcular:**
  1. Ordenar os dados em ordem crescente ou decrescente.
  2. Se o número de observações for ímpar, a mediana é o valor central.
  3. Se o número de observações for par, a mediana é a média dos dois valores centrais.

Exemplo: Calcular a mediana dos salários de uma empresa.

Mediana: O Valor do Meio - Exemplos

- **Preço de imóveis:** A mediana do preço de casas em um bairro é uma medida mais representativa do valor típico de um imóvel, pois não é afetada por casas muito caras ou muito baratas.
- **Salários:** A mediana salarial em uma empresa mostra o salário do funcionário que está no meio da distribuição, o que pode ser mais informativo do que a média se houver grandes disparidades salariais.
- **Tempo de espera:** A mediana do tempo de espera em uma fila indica o tempo que metade das pessoas esperou ou menos, o que é útil para ter uma ideia realista da espera.

Mediana: O Valor do Meio - Exemplos

- **Renda no Brasil:** é exatamente por isso que economistas preferem a mediana à média para descrever a renda "típica" de uma família brasileira — a média nacional (R$ 2.316, IBGE 2025) é puxada para cima por quem ganha muito mais que a maioria.

$$\tilde{x} = \frac{1}{2}\left(x\,\frac{n}{2} + x\,\frac{n}{2} + 1\right)$$

$$\text{Med}(X) = \begin{cases} X_{\frac{n+1}{2}} & \text{si n es impar} \\ \dfrac{X_{\frac{n}{2}} + X_{\frac{n}{2}+1}}{2} & \text{si n es par} \end{cases}$$

Moda: O Valor Mais Frequente

- A moda é o valor que aparece com maior frequência em um conjunto de dados
- Um conjunto de dados pode ter uma moda (unimodal), mais de uma moda (multimodal) ou nenhuma moda.
- **Exemplo:** Calcular a moda das cores de carros em um estacionamento

Moda: O Valor Mais Frequente - Exemplos

- **Tamanho de roupa:** A moda em uma loja de roupas indica o tamanho mais vendido, o que ajuda a decidir quais tamanhos devem ser mais estocados.
- **Preferência de cor:** A moda entre as cores de carros em um estacionamento mostra qual cor é mais popular.
- **Prato mais pedido:** A moda em um restaurante indica qual prato é o mais popular entre os clientes.

Fórmula de Czuber

$$\mathbf{moda} = \mathrm{L_i} + \left(\frac{\Delta_1}{\Delta_1 + \Delta_2} \right) \times c$$

Onde
- $\mathrm{L_i}$ - limite inferior da classe modal;
- $\Delta_1 = \mathrm{f_{mo}} - \mathrm{f_{ant}}$ - excesso da freq. modal sobre a classe anterior;
- $\Delta_2 = \mathrm{f_{mo}} - \mathrm{f_{pos}}$ - excesso da freq. modal sobre a classe posterior;
- $\mathrm{c} = \mathrm{L_s} - \mathrm{L_i}$ - amplitude da classe modal.

Variância: Medindo a Dispersão

- A variância mede o quão espalhados estão os dados em relação à média.
- Uma variância alta indica que os dados estão mais dispersos, enquanto uma variância baixa indica que os dados estão mais próximos da média.

- Fórmula: Variância = (Soma dos quadrados das diferenças entre cada valor e a média) / (Número de valores)

- **Exemplo:** Calcular a variância das notas de uma turma.

$$VAR = \frac{\Sigma | x - \mu |^2}{N}$$

Desvio Padrão: A Raiz da Variância

- O desvio padrão é a raiz quadrada da variância.
- É uma medida de dispersão que está na mesma unidade de medida dos dados originais, o que facilita a interpretação.
- Chamado de DP ou de s^2

- Fórmula: Desvio Padrão = √Variância

- **Exemplo:** Calcular o desvio padrão das alturas de um grupo de pessoas.

Variância e Desvio Padrão: Exemplos

- **Controle de qualidade:** Em uma fábrica, a variância e o desvio padrão das medidas de peças produzidas indicam a consistência do processo de produção. Baixa variabilidade significa que as peças são mais uniformes.
- **Investimentos:** A variância e o desvio padrão do retorno de um investimento medem o seu risco. Maior variabilidade significa maior potencial de ganhos ou perdas.
- **Notas de provas:** O desvio padrão das notas de uma prova mostra o quão dispersos estão os resultados dos alunos. Um desvio padrão alto indica maior variedade de desempenhos.

Variância e Desvio Padrão: Exemplos

- **Tempo de resposta de sistemas:** na Engenharia de Software, um desvio padrão alto no tempo de resposta de uma API indica um sistema instável — alguns usuários têm experiência rápida, outros esperam muito mais (veja o slide de percentis, mais adiante).

$$DP = \sqrt{\frac{\Sigma| x - \mu |^2}{N}}$$

Amplitude: A Extensão dos Dados

- A amplitude é a diferença entre o maior e o menor valor em um conjunto de dados
- É uma medida de dispersão simples, mas sensível a valores extremos (outliers)

- Fórmula: Amplitude = Valor Máximo - Valor Mínimo

- **Exemplo:** Calcular a amplitude das temperaturas diárias em uma semana

Amplitude: A Extensão dos Dados - Exemplos

- **Variação de temperatura:** A amplitude da temperatura em um dia indica a diferença entre a temperatura máxima e mínima, o que ajuda a escolher a roupa adequada.
- **Alcance de um sinal:** A amplitude de um sinal de rádio indica a sua força e alcance.
- **Diferença de idade:** A amplitude de idade em um grupo de pessoas mostra a diferença entre a pessoa mais velha e a mais nova.

Amplitude: A Extensão dos Dados - Exemplos

- **Renda entre estados:** a amplitude entre a renda per capita média do Distrito Federal (R$ 4.538) e do Maranhão (R$ 1.219) é de mais de R$ 3.300 — um retrato simples, mas contundente, da desigualdade regional brasileira (IBGE, 2025).

$$DP = \sqrt{\frac{\Sigma| x - \mu |^2}{N}}$$

Estatística na Prática: Percentis em Engenharia de Software

- **O problema com a média:** se 99 requisições de uma API respondem em 50ms e 1 trava em 20 segundos, a MÉDIA de tempo de resposta sobe bastante — mas isso não representa a experiência de quase ninguém.
- **A solução da indústria: percentis.** em vez da média, equipes de engenharia usam p50 (a mediana — metade das requisições foi mais rápida que isso), p95 e p99 (o tempo que só 5% ou 1% das requisições piores ultrapassam).
- **Por que isso é dispersão:** p95 e p99 são, na prática, uma forma de medir o quão espalhada (dispersa) é a distribuição do tempo de resposta — o mesmo espírito da variância e do desvio padrão, mas focado na cauda (os piores casos).
- **Onde você vai ver isso:** painéis de monitoramento (Datadog, Grafana, New Relic) de empresas como Google, Netflix e Amazon reportam SLOs (Service Level Objectives) quase sempre em termos de p95/p99, não de média.

Quando Usar Cada Medida?

- **Média:** Útil quando os dados estão distribuídos simetricamente e não há outliers significativos.
- **Mediana:** Útil quando há outliers ou a distribuição dos dados é assimétrica.
- **Moda:** Útil para dados categóricos ou quando se deseja identificar o valor mais comum
- **Variância e Desvio Padrão:** Úteis para entender a dispersão dos dados e comparar a variabilidade entre diferentes conjuntos de dados.
- **Amplitude:** Útil para uma rápida noção da dispersão dos dados, mas sensível a outliers

Estatística Descritiva: Uma Ferramenta Poderosa

- A Estatística Descritiva nos permite resumir e entender grandes quantidades de dados de forma clara e concisa.
- As medidas de tendência central e dispersão são ferramentas essenciais para descrever e comparar conjuntos de dados.
- Ao dominar essas medidas, você estará equipado para analisar dados e tomar decisões informadas em diversas áreas.
- **Vimos isso no mundo real hoje:** da desigualdade de renda no Brasil (IBGE) aos percentis de latência que empresas como Google e Netflix monitoram todos os dias — as mesmas 5 medidas que vimos aqui aparecem por trás de decisões importantes.

Estatística Descritiva: Uma Ferramenta Poderosa

- **Próximo passo:** vamos praticar tudo isso em Python, calculando e visualizando essas medidas em um conjunto de dados real, no Google Colab.