

Universidade POSITIVO

# Data Science

Prof.: MSc. Alex Junior Nunes

pfsalexnunes@gmail.com

# Data Science

## Distribuição de Frequências, Histograma e Distribuição Normal

# Dinâmica de Abertura: Dados da Nossa Própria Sala

- **O que vamos fazer:** coletar, ao vivo, a altura (em cm) de cada pessoa presente — das duas turmas — e usar esse dado real para construir nossa própria distribuição de frequências hoje.
- **Como participar:** quando eu pedir, informe sua altura em voz alta (ou pelo formulário/chat que eu compartilhar) — vale para todo mundo, de ambas as turmas.
- **Por que altura:** é um dos exemplos clássicos de variável que segue (aproximadamente) uma distribuição normal — hoje vocês vão comprovar isso com dados da própria sala, não de um exemplo de livro.
- **Guardem o número:** vamos usar esses dados ao longo de toda a aula, direto no notebook do Google Colab.

# Distribuição de frequências

- **O que é:** Uma representação tabular ou gráfica que mostra a frequência com que diferentes valores ou intervalos de valores ocorrem em um conjunto de dados
- **Importância:** Permite visualizar a forma como os dados estão distribuídos, identificar tendências centrais, dispersão e possíveis outliers

# Distribuição de frequências - Tipos

- **Absoluta:** Conta o número de vezes que cada valor ou intervalo ocorre
- **Relativa:** Expressa a frequência como uma proporção ou porcentagem do total de observações
- **Acumulada:** Soma as frequências de todos os valores ou intervalos até um determinado ponto

# Distribuição de frequências

- Construção:

- Dividir os dados em intervalos de classes (bins)
- Contar o número de observações em cada intervalo
- Informar o valor da contagem (quantidade) em cada classe

# Distribuição de frequências - Exemplos

| Ordem | Classe | Frequência (fi) |
|---|---|---|
| 1 | 1,55 \|- 1,57 | 2 |
| 2 | 1,57 \|- 1,59 | 6 |
| 3 | 1,59 \|- 1,61 | 7 |
| 4 | 1,61 \|- 1,63 | 8 |
| 5 | 1,63 \|- 1,65 | 2 |
| 6 | 1,65 \|- 1,67 | 1 |

# Distribuição de frequências - Exemplos

| Km rodados por veículo | Frequência Absoluta $f_i$ | Frequência relativa $f_{ri}$ (%) | Frequência acumulada $F_{ac}$ | Frequência Acumulada Relativa $F_{Ri}$ (%) |
|---|---|---|---|---|
| 20 ->29 | 3 | 14% | 3,3 | 14% |
| 29 -> 38 | 6 | 25% | 9,3 | 38% |
| 38 -> 47 | 6 | 25% | 15,3 | 63% |
| 47 - > 56 | 4 | 16% | 19,3 | 79% |
| 56 -> 65 | 5 | 21% | 24,3 | 100% |
| Total | 24 | 100% | ---- | ---- |

# Regra de Sturges

$$k = 1 + 3,3 \cdot log_{10}(n)$$

# Histograma

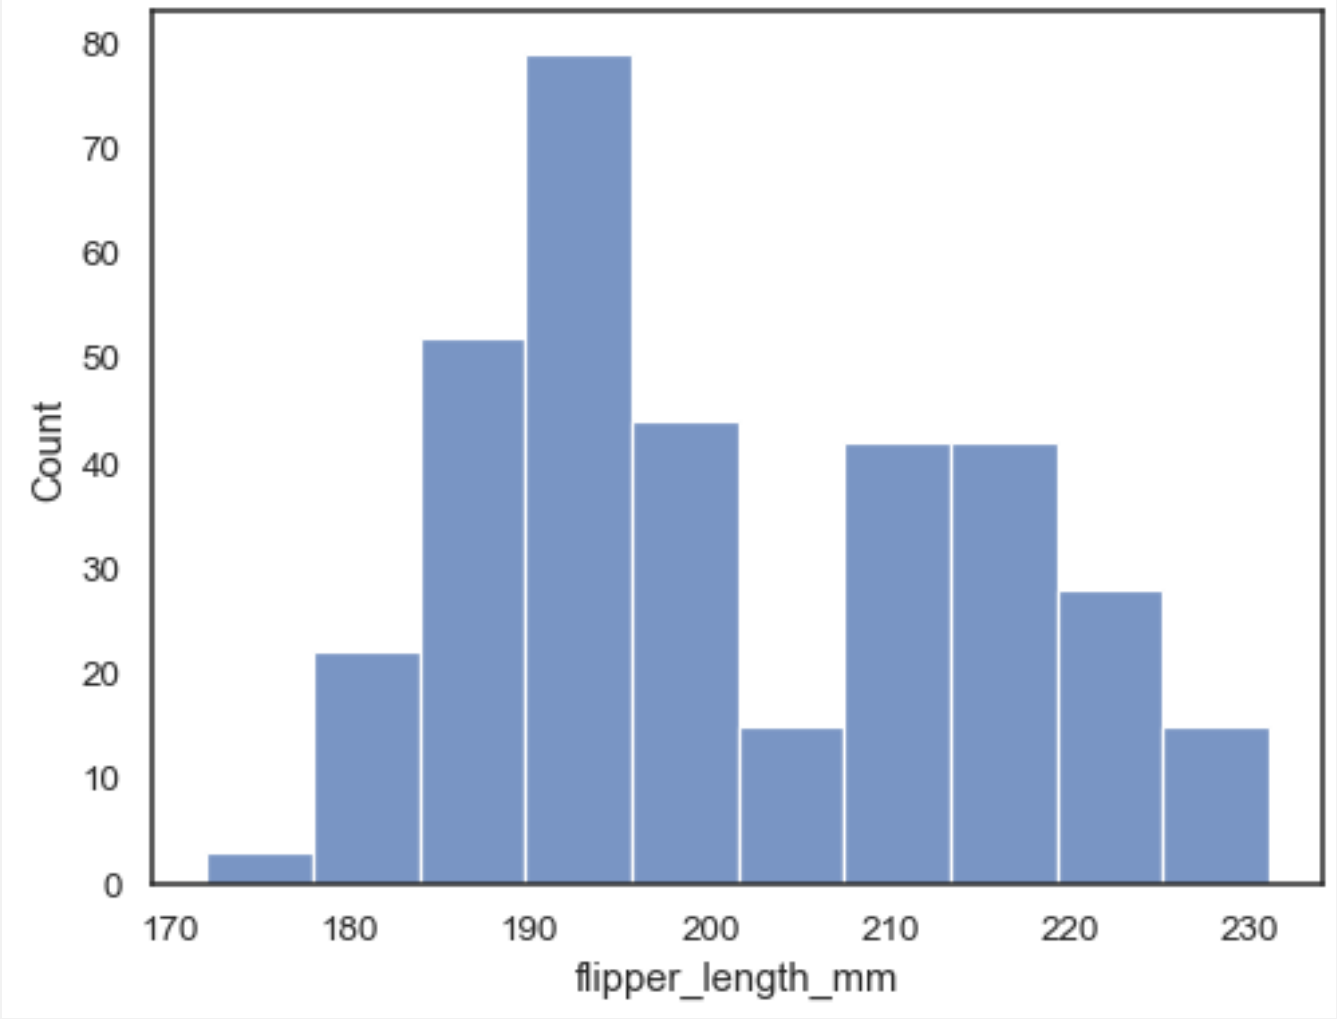
- **O que é:** Um gráfico de barras que representa a distribuição de frequências de um conjunto de dados numéricos

- **Construção:**
- Dividir os dados em intervalos de classes (bins)
- Contar o número de observações em cada intervalo
- Representar cada intervalo por uma barra, onde a altura da barra corresponde à frequência do intervalo

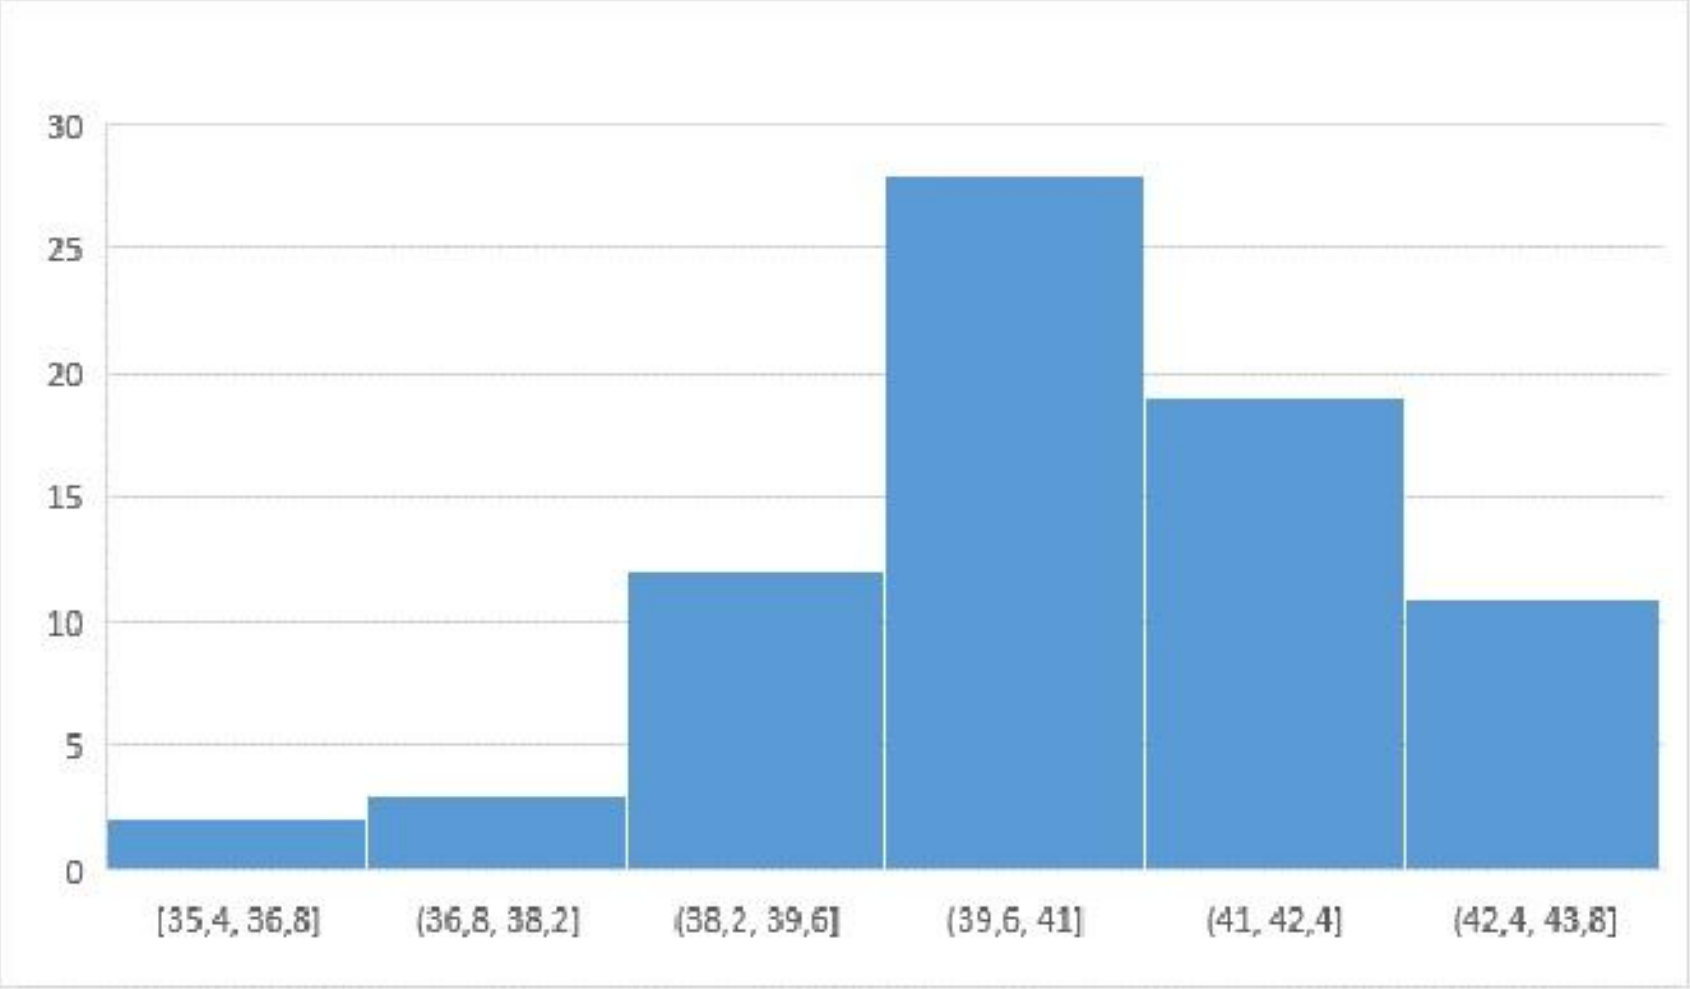
# Histograma - Interpretação

- A forma do histograma revela a distribuição dos dados (simétrica, assimétrica, unimodal, bimodal, etc.)
- A localização das barras indica a tendência central dos dados
- A dispersão das barras mostra a variabilidade dos dados

# Histograma

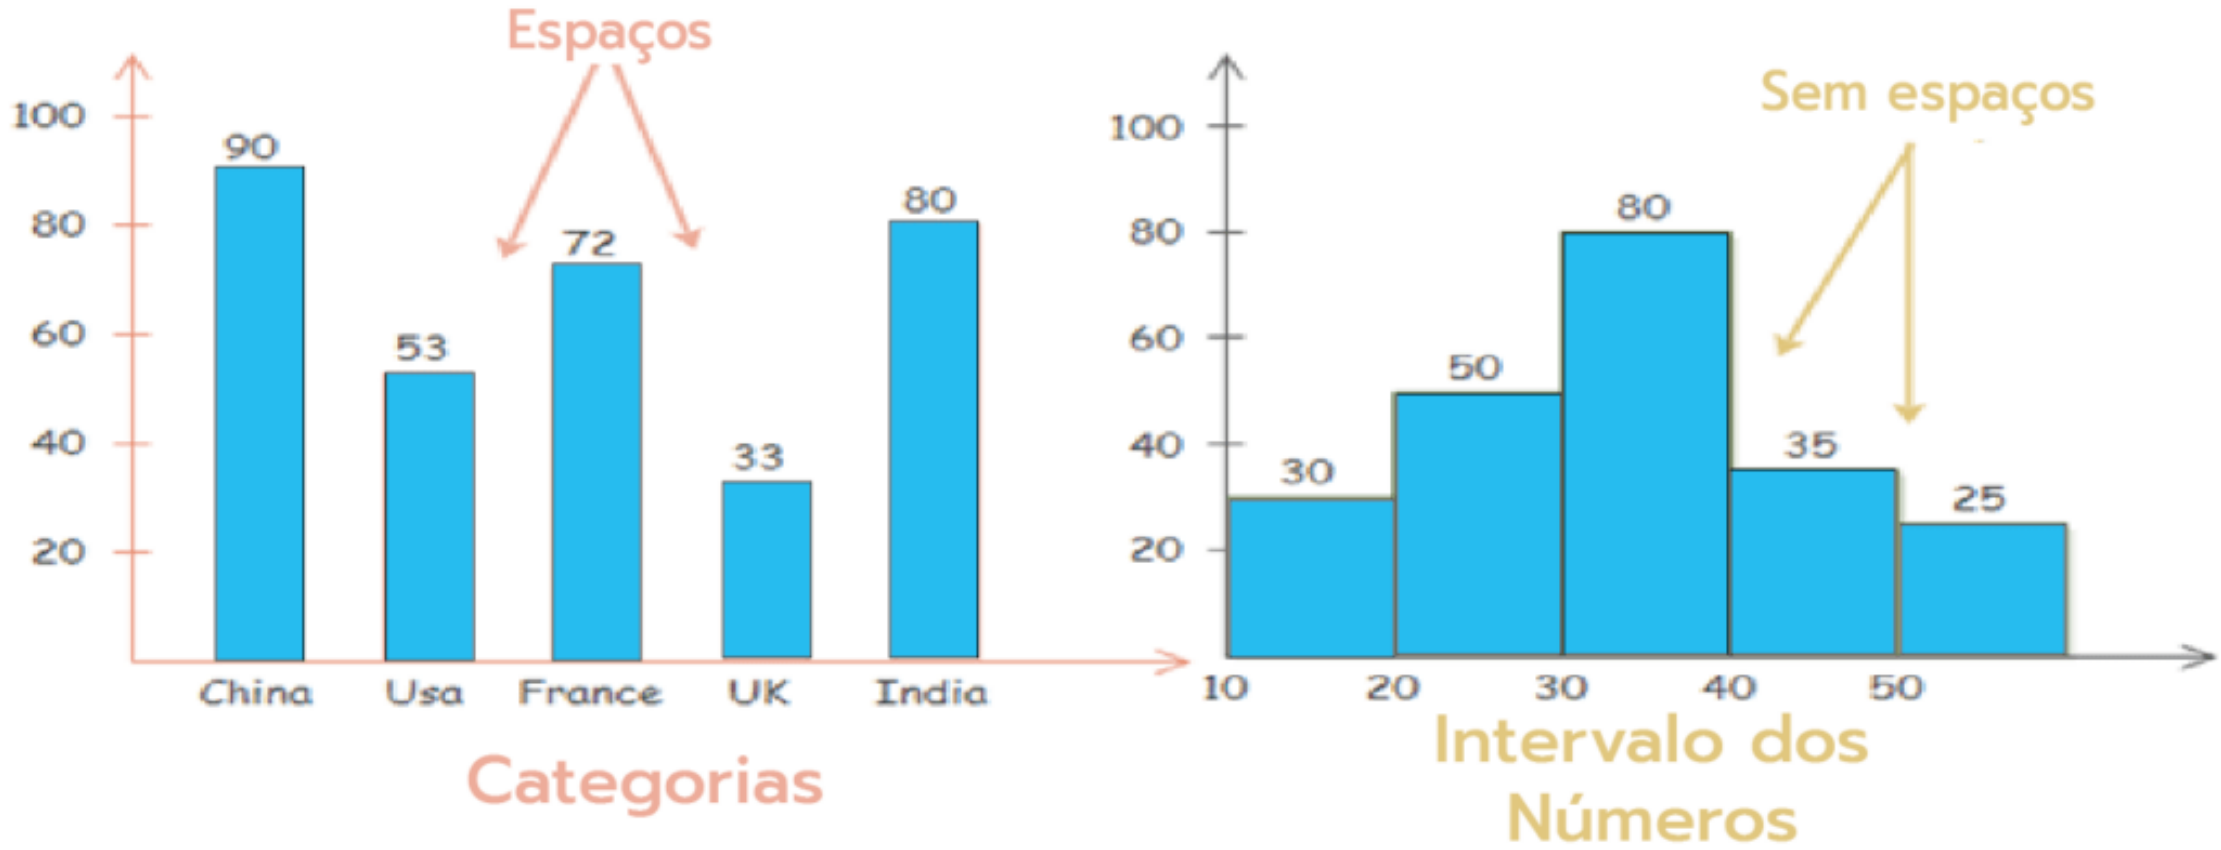

80
70
60
50
40
30
20
10
0
Count
170
180
190
200
210
220
230
flipper_length_mm

# Histograma



# HISTOGRAMA NÃO É GRÁFICO DE BARRAS!

# Gráfico de Barras x Histograma



# Distribuição Normal

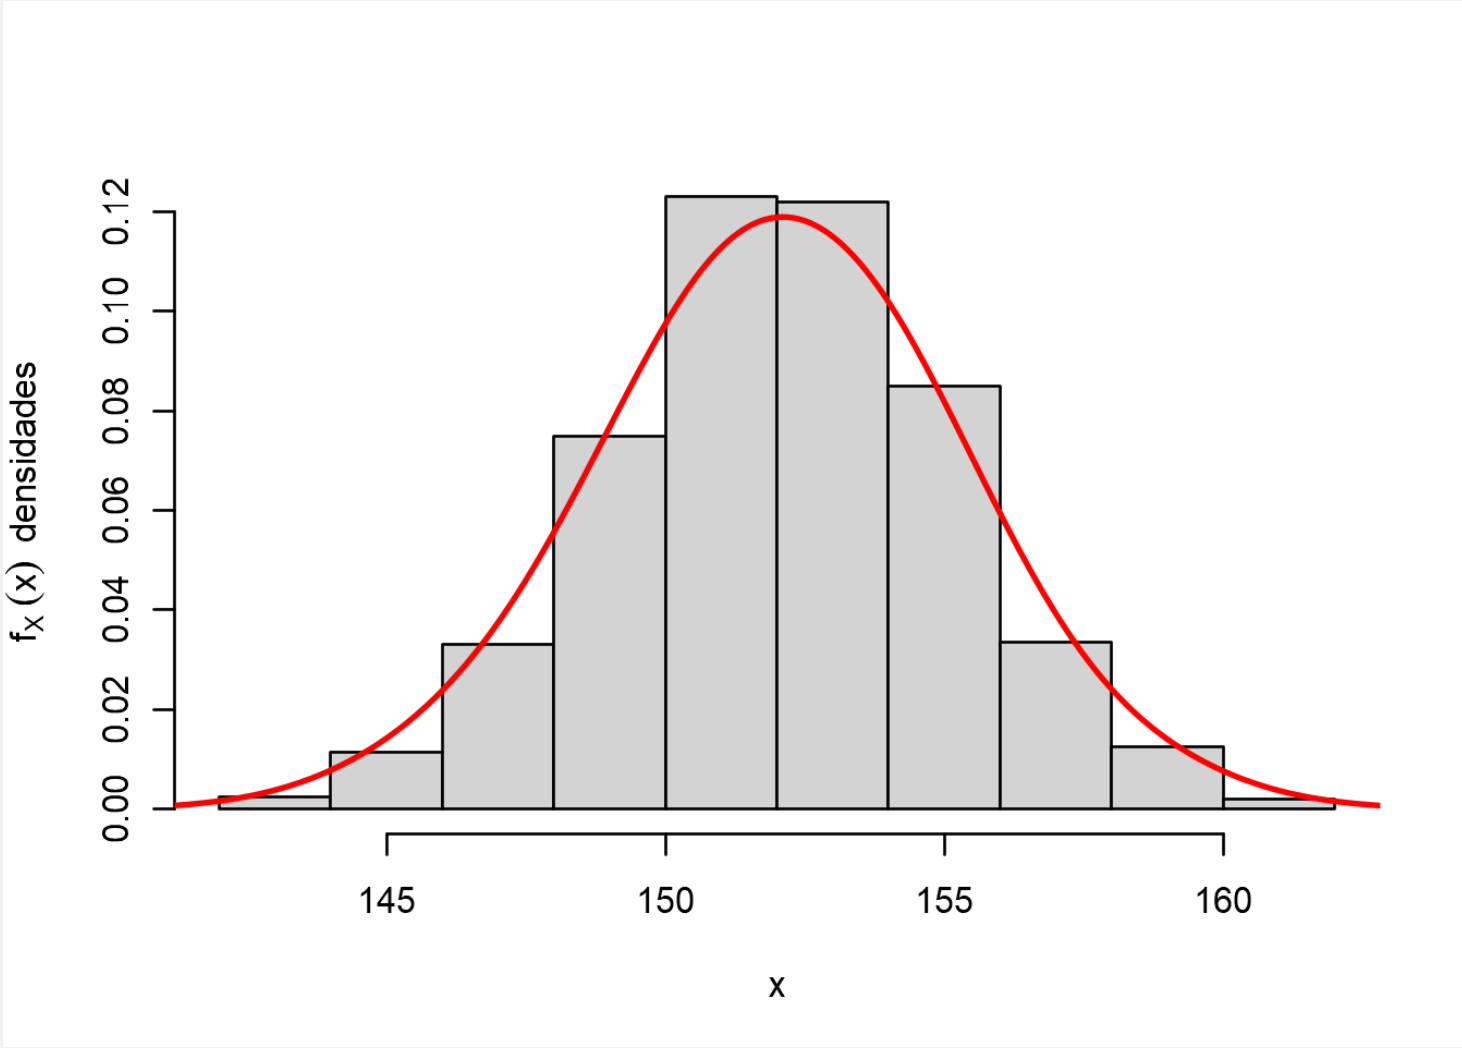
- **O que é:** Uma distribuição de probabilidade simétrica em forma de sino, também conhecida como curva gaussiana

- **Características:**
- A média, mediana e moda coincidem no centro da distribuição
- A área sob a curva representa a probabilidade total (1 ou 100%)
- A maior parte dos dados se concentra em torno da média, com a frequência diminuindo à medida que se afasta da média

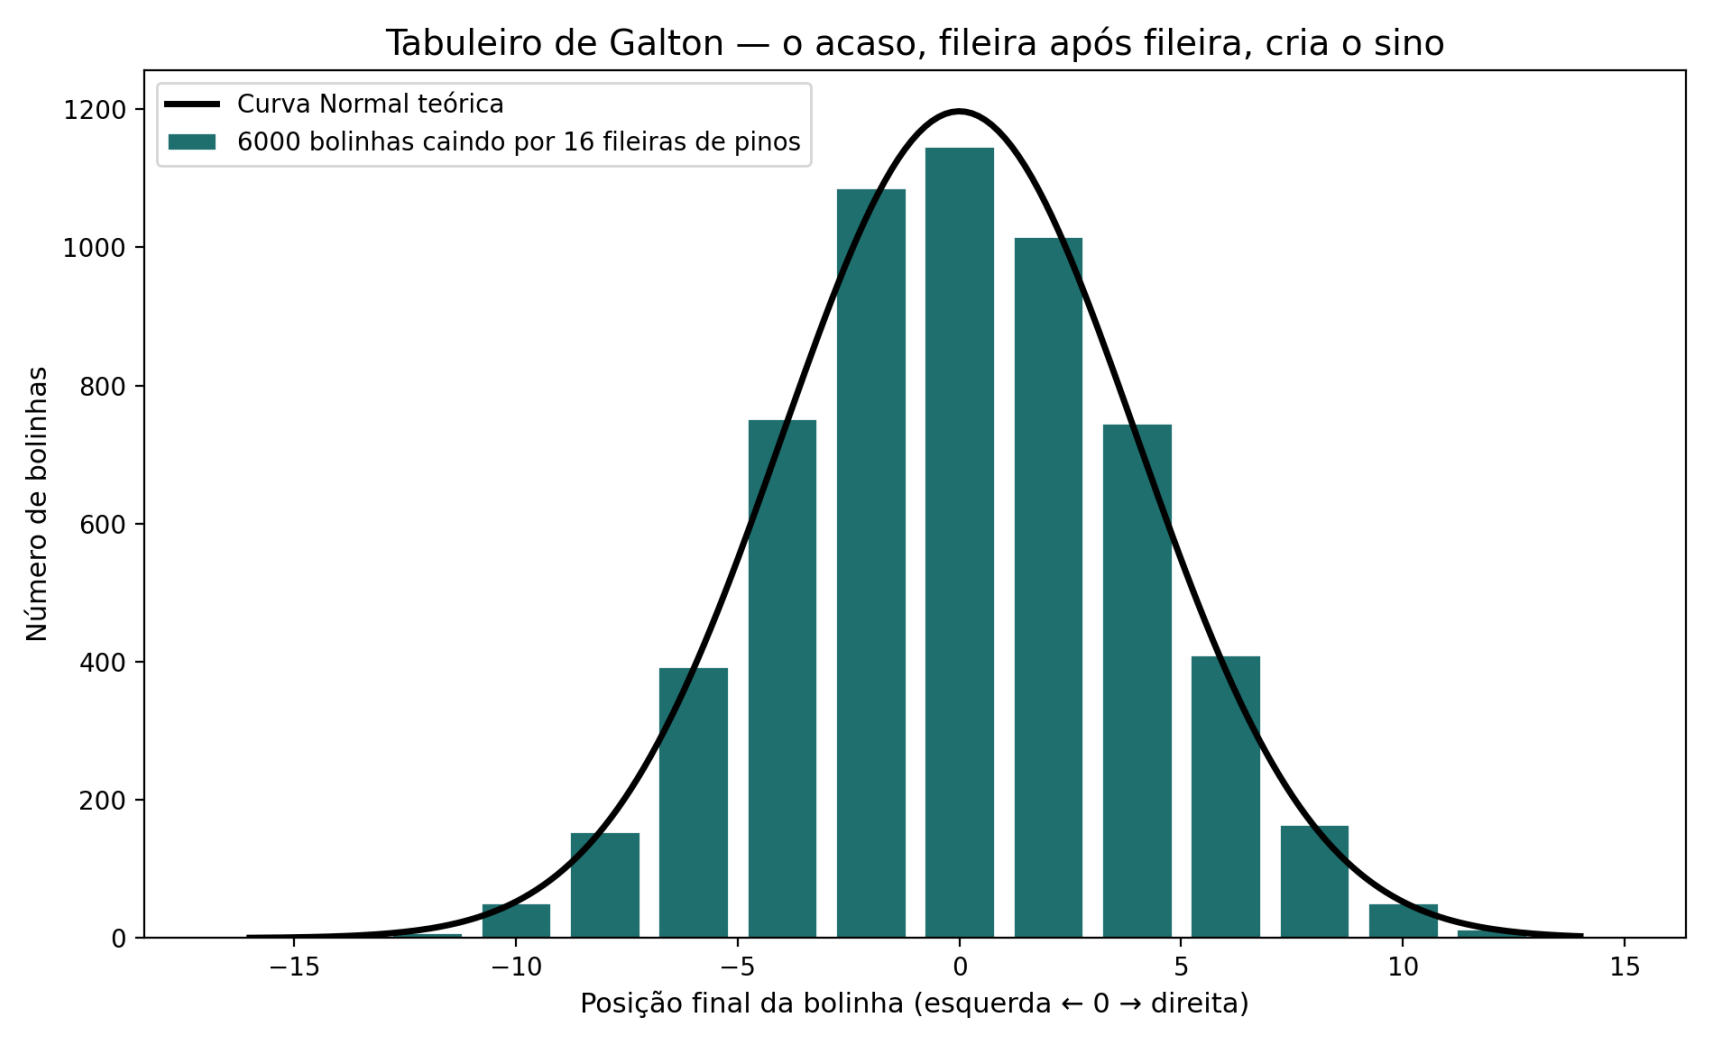
# Distribuição Normal - Importância

- Muitos fenômenos naturais e sociais seguem aproximadamente uma distribuição normal
- É a base de muitos testes estatísticos e modelos de Data Science
- Permite calcular probabilidades e fazer inferências sobre populações a partir de amostras

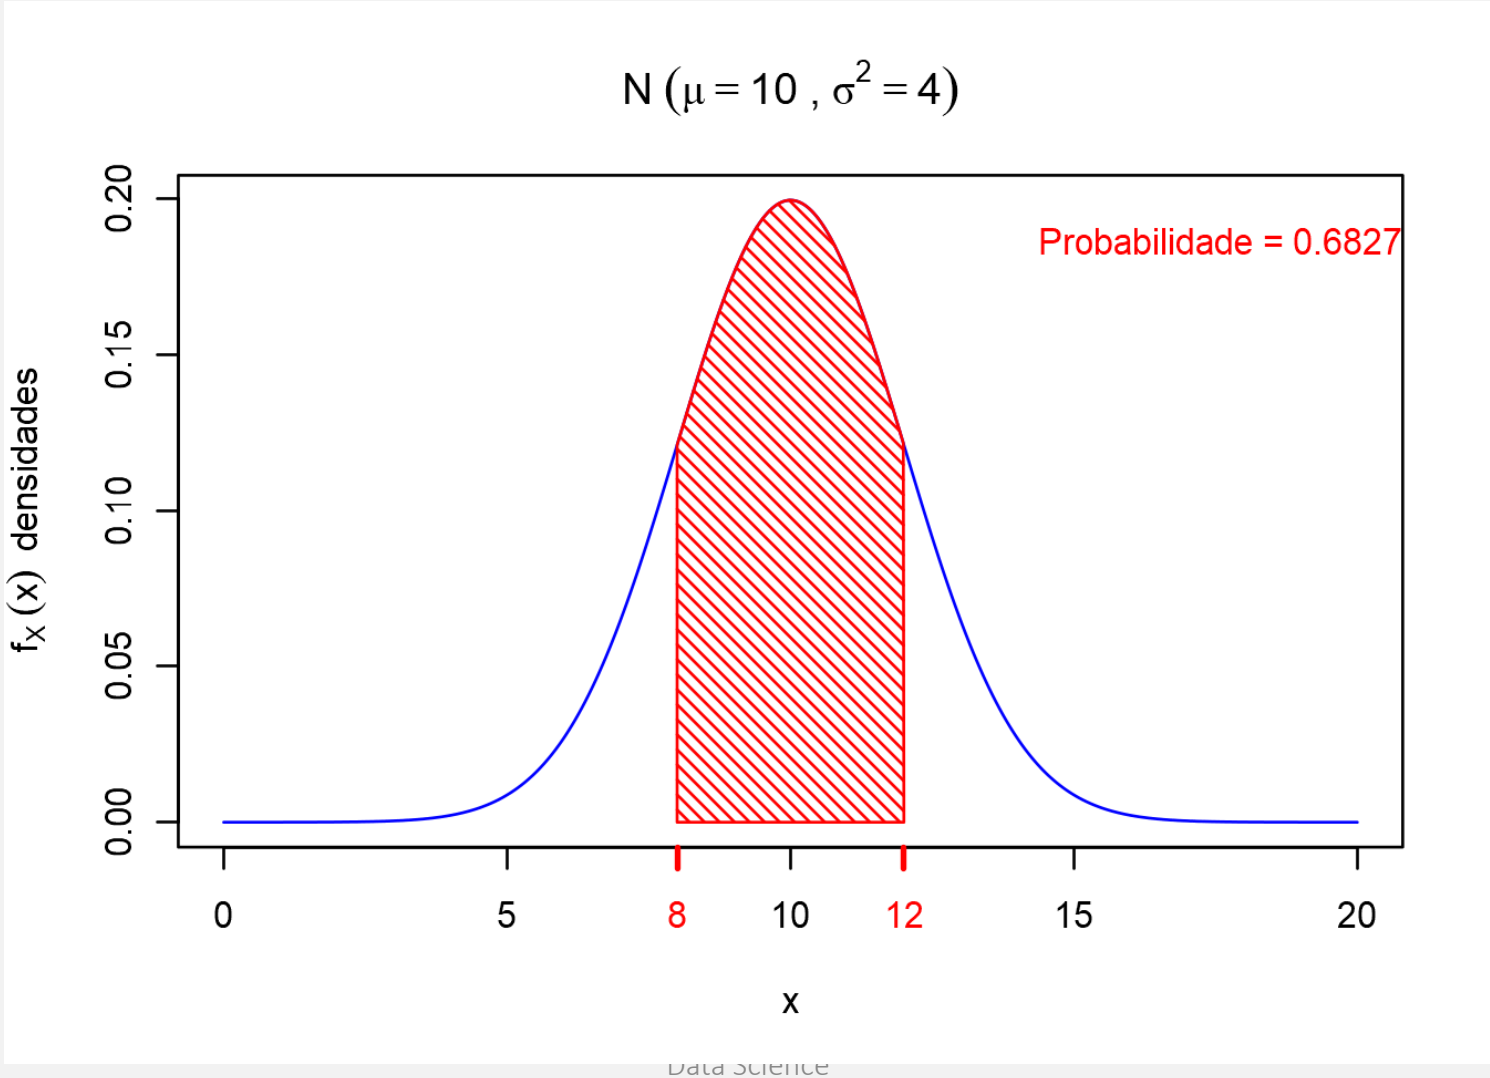
# Distribuição Normal



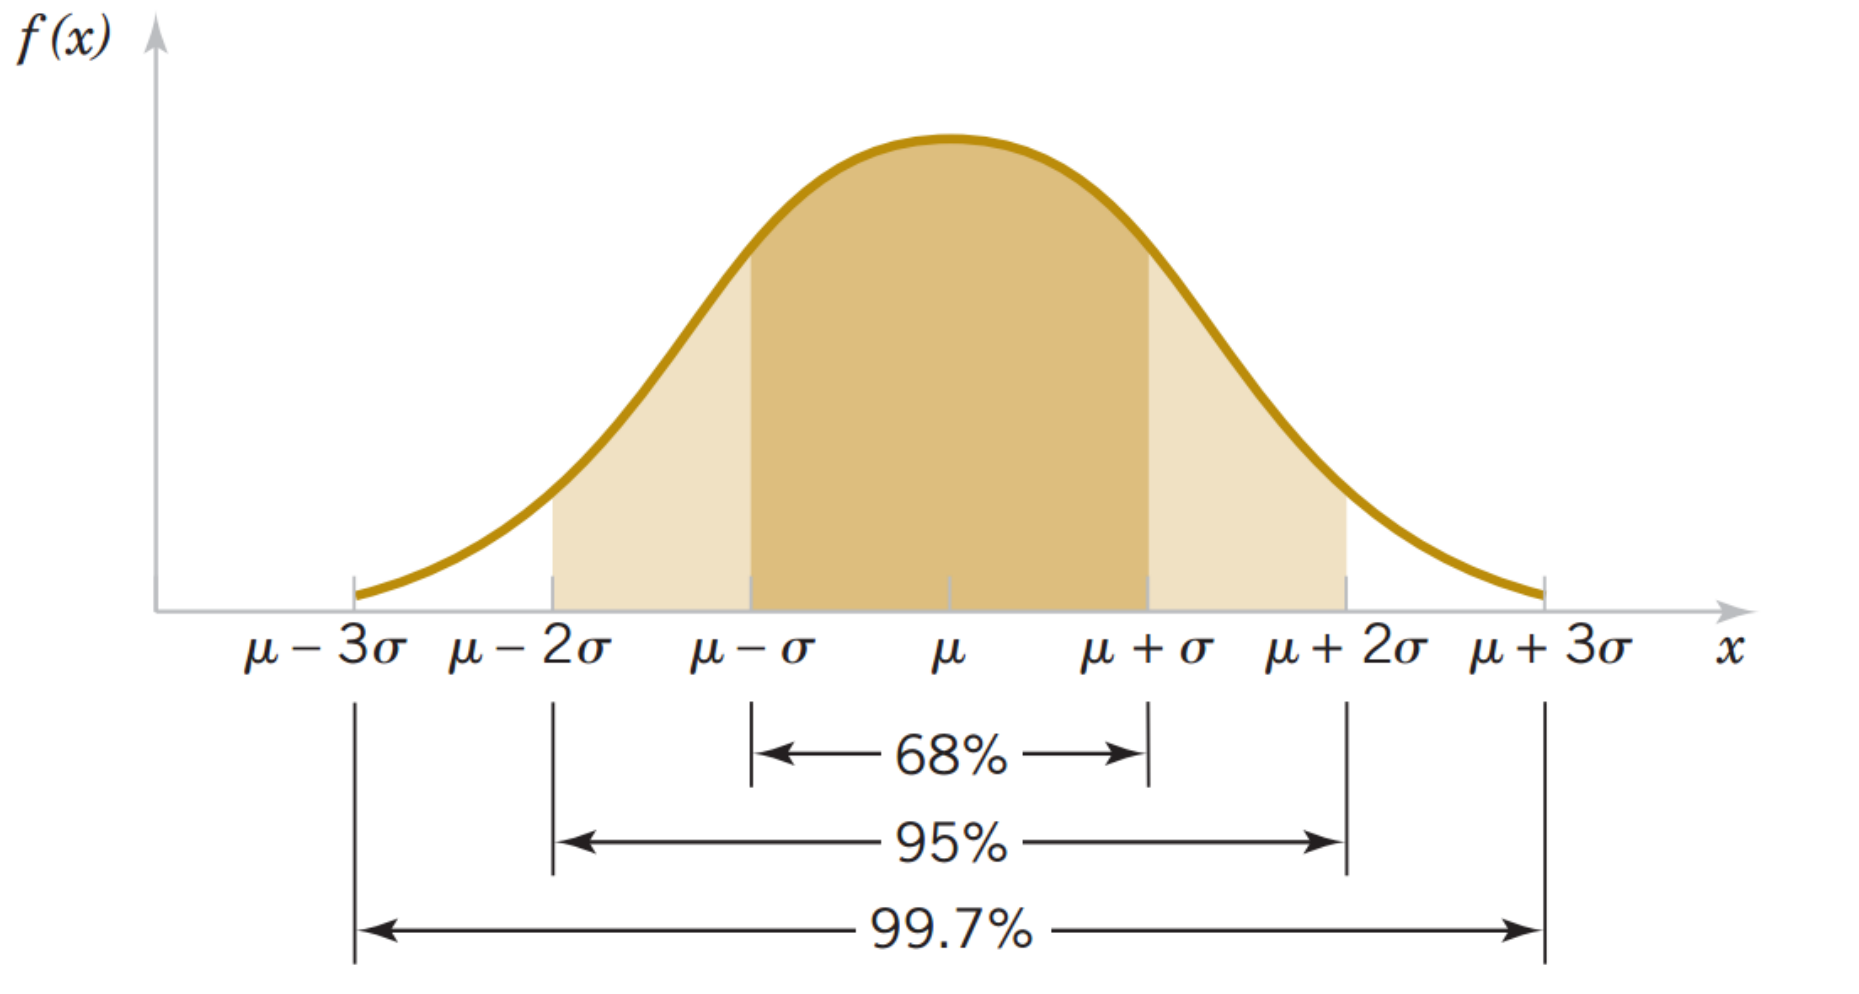
# O Tabuleiro de Galton

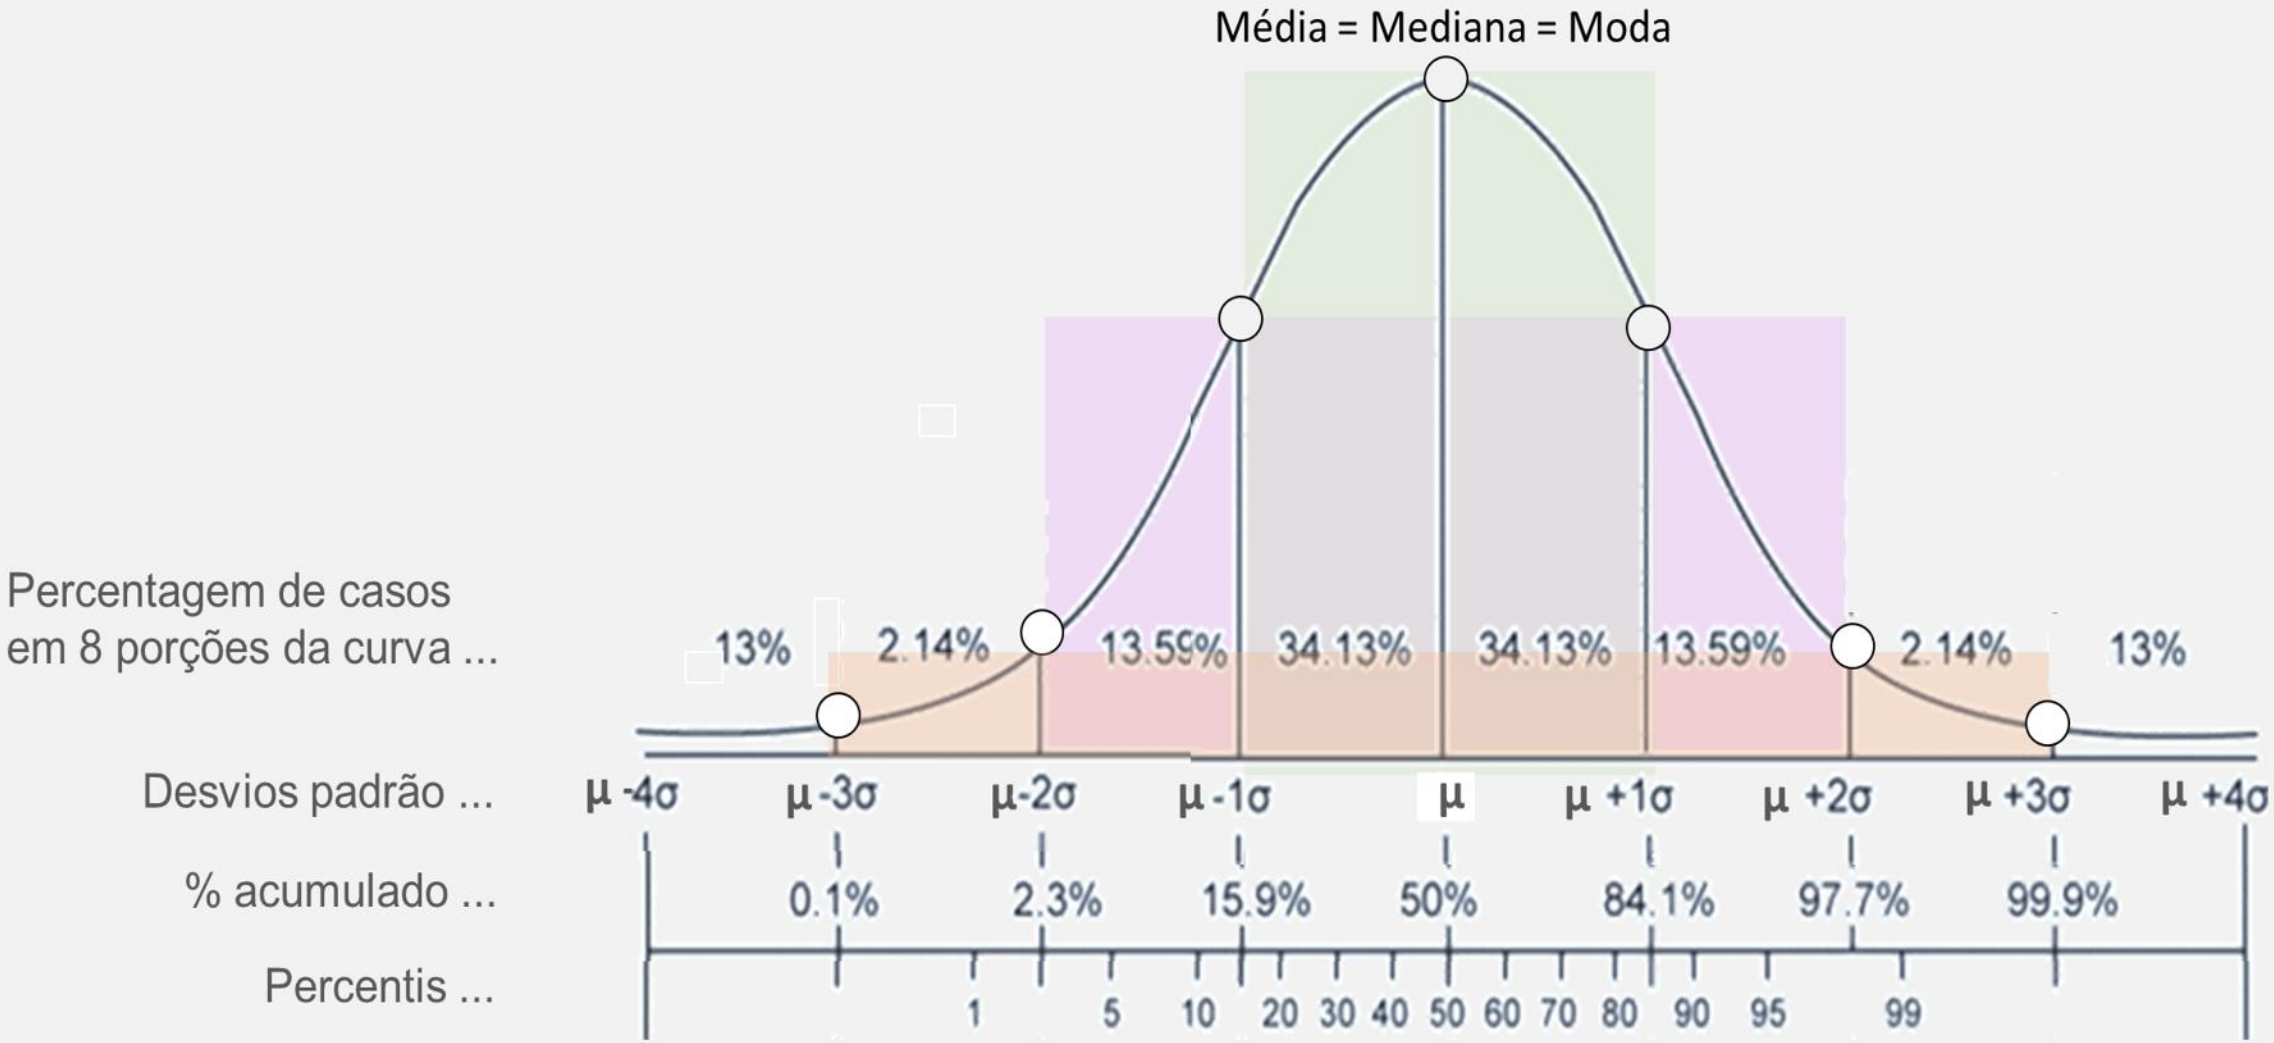


# Distribuição Normal



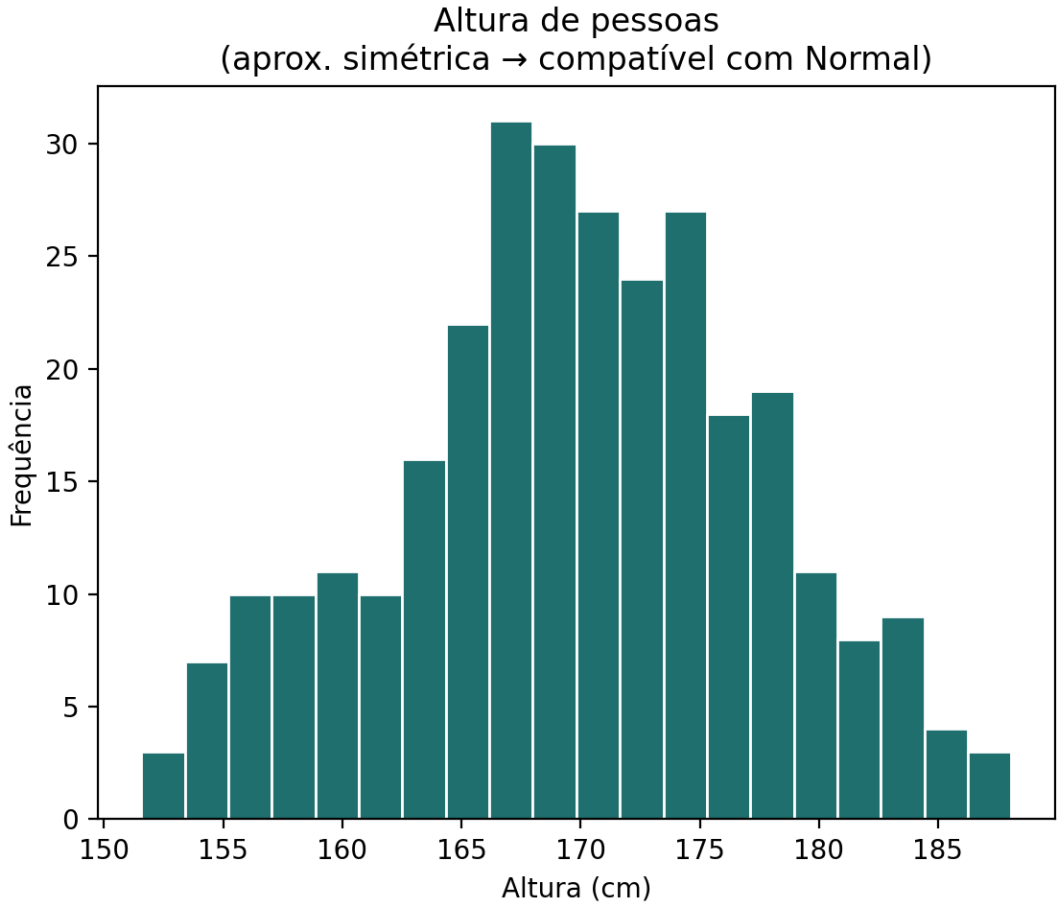
# Distribuição Normal

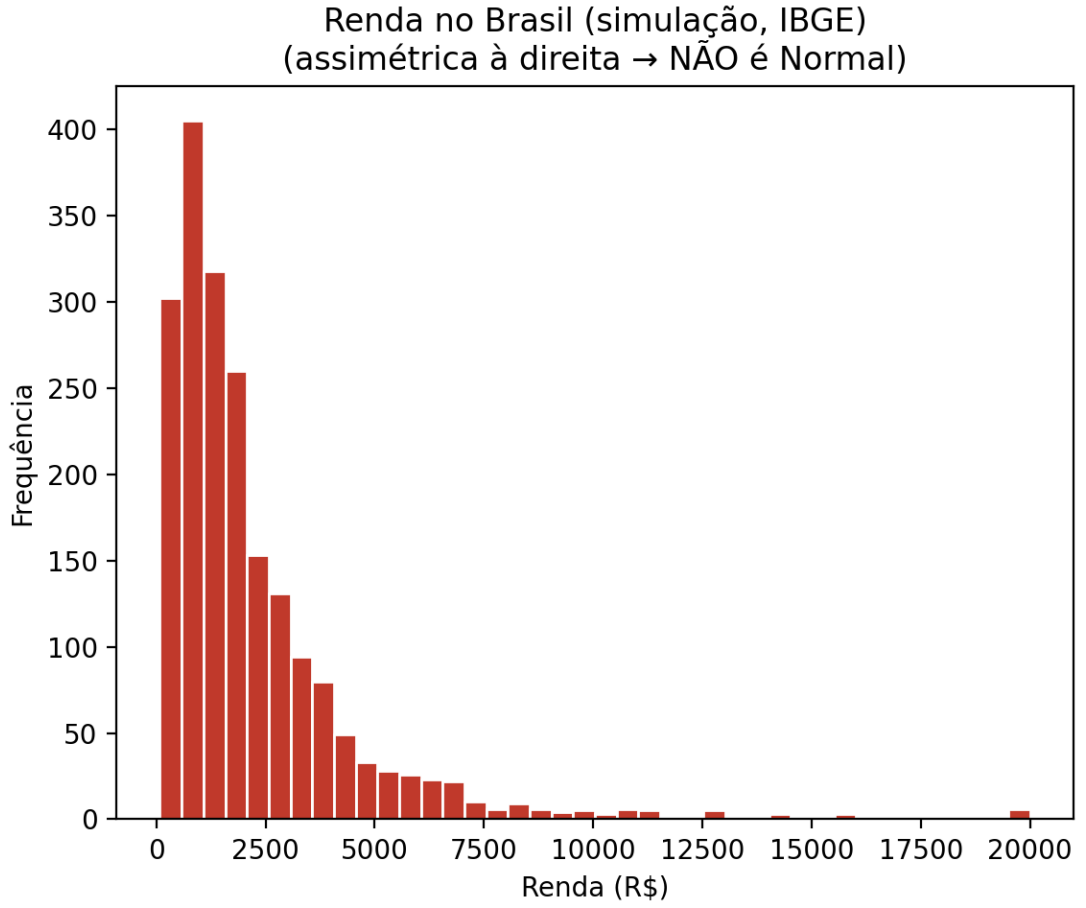





Parâmetros da Curva Normal Padrão de Distribuição de Probabilidade

# Nem Tudo é Normal



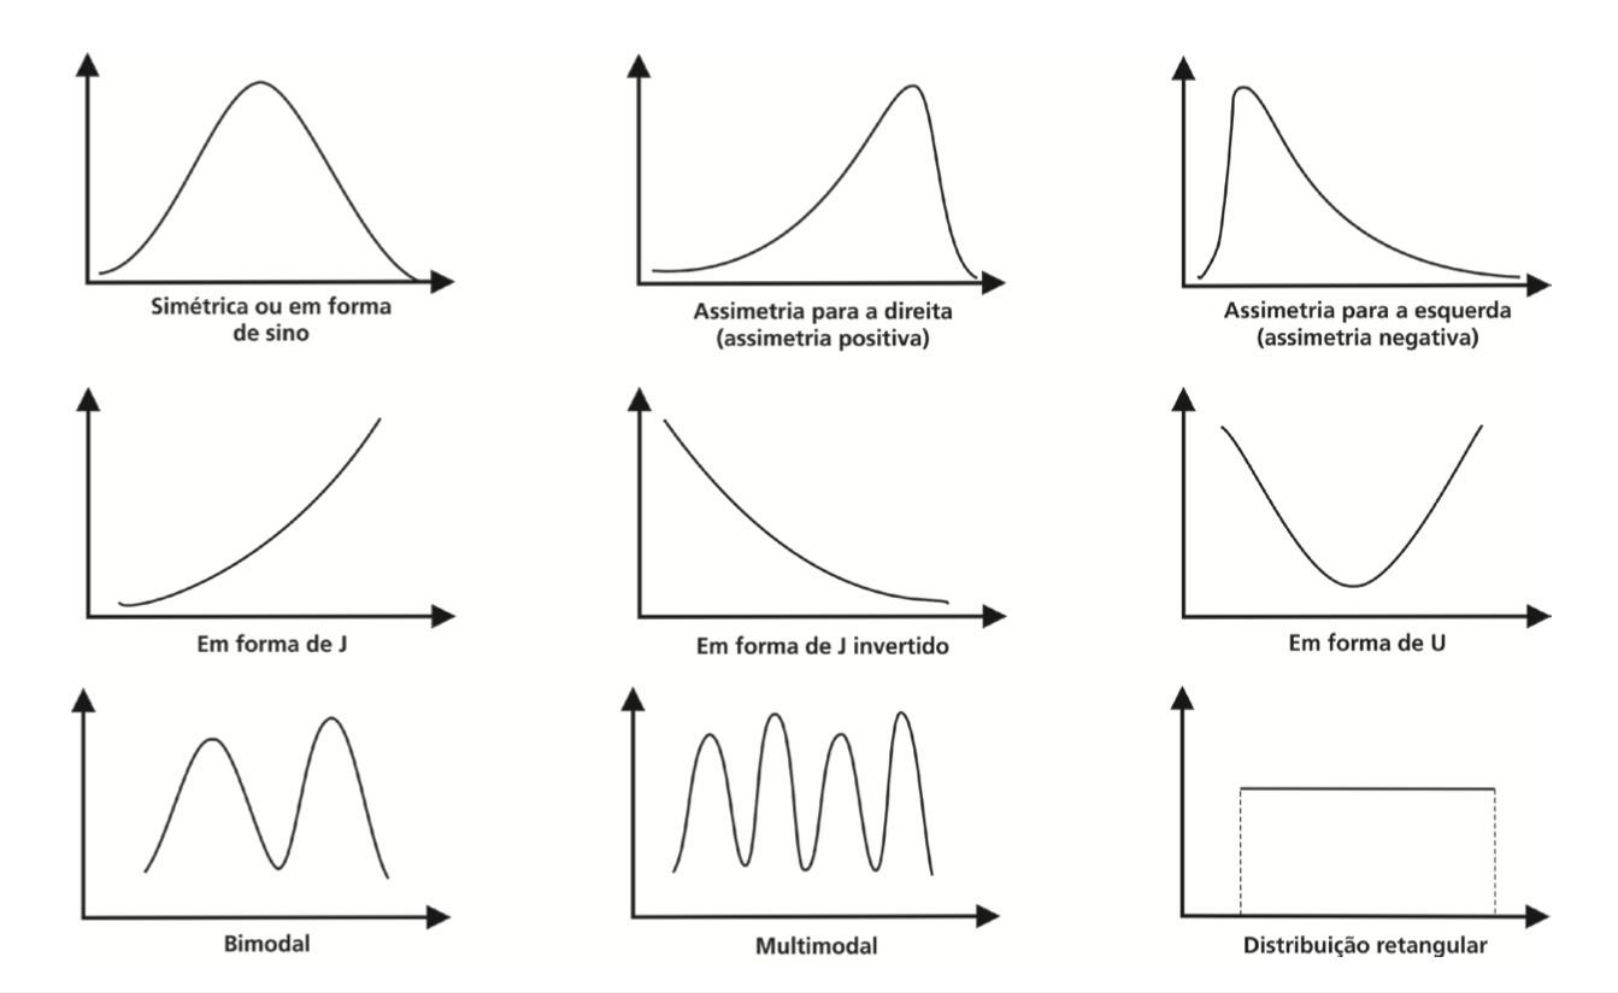



| ID do Aluno | Altura (cm) | Nota da Prova (%) | Número de Livros Lidos (Último Ano) |
|---|---|---|---|
| 1001 | 172 | 78 | 12 |
| 1002 | 165 | 85 | 18 |
| 1003 | 180 | 62 | 5 |
| 1004 | 158 | 91 | 10 |
| 1005 | 170 | 82 | 7 |
| 1006 | 168 | 75 | 15 |
| 1007 | 175 | 58 | 3 |
| 1008 | 155 | 94 | 9 |
| 1009 | 183 | 70 | 8 |
| 1010 | 162 | 88 | 11 |

# Conclusão

- A distribuição de frequências, o histograma e a distribuição normal são ferramentas essenciais para a análise e compreensão de dados em Data Science
- A visualização da distribuição dos dados permite identificar padrões, tendências e outliers
- A compreensão da distribuição normal possibilita a realização de inferências estatísticas e a construção de modelos preditivos

# Distribuições de Frequências



# Distribuições de Frequências

