

Universidade POSITIVO

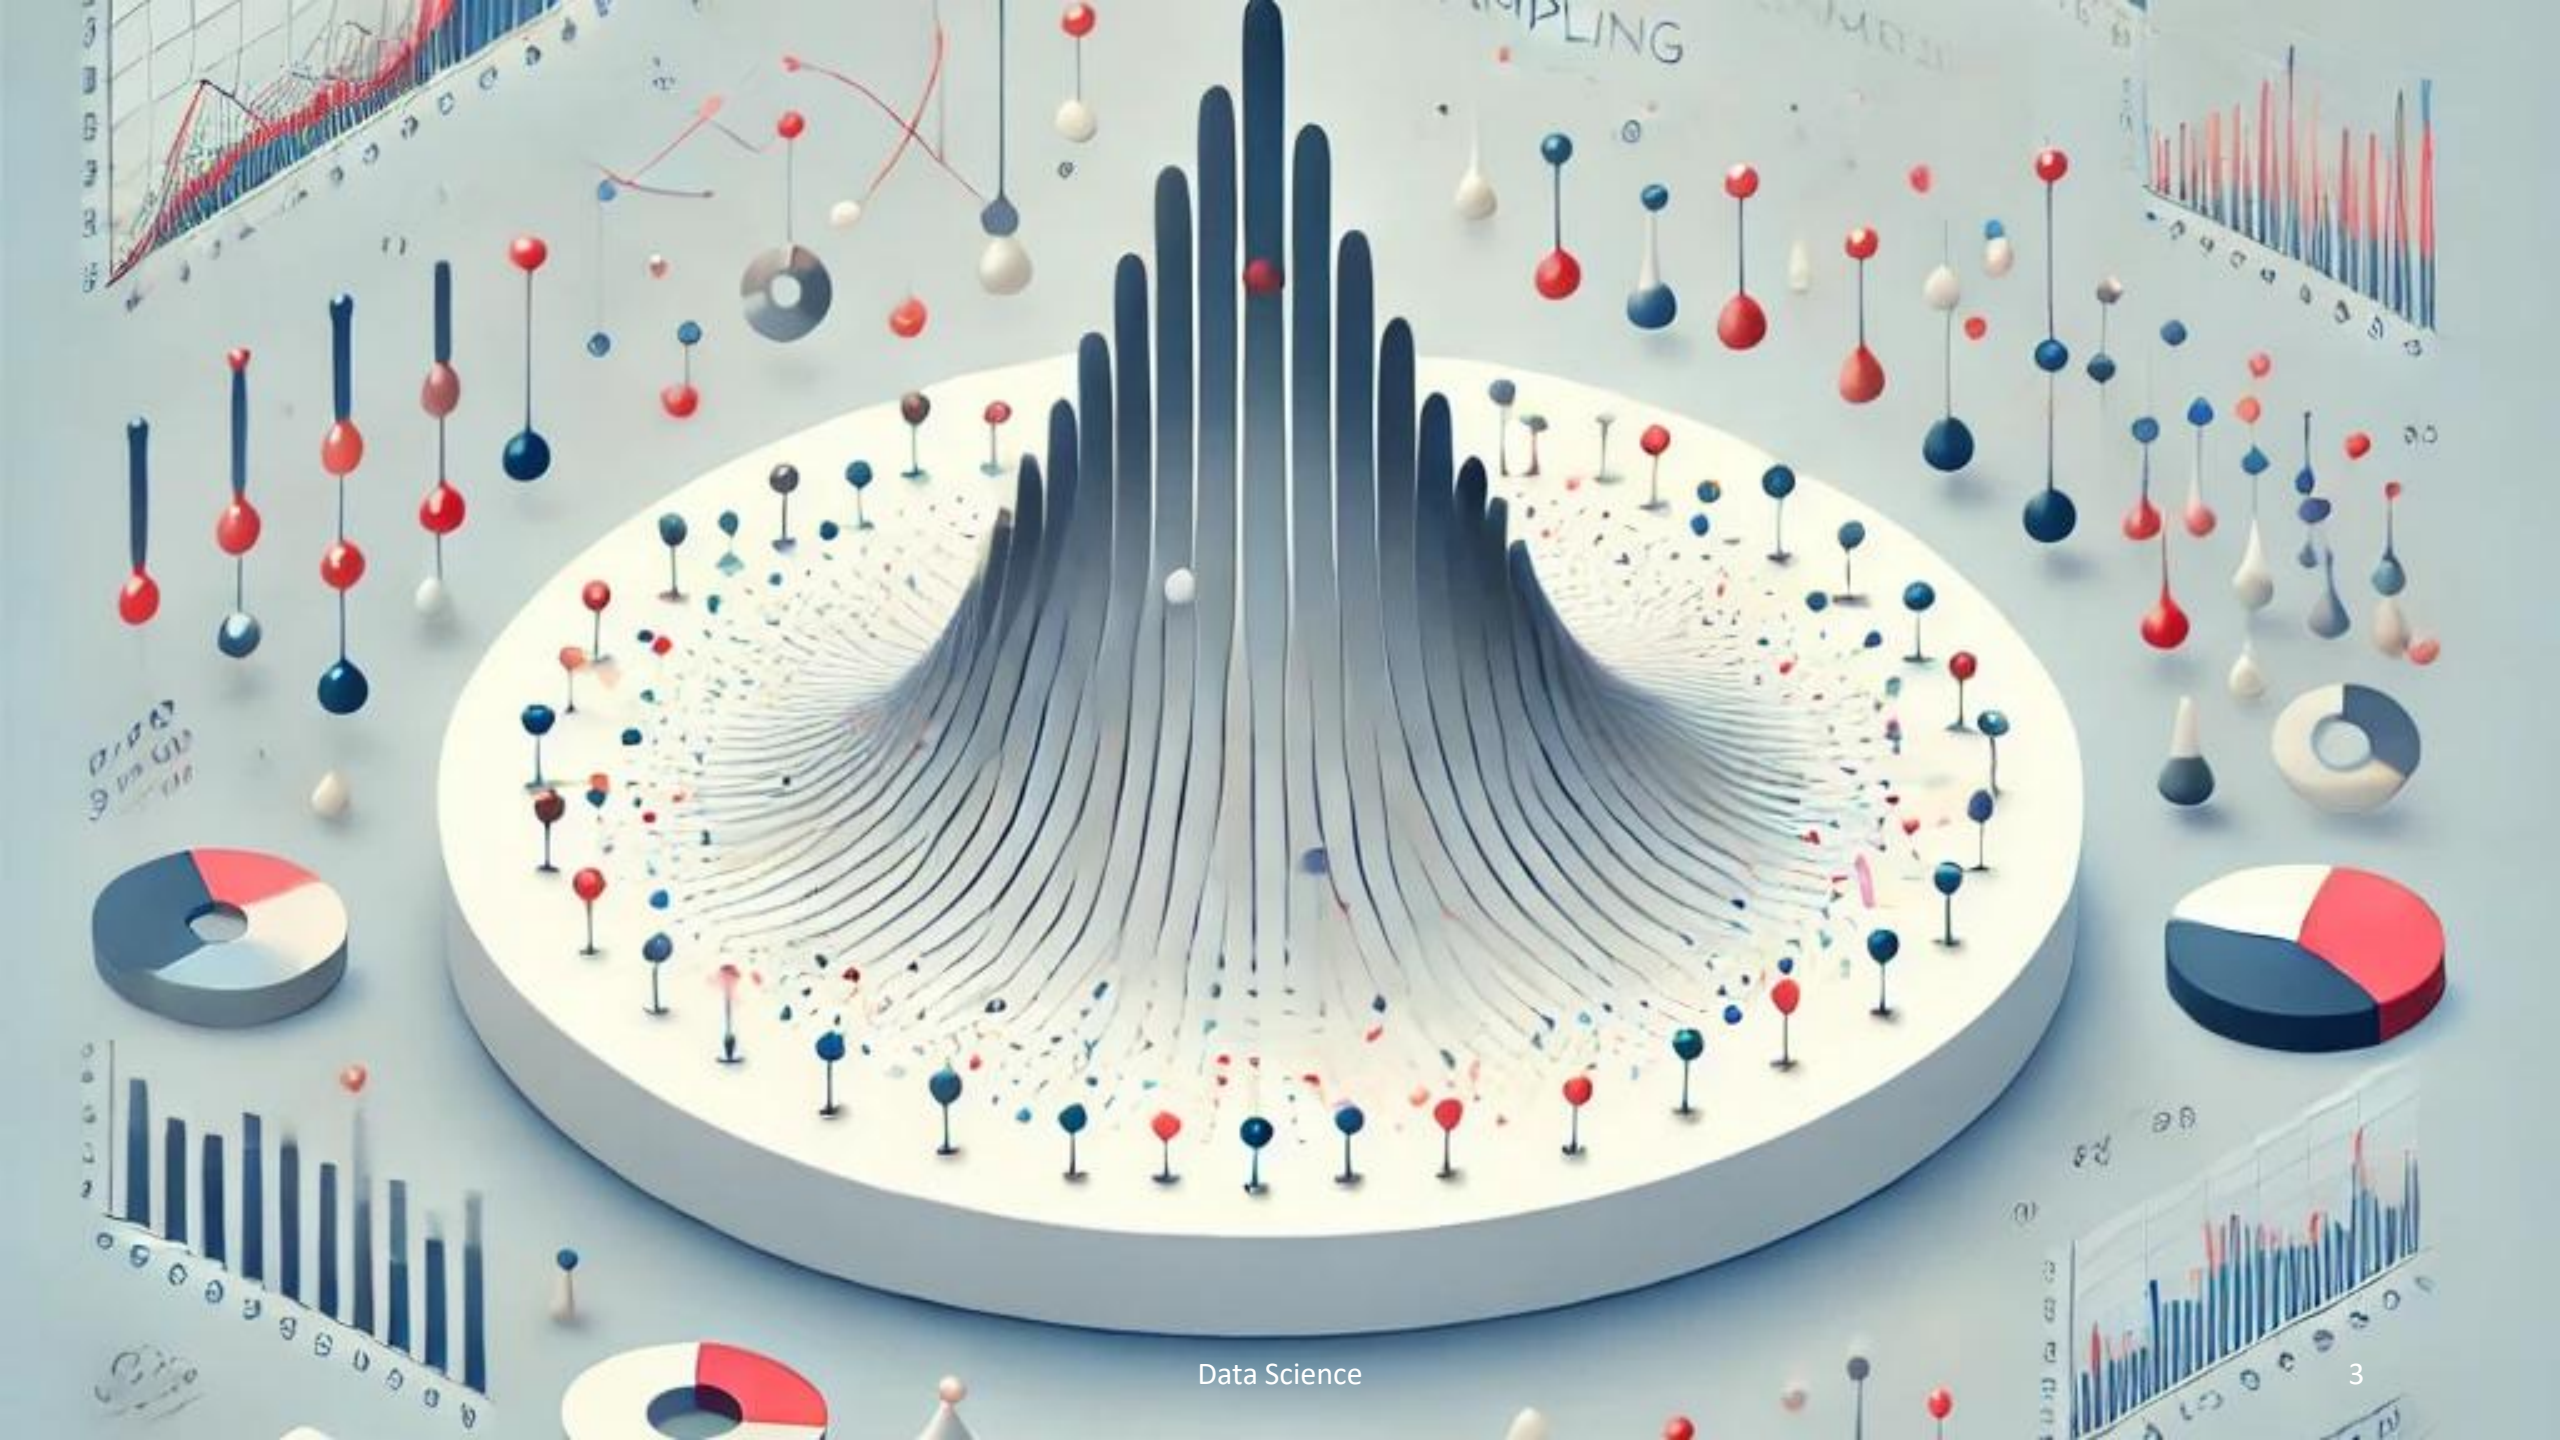
Data Science

Prof.: MSc. Alex Junior Nunes

pfsalexnunes@gmail.com

Data Science

Análise de quartis e Sturges, gráficos de dispersão



Explorando a Distribuição dos Dados

- A análise exploratória de dados (EDA) é uma etapa crucial em qualquer projeto de Data Science.
- É como um "reconhecimento do terreno" antes de aplicar modelos complexos.
- A EDA ajuda a:
  - Entender a natureza dos dados (tipos de variáveis, distribuição, etc.)
  - Identificar padrões, tendências e relações entre variáveis
  - Descobrir outliers e valores ausentes
  - Formular hipóteses e direcionar a análise subsequente
  - Escolher os modelos e técnicas mais adequados para o problema em questão

Ferramentas de Auxílio a EDA

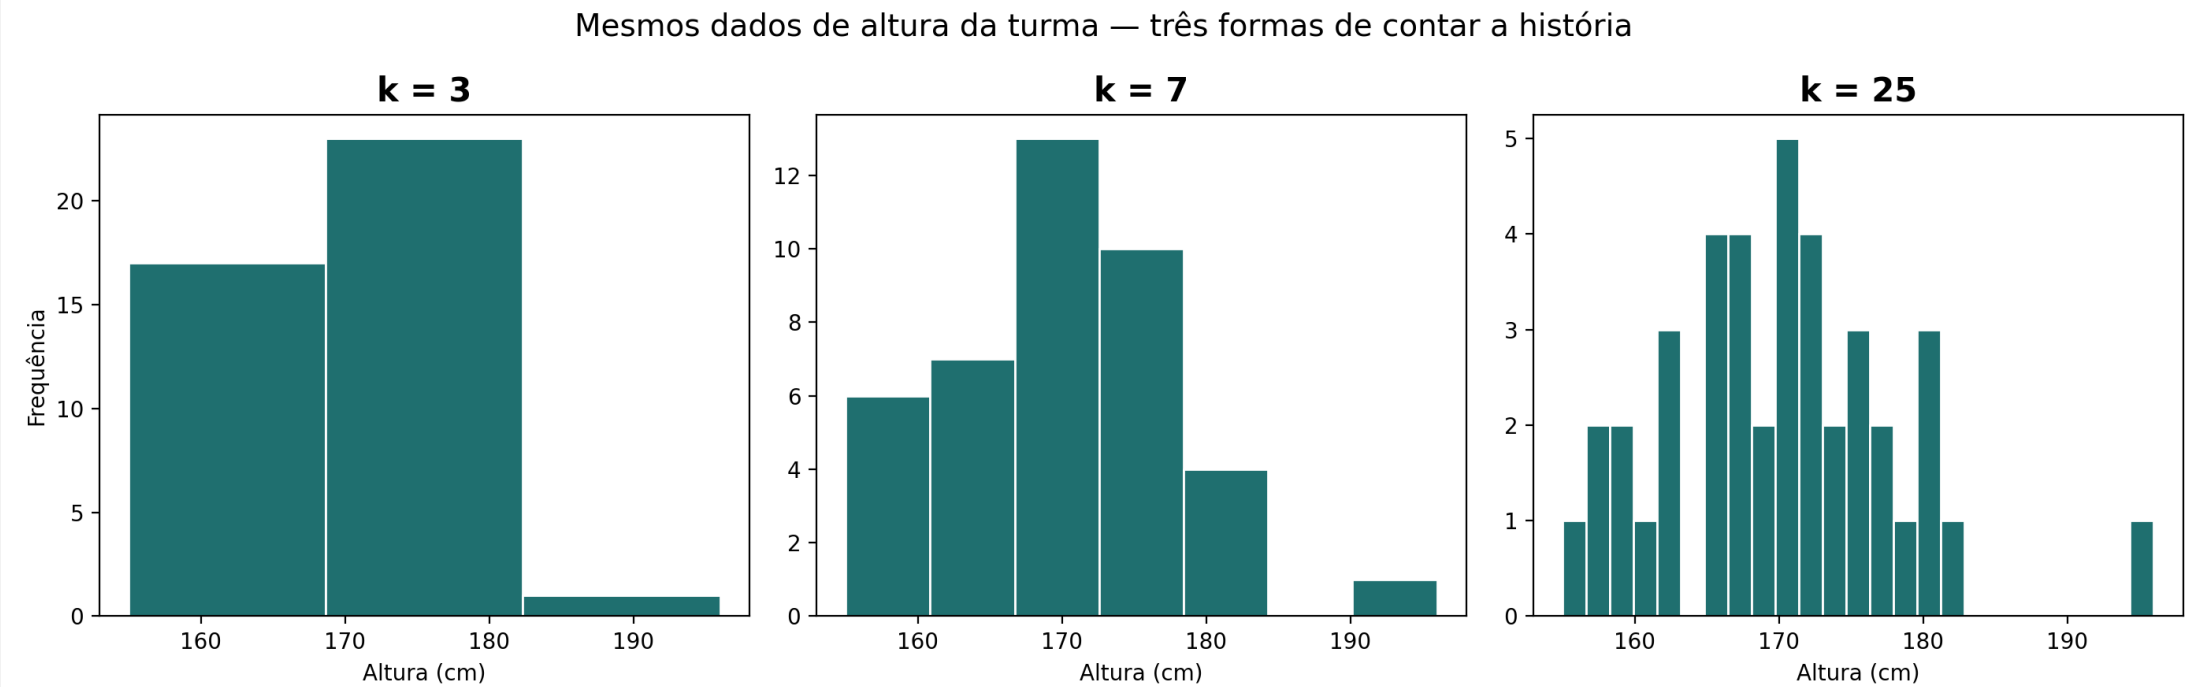
- **Quartis:** Dividem os dados em quatro partes iguais, revelando informações sobre a dispersão e a centralidade dos valores.
- **Regra de Sturges:** Ajuda a determinar o número ideal de classes em um histograma, facilitando a visualização da distribuição dos dados.
- **Gráficos de Dispersão:** Permitem visualizar a relação entre duas variáveis, revelando padrões de correlação e associação.

Regras de Sturge

Encontrando o Número Ideal de Classes

O Problema de Escolher o Número de Classes em um Histograma

- Um histograma é uma ferramenta poderosa para visualizar a distribuição de dados numéricos, mas a escolha do número de classes (ou barras) pode afetar significativamente a interpretação do gráfico.
- Um número muito pequeno de classes pode agrupar dados excessivamente, perdendo detalhes importantes, enquanto um número muito grande pode resultar em barras muito finas e difíceis de interpretar.


Mesmos dados de altura da turma — três formas de contar a história
k = 3
k = 7
k = 25
Frequência
Altura (cm)
Altura (cm)
Altura (cm)

A Fórmula de Sturges

- Uma solução prática para esse problema:

- **`k = 1 + 3.322 * log(n),`** onde:

- k é o número recomendado de classes
- n é o número total de observações no conjunto de dados

- A fórmula é baseada em princípios estatísticos e fornece uma estimativa razoável para o número de classes na maioria dos casos.

A Fórmula de Sturges

- Vantagens da regra de Sturges:
  - Simplicidade e facilidade de uso
  - Fornece um bom ponto de partida para a escolha do número de classes
  - Evita a subjetividade na decisão
- Limitações:
  - É uma regra empírica e pode não ser a melhor opção em todos os casos
  - Pode não funcionar bem para distribuições de dados muito assimétricas ou com outliers
  - O julgamento e a interpretação do analista ainda são importantes.



Quartis

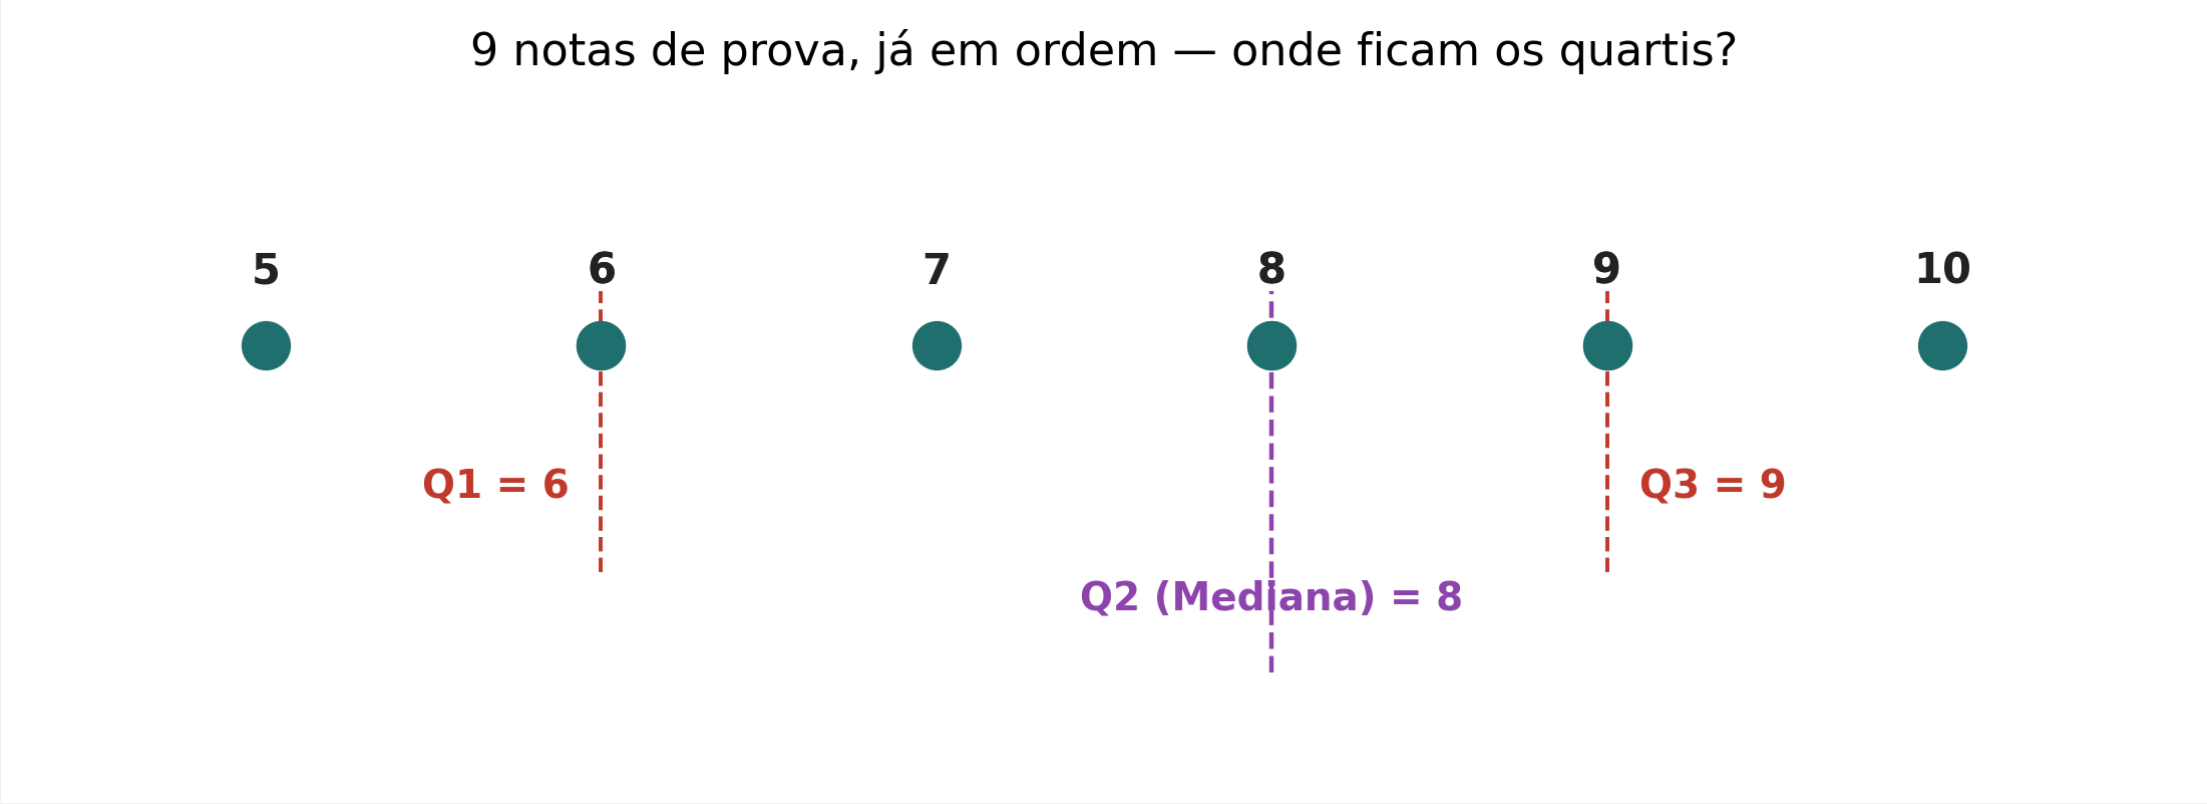
Dividindo e Conquistando

Definição de Quartis

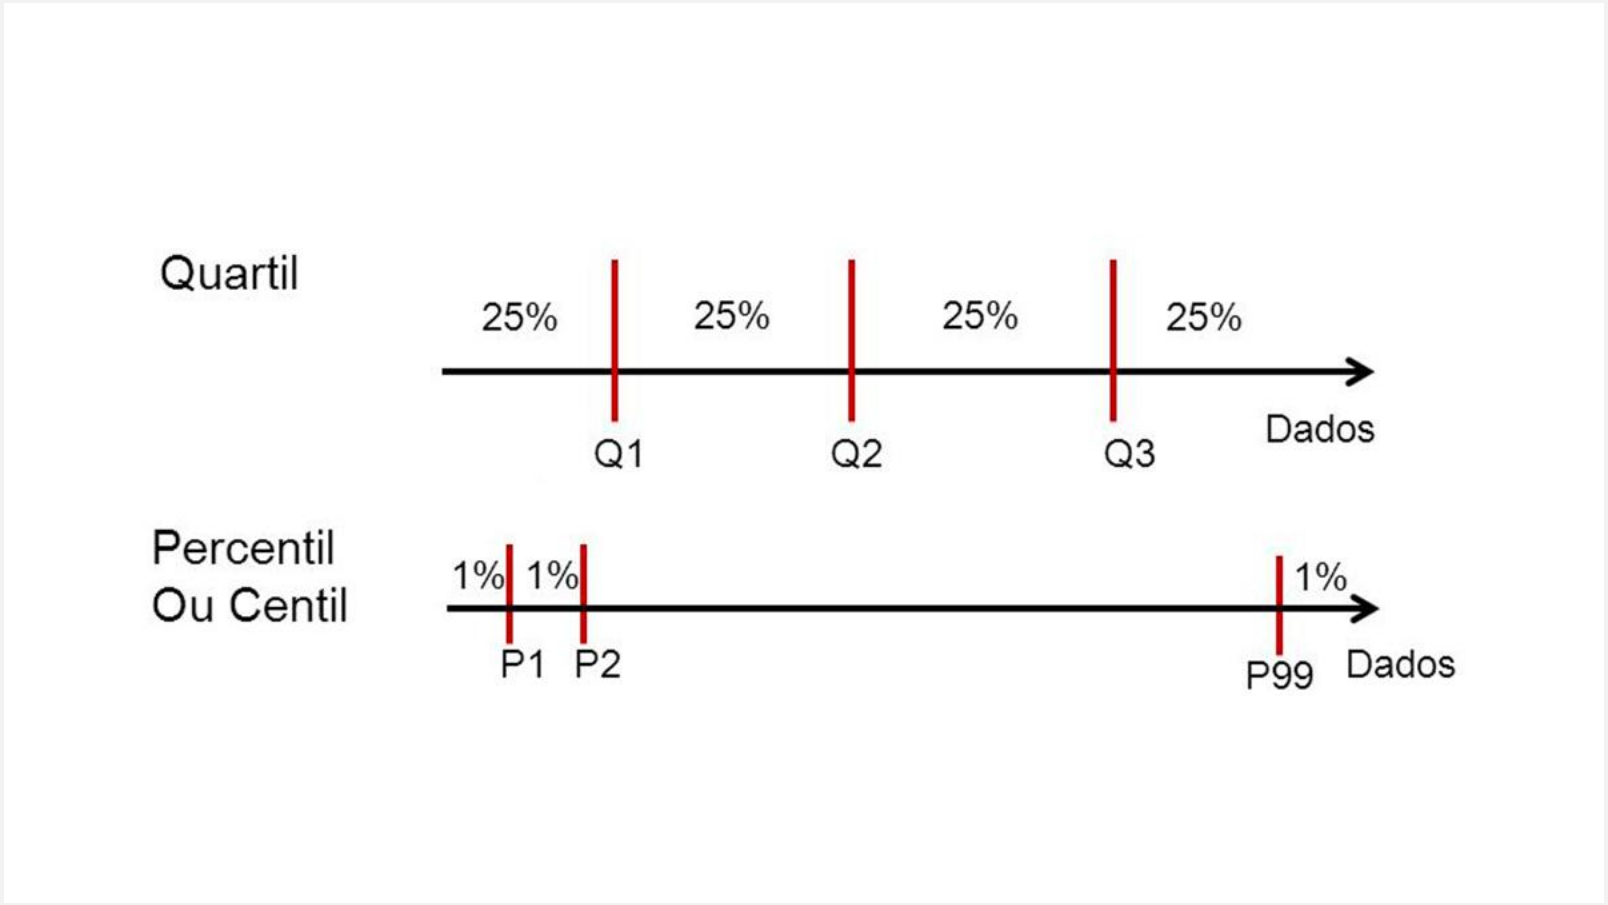
- Os quartis são valores que dividem um conjunto de dados ordenados em quatro partes iguais.

- Os três quartis principais são:
- **Q1 (Primeiro Quartil):** 25% dos dados estão abaixo deste valor.
- **Q2 (Segundo Quartil ou Mediana):** 50% dos dados estão abaixo deste valor.
- **Q3 (Terceiro Quartil):** 75% dos dados estão abaixo deste valor.

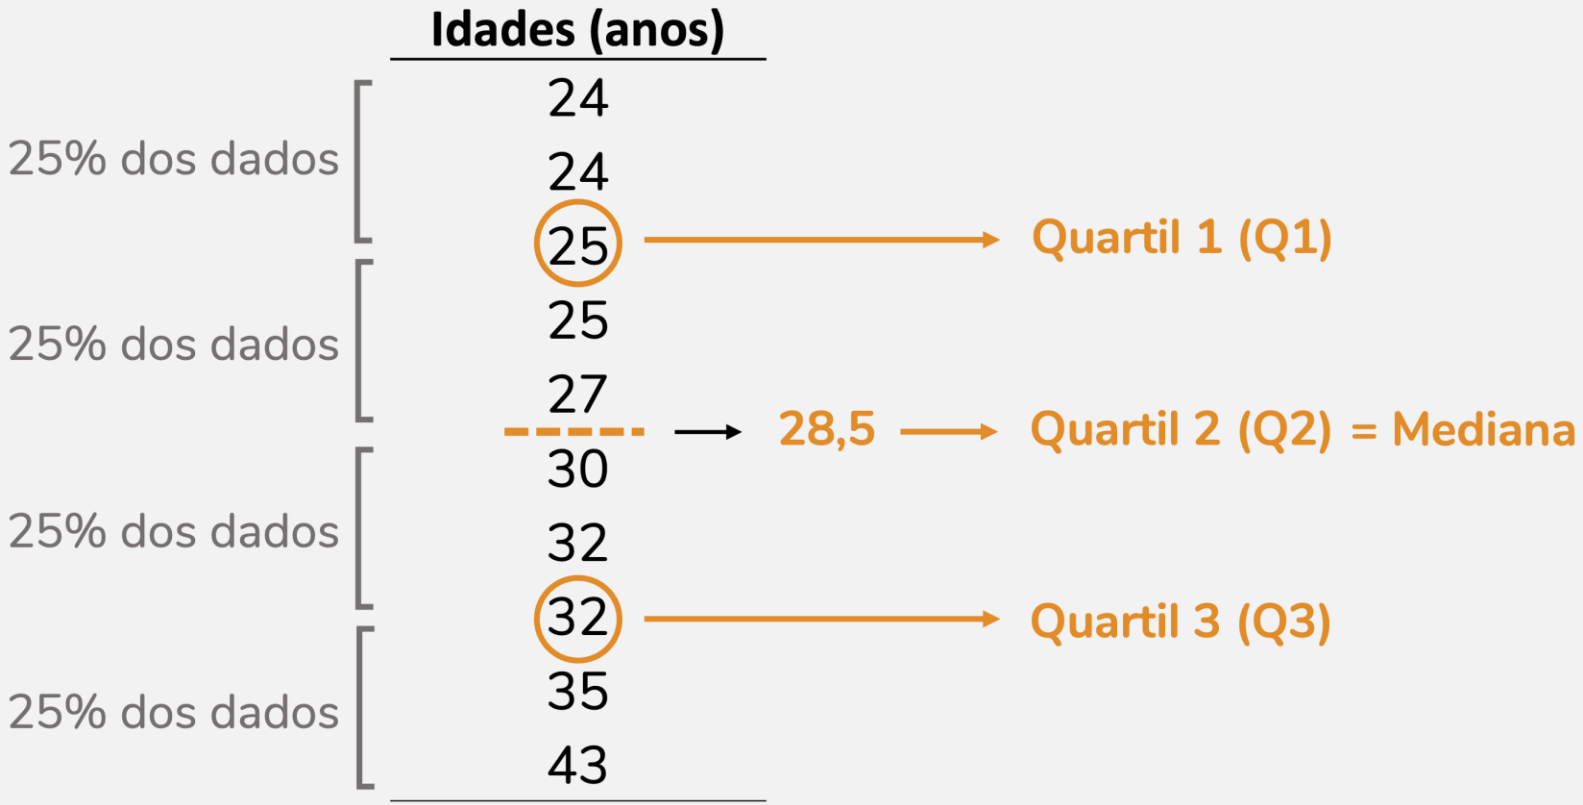
Quartis na Prática: um Exemplo Rápido



Quartis na Prática: um Exemplo Rápido



Quartis na Prática: um Exemplo Rápido



Interpretação dos Quartis

- Os quartis nos ajudam a entender a distribuição dos dados, mostrando onde a maior parte dos valores se concentra e como eles se espalham.
- A diferença entre Q3 e Q1 (chamada de intervalo interquartil ou IQR) é uma medida importante da dispersão dos dados, indicando o quão espalhados estão os 50% centrais dos valores.

Importância dos Quartis para Identificar Outliers e Entender a Dispersão

- Os quartis são úteis para identificar outliers, ou seja, valores que se distanciam muito do restante dos dados.
- Defina outliers como valores que estão abaixo de Q1 - 1.5 * IQR ou acima de Q3 + 1.5 * IQR.
- Os quartis podem ser usados para comparar a dispersão de diferentes conjuntos de dados.

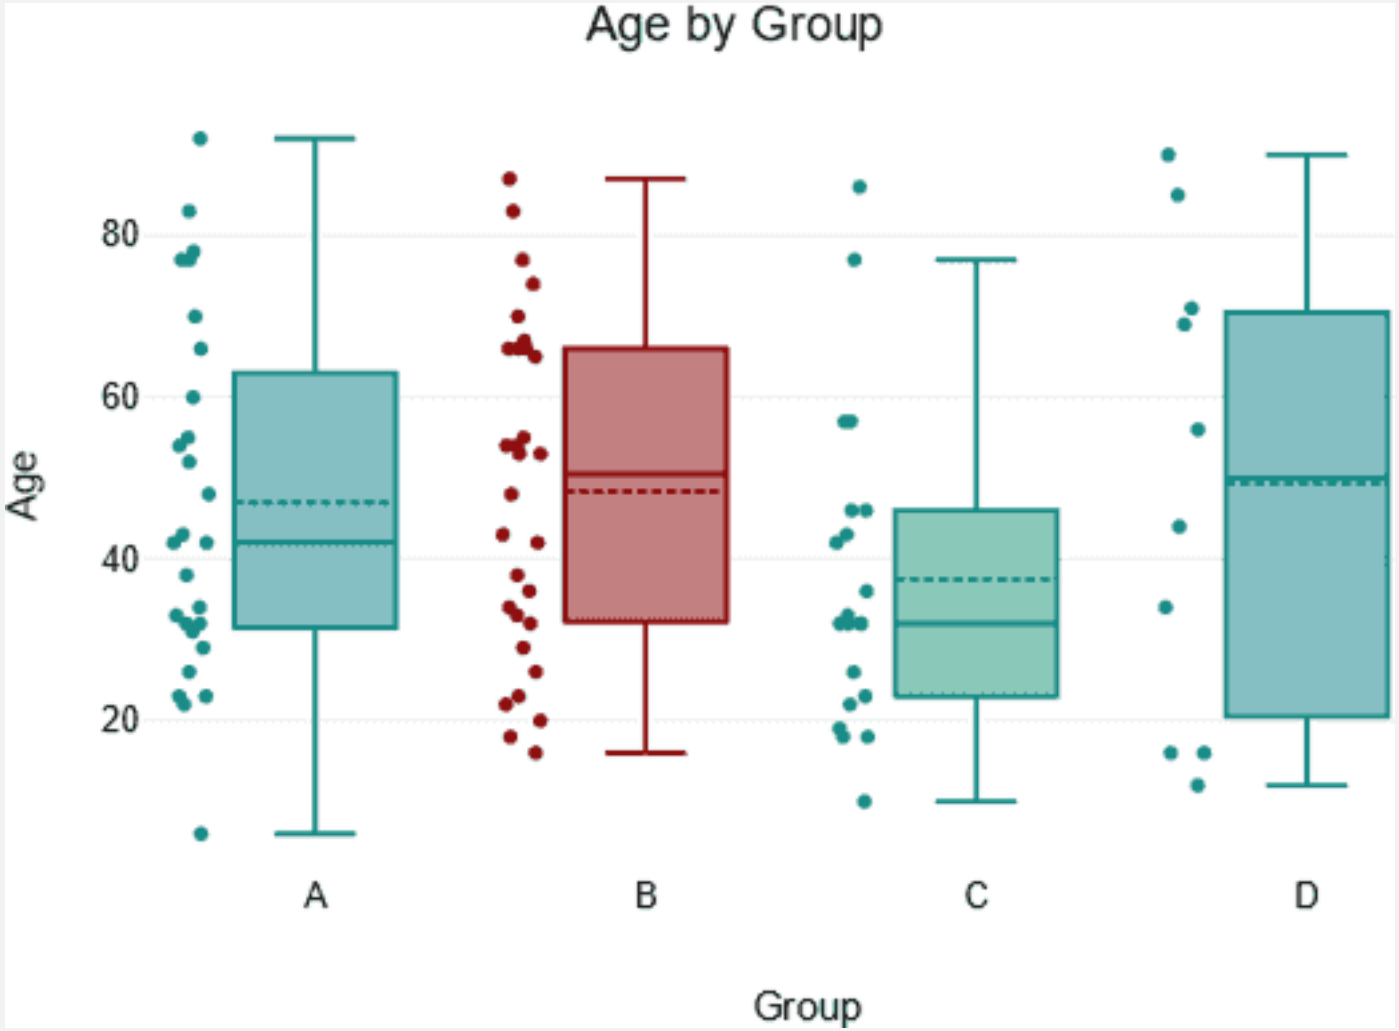
Boxplot

Visualizando a Distribuição dos Dados

Boxplot

- Também traduzido como diagrama de caixa
- Um gráfico que representa a distribuição de um conjunto de dados numéricos através de quartis.
- Mostra visualmente a mediana, os quartis, a amplitude interquartil e possíveis outliers.
- Permite comparar facilmente a distribuição de diferentes grupos de dados.

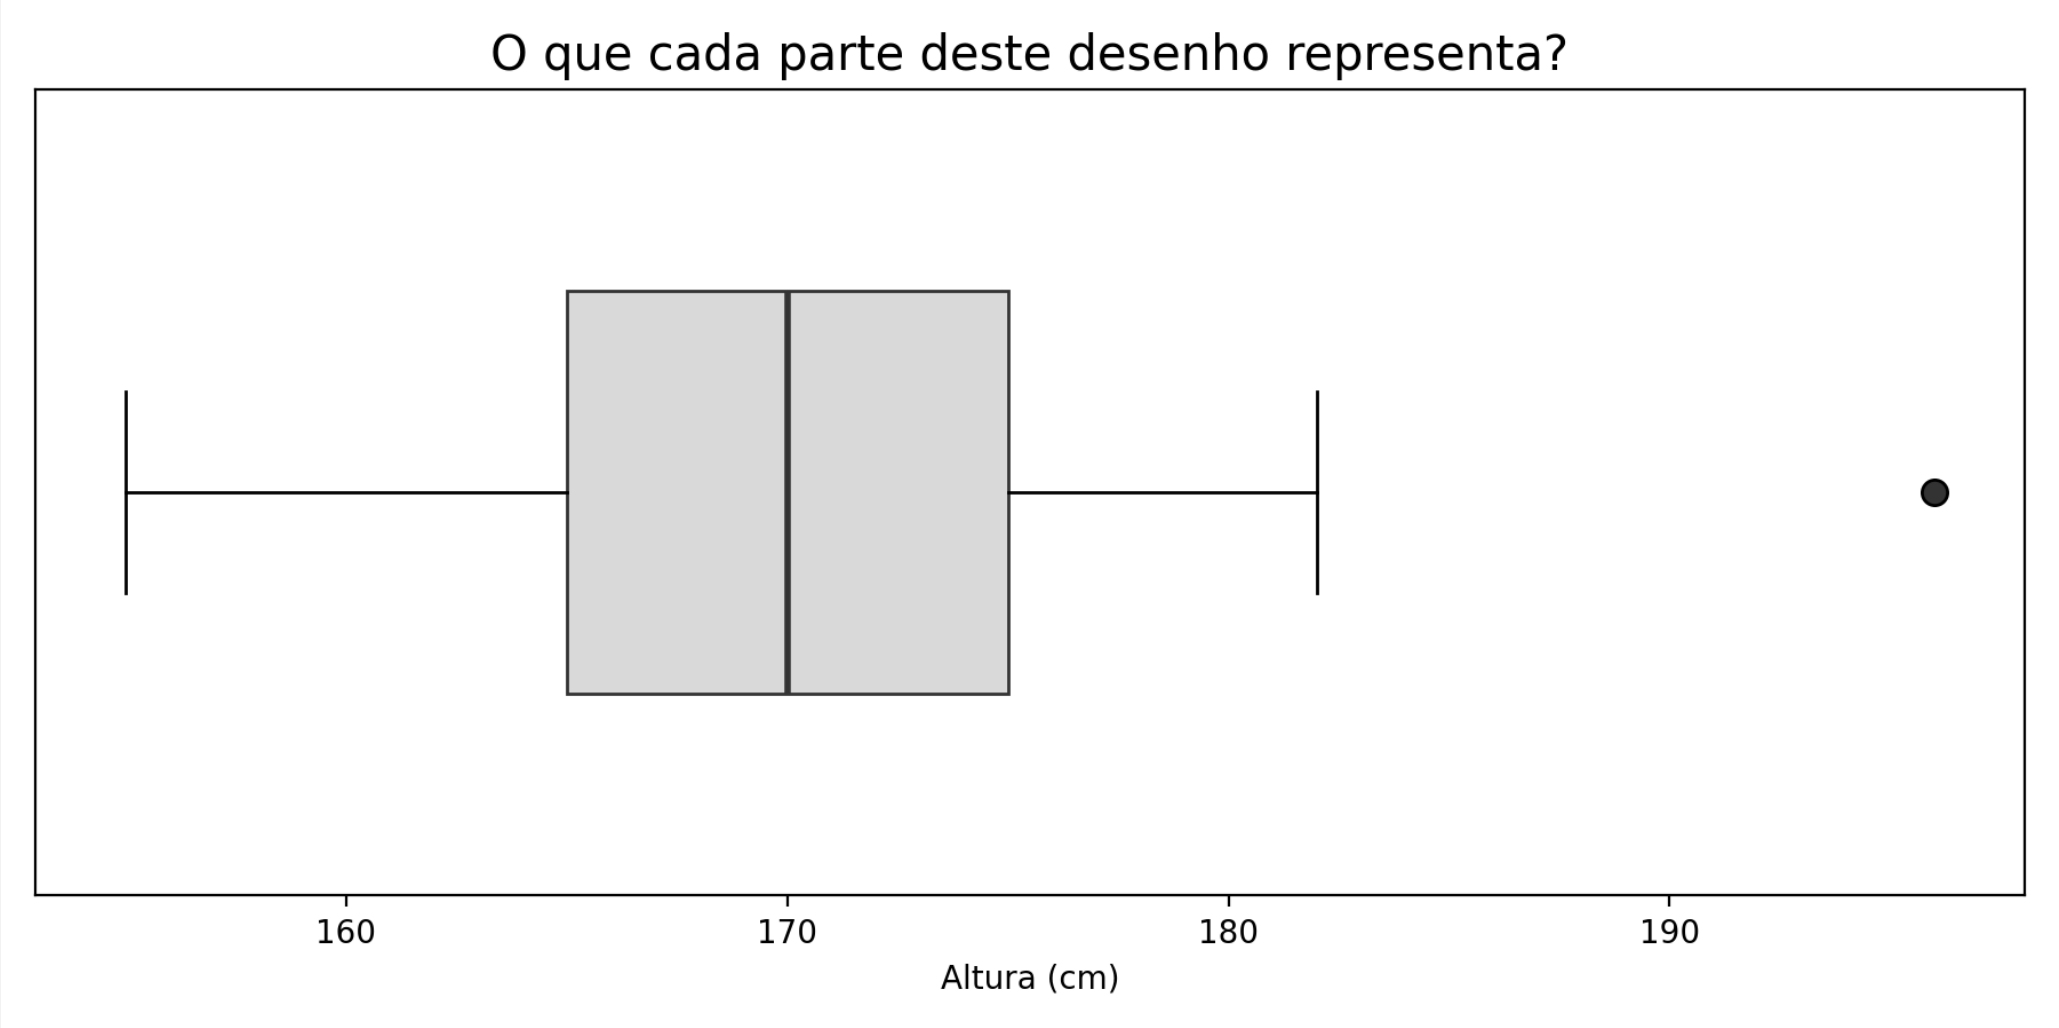
Boxplot



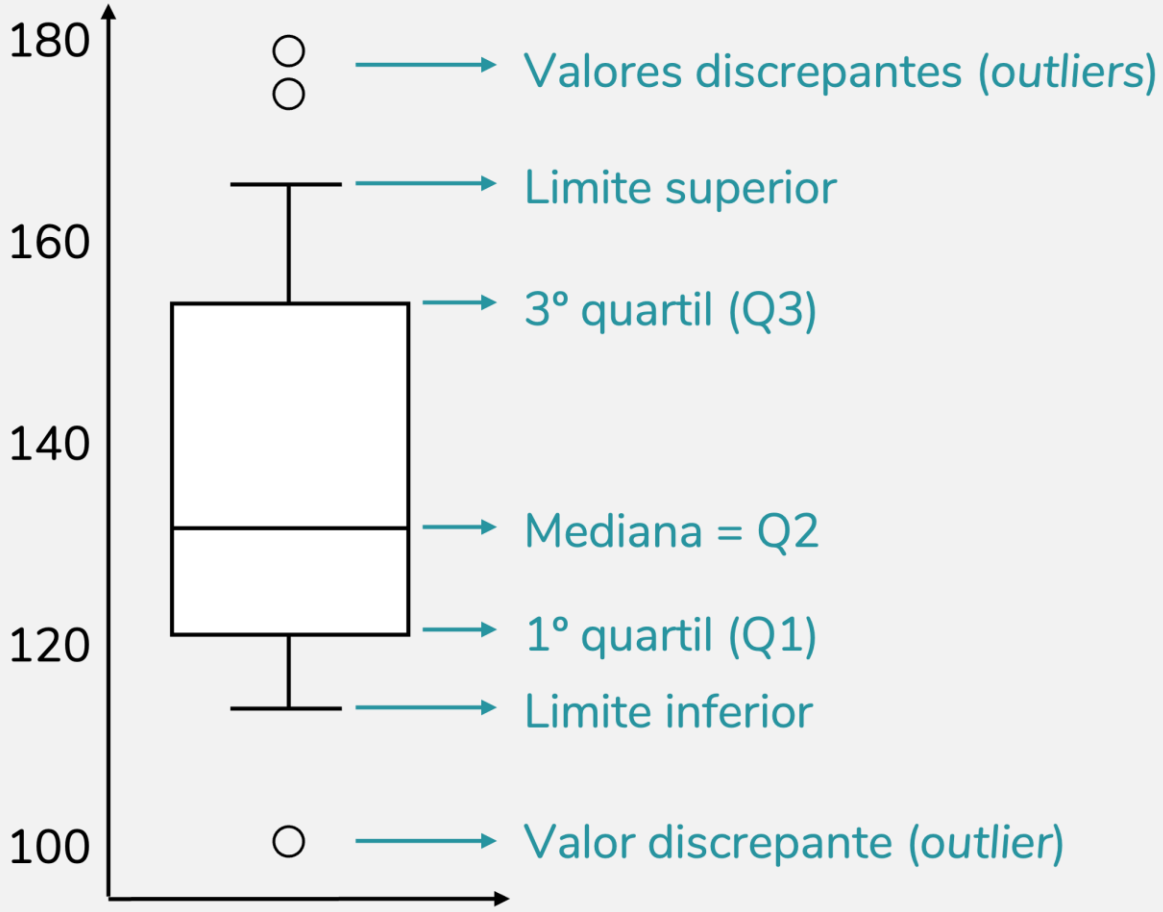
Boxplot - Elementos

- **Caixa:** Representa o intervalo interquartil (IQR), que contém 50% dos dados.
- **Linha dentro da caixa:** Indica a mediana (segundo quartil), dividindo os dados em duas metades iguais.
- **Bigodes (ou whiskers):** Linhas que se estendem da caixa até os valores mínimo e máximo dentro de 1.5 vezes o IQR a partir dos quartis.
- **Pontos fora dos bigodes:** Representam possíveis outliers, ou seja, valores que se distanciam significativamente da maioria dos dados.

Quiz: Leia Este Boxplot



A Resposta: Anatomia do Boxplot



Boxplot - Interpretação

- **Mediana:** Indica o centro da distribuição dos dados.
- **IQR:** Mostra a dispersão da metade central dos dados. Um IQR maior indica maior variabilidade.
- **Bigodes:** Indicam a extensão dos dados, excluindo possíveis outliers.
- **Outliers:** Pontos individuais que podem representar erros de medição, eventos raros ou características interessantes a serem investigadas.
- **Simetria:** Se a mediana está no centro da caixa e os bigodes têm comprimentos semelhantes, a distribuição tende a ser simétrica. Caso contrário, indica assimetria significativamente da maioria dos dados.

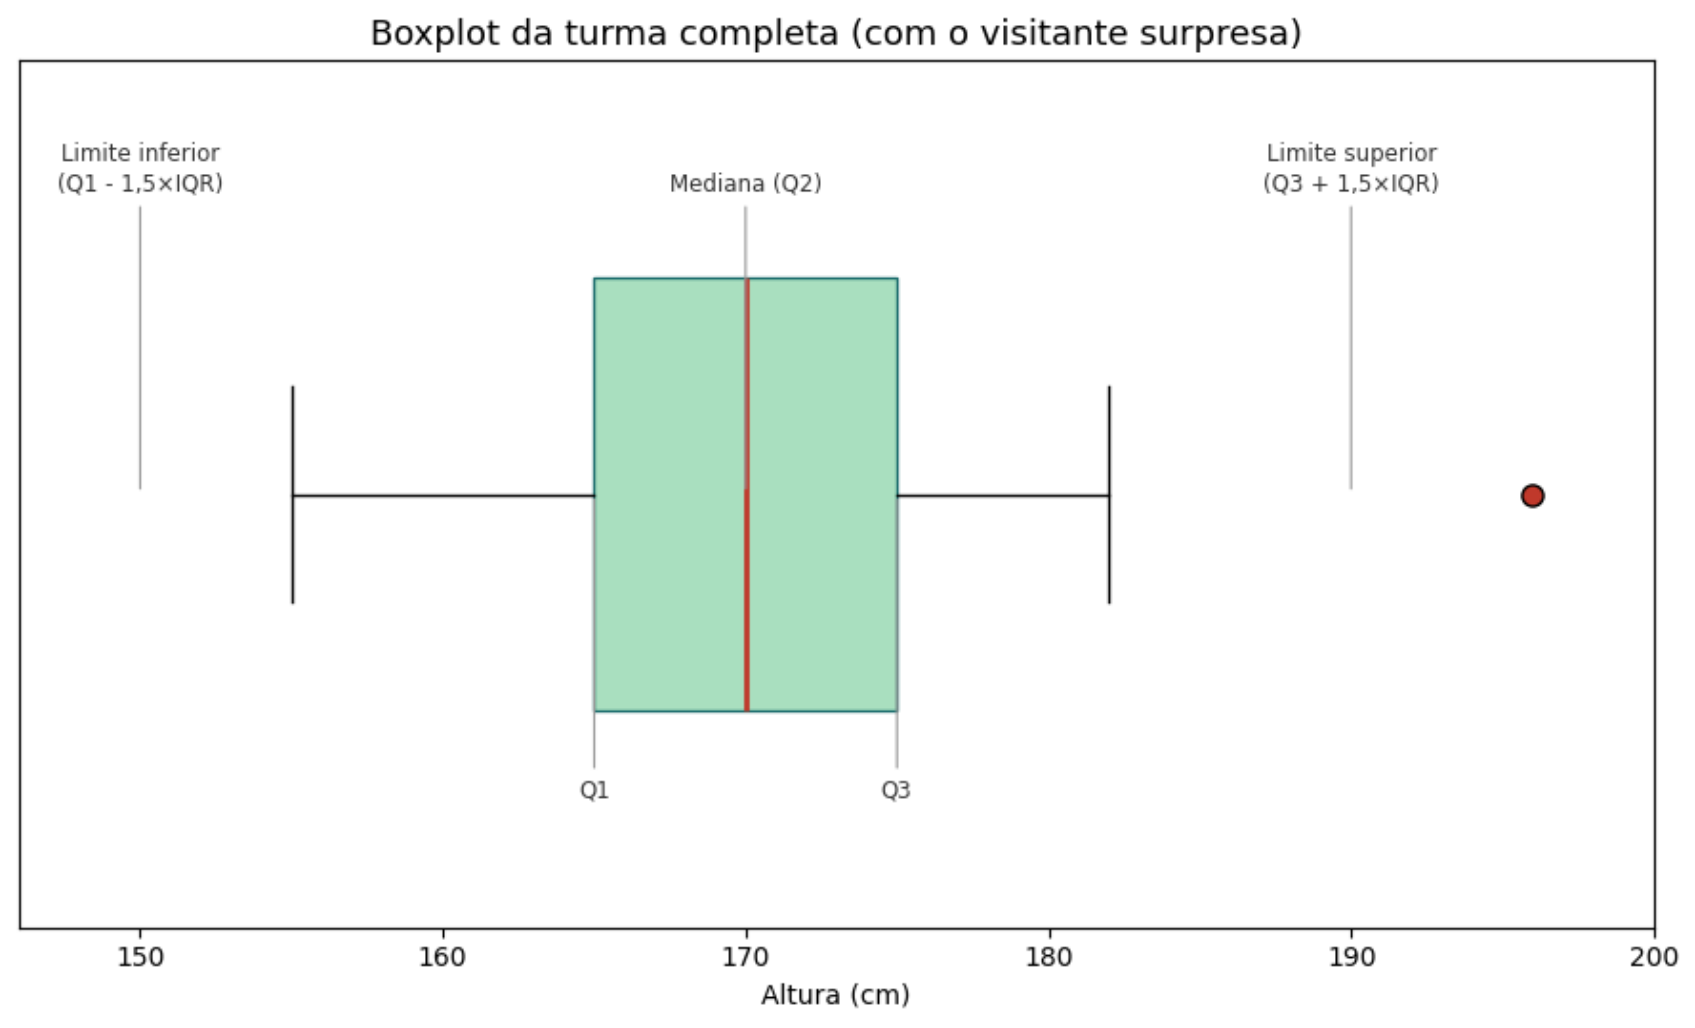
Boxplot

- Vantagens do Boxplot
  - Fácil interpretação visual.
  - Mostra informações importantes sobre a distribuição dos dados (centro, dispersão, assimetria, outliers).
  - Permite comparar facilmente diferentes grupos de dados.
- Desvantagens do Boxplot
  - Não mostra a forma detalhada da distribuição (como um histograma).
  - Pode esconder detalhes importantes sobre a distribuição, como bimodalidade.
- Quando usar um Boxplot
  - Para visualizar a distribuição de um conjunto de dados numéricos.
  - Para comparar a distribuição de diferentes grupos de dados.
  - Para identificar possíveis outliers — como o visitante de 196 cm da nossa dinâmica!

Dinâmica: Caçando Outliers com Quartis e IQR

- **Relembrando a Aula 04:** vamos usar os mesmos dados de altura que coletamos naquela aula (ou os dados de exemplo, se preferir).
- **O truque:** vamos calcular, ao vivo, Q1, Q3 e o IQR desses dados e depois "inserir" um visitante surpresa de 196 cm na turma.
- **A pergunta:** usando a regra Q1 - 1,5×IQR e Q3 + 1,5×IQR, esse visitante seria classificado como outlier?
- **Vamos conferir:** no notebook do Google Colab, e o resultado em forma de boxplot está no próximo slide.

Boxplot: Achamos o Outlier!





Gráficos de Dispersão (Scatterplots)

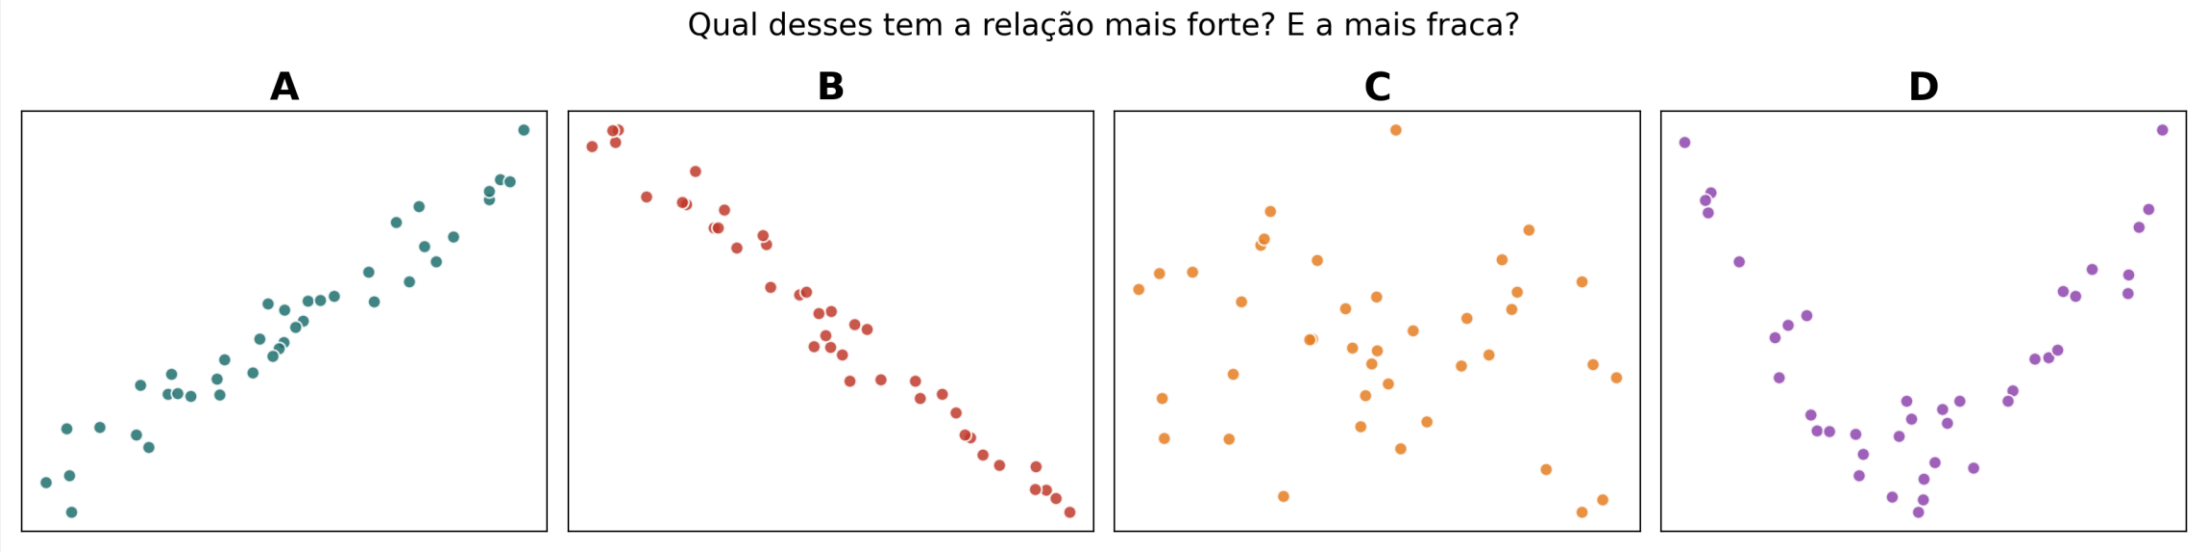
Visualizando a Relação entre Duas Variáveis

O que são Gráficos de Dispersão?

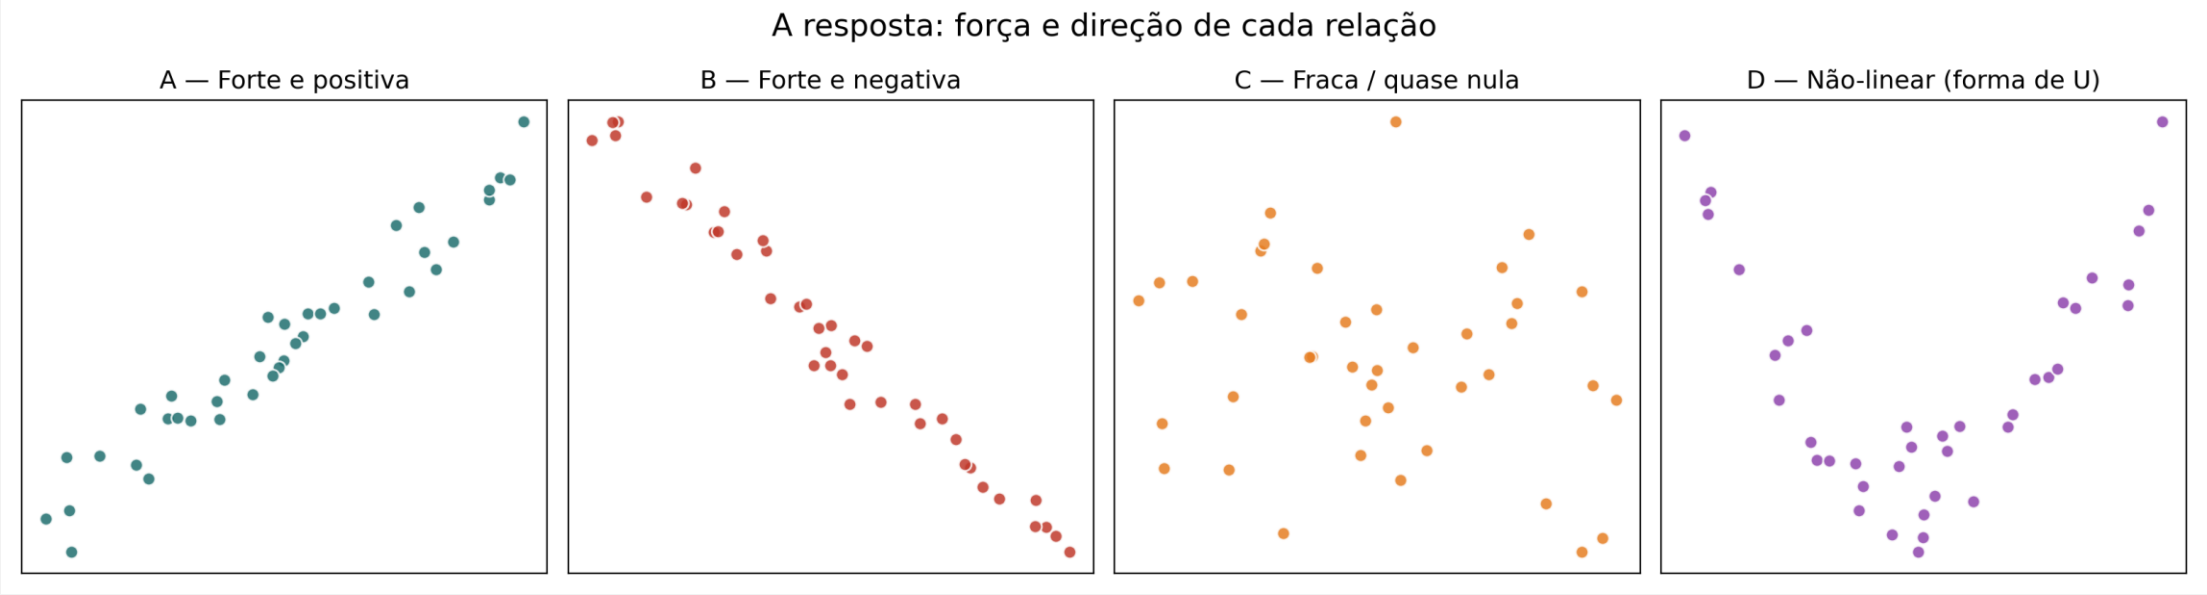
- **Definição:** um gráfico que utiliza pontos para representar a relação entre duas variáveis numéricas.

- **Eixo X:** representa uma variável.
- **Eixo Y:** representa a outra variável.
- Cada ponto no gráfico representa um par de valores das duas variáveis.
- Útil para visualizar padrões, tendências e outliers na relação entre as variáveis.

Quiz Relâmpago: Qual Tem a Relação Mais Forte?

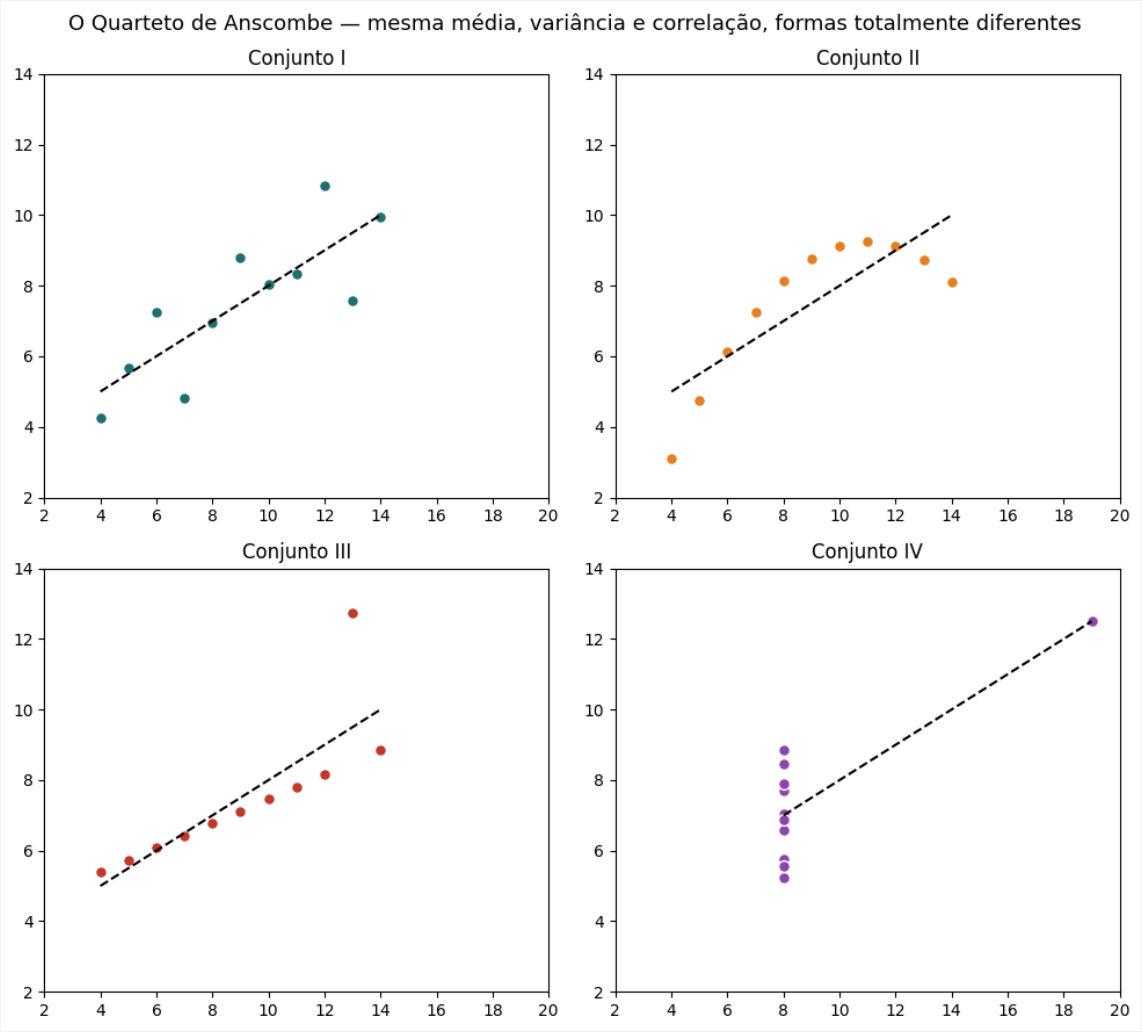


A Resposta: Força e Direção da Relação

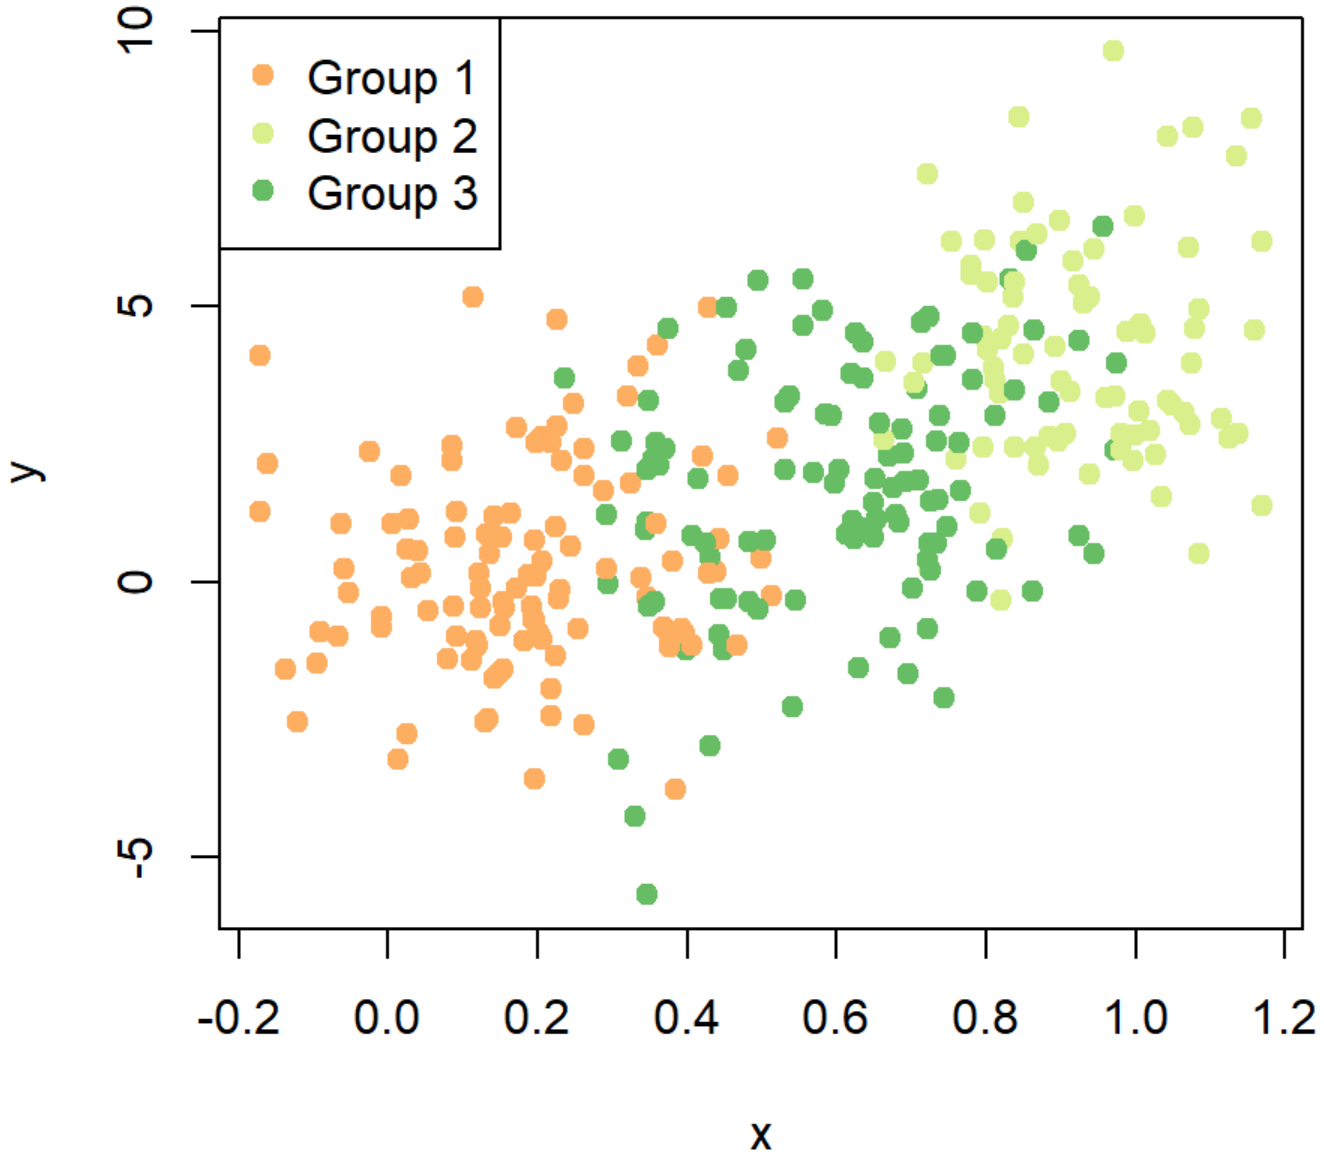


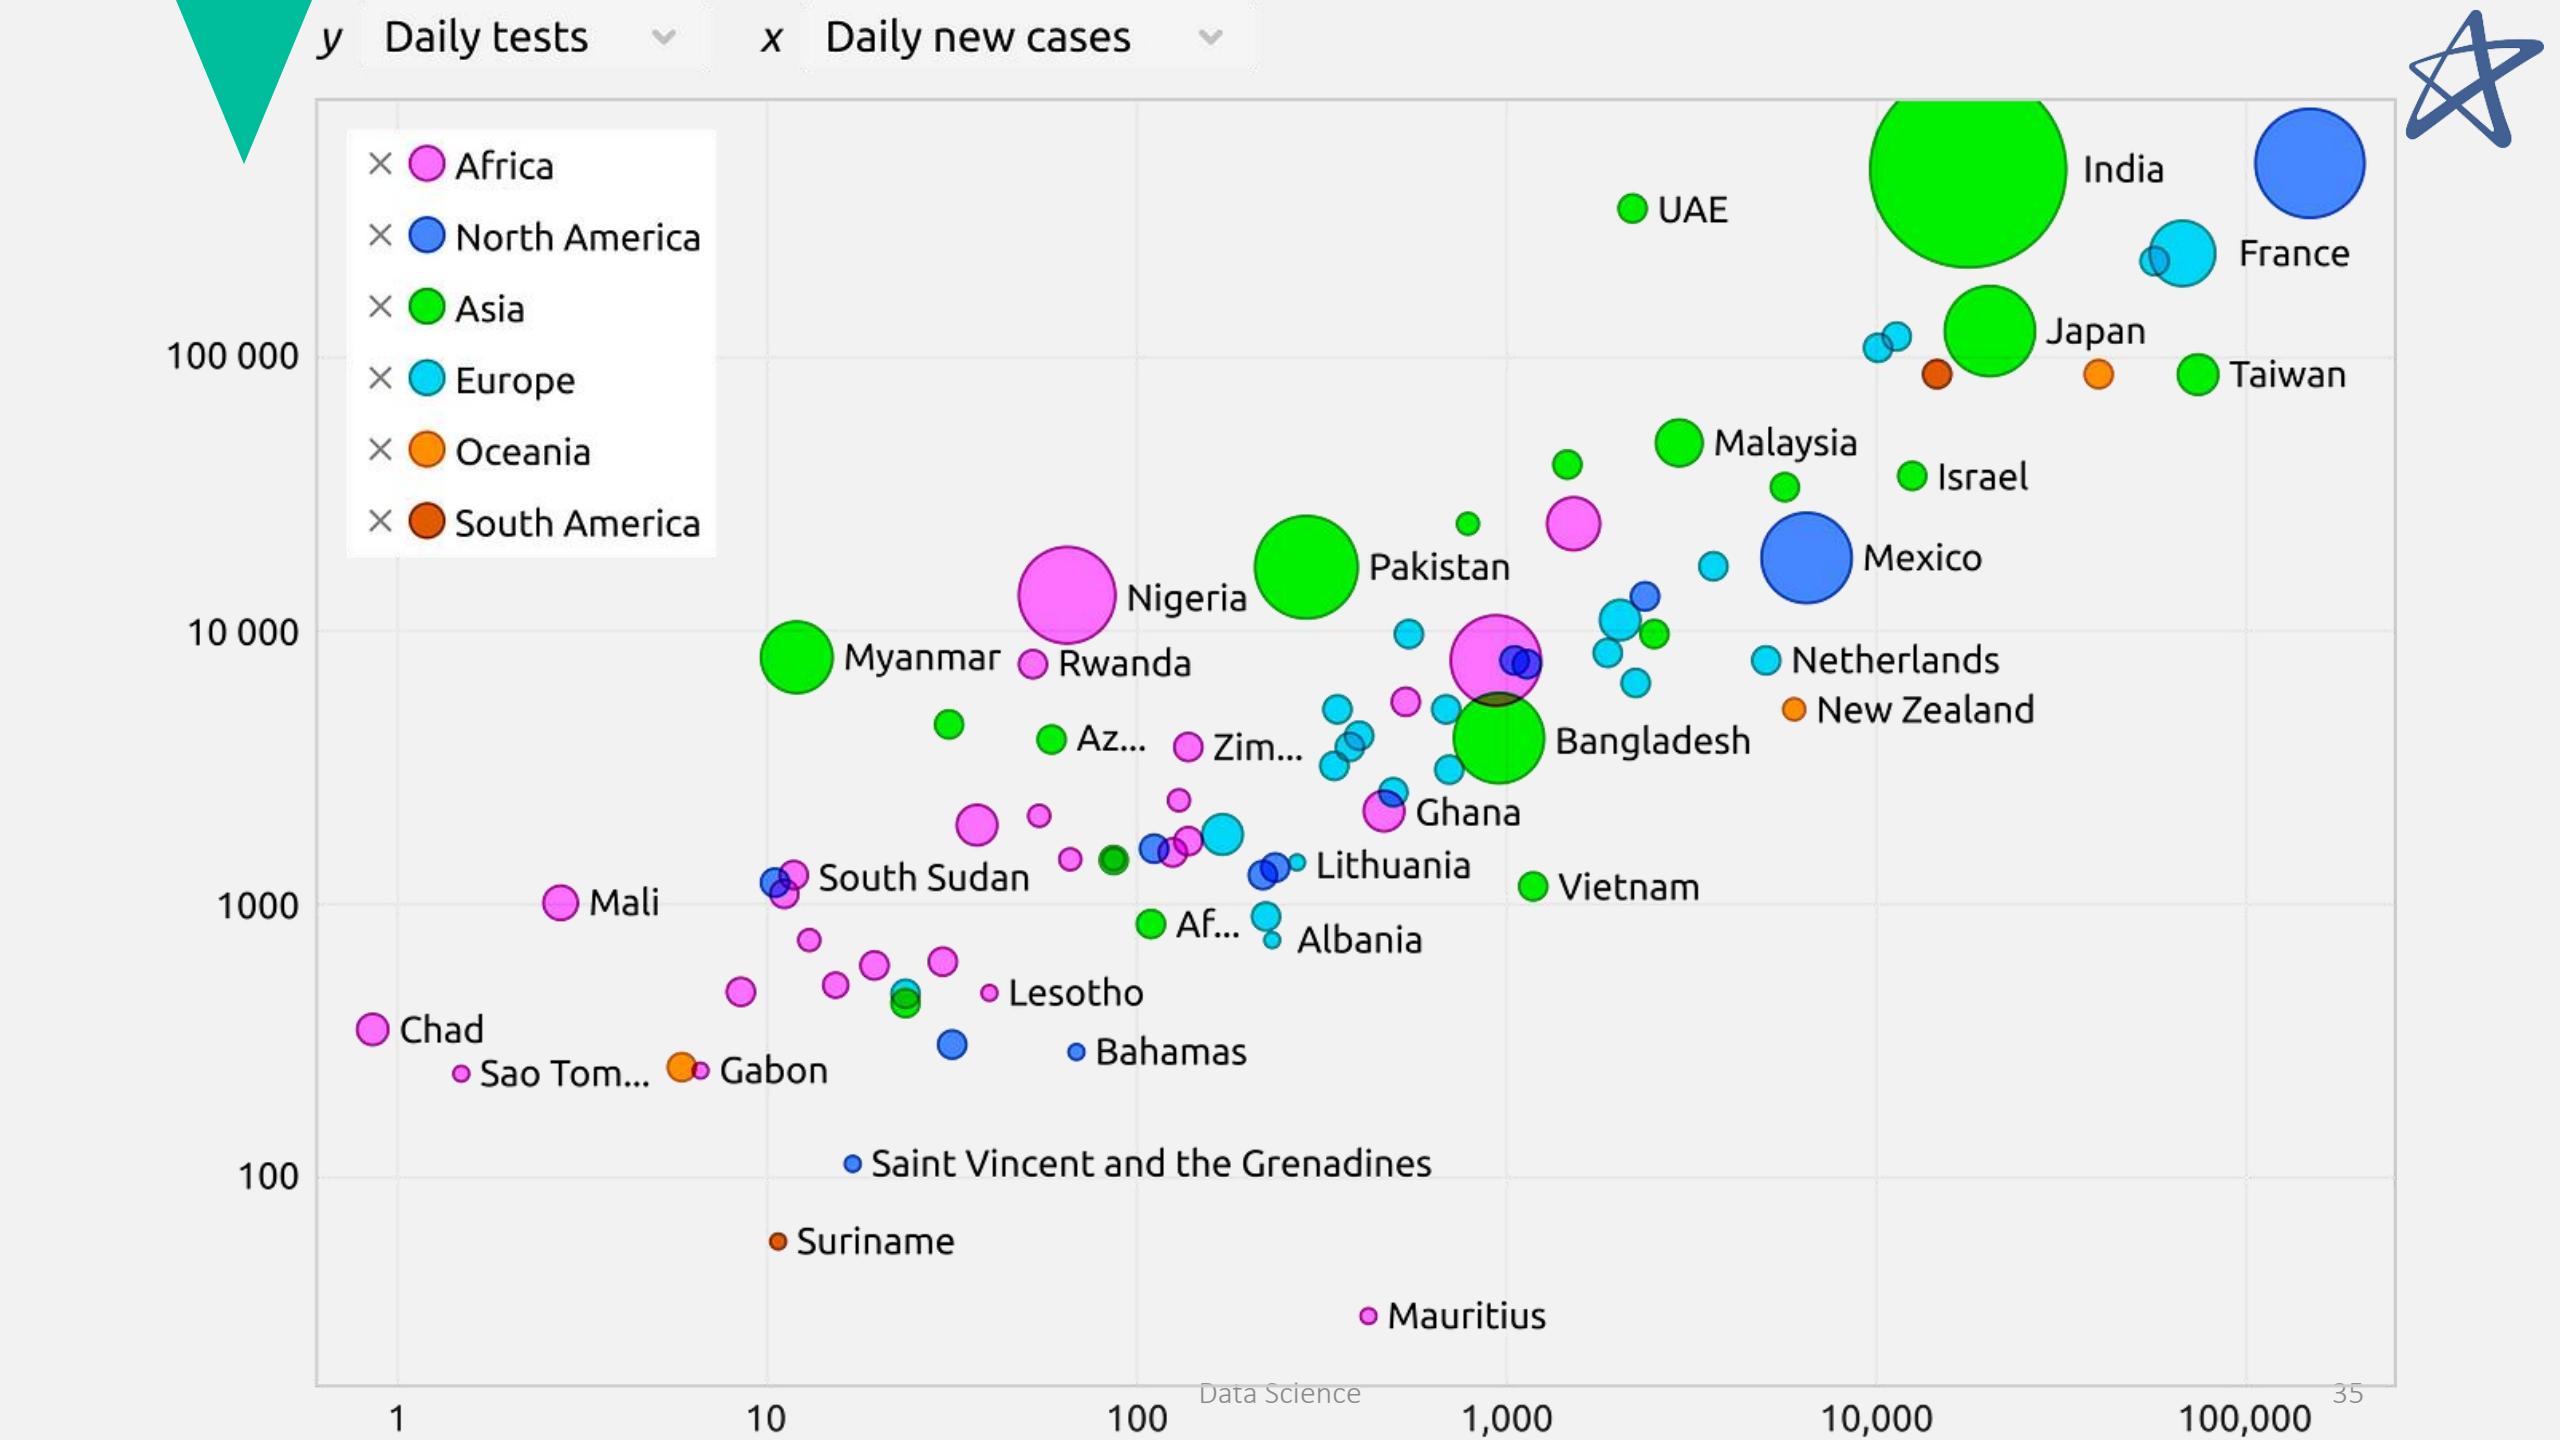
Direção: positiva ou negativa | Força: forte, fraca ou nula | Outliers: pontos que fogem do padrão geral dos demais

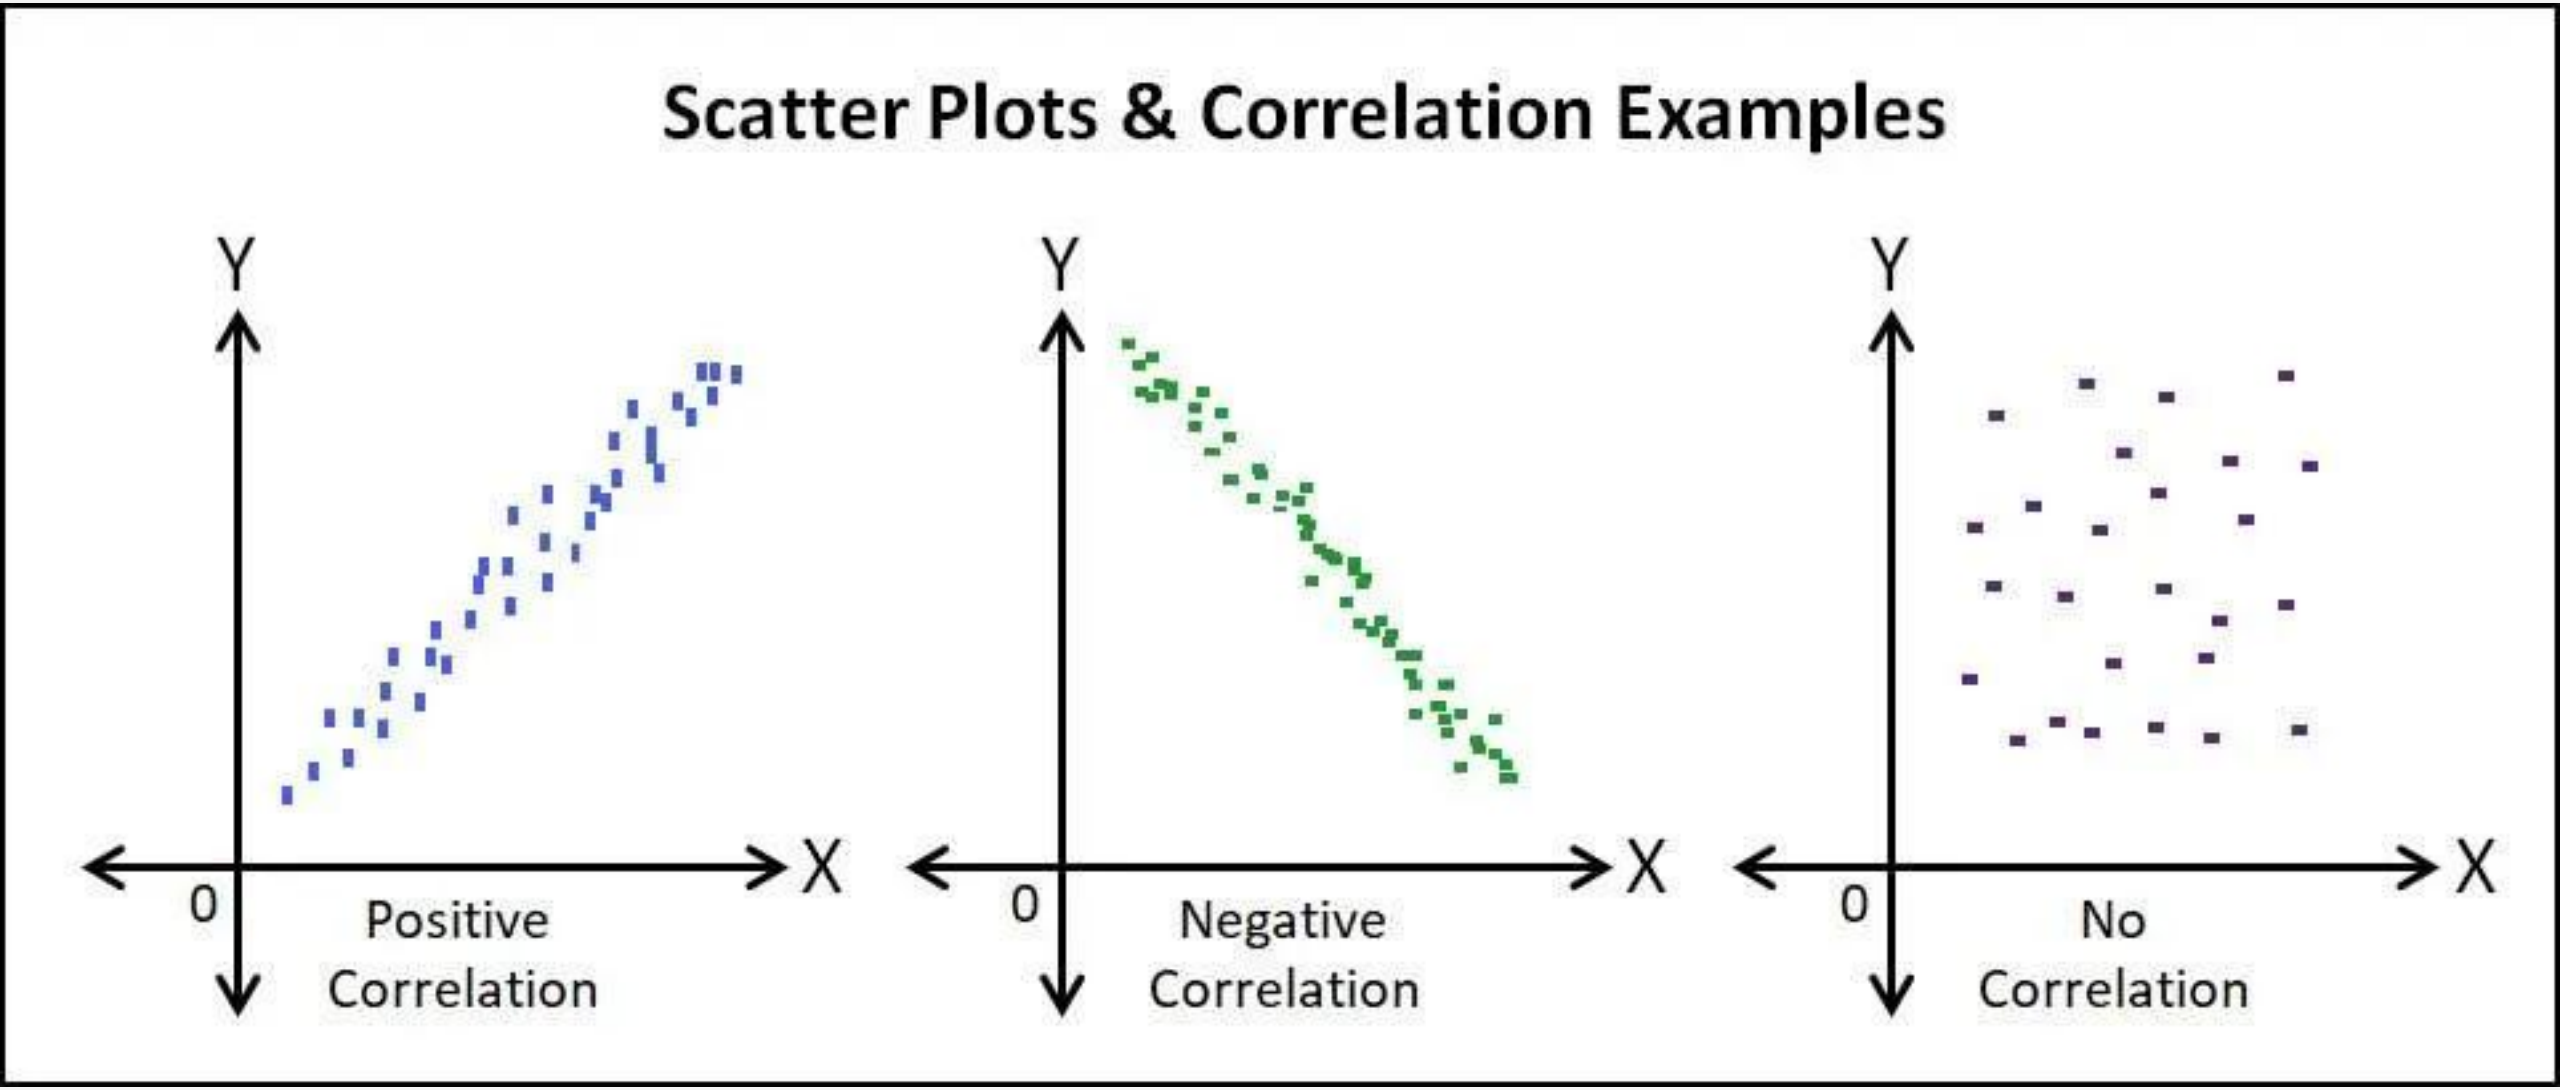
O Quarteto de Anscombe

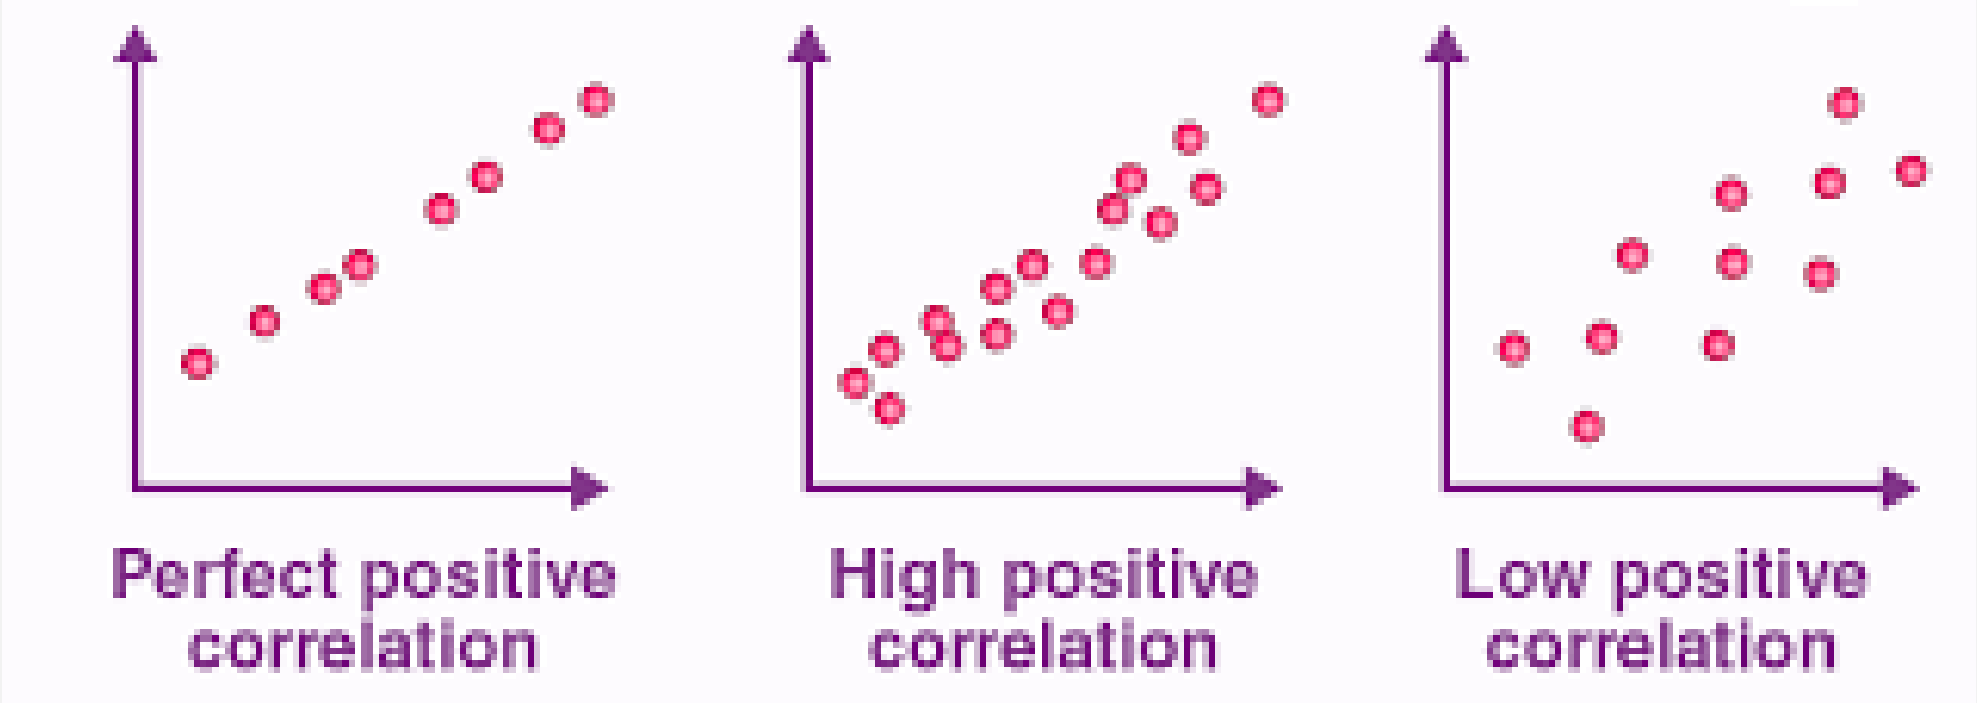



Ground living area partially explains sale price of apartments
Sale price (k$)
600
400
200
0
1000
2000
3000
4000
5000
Ground living area


Group 1
Group 2
Group 3
y
10
5
0
-5
-0.2
0.0
0.2
0.4
0.6
0.8
1.0
1.2
x


y Daily tests
x Daily new cases
Africa
North America
Asia
Europe
Oceania
South America
100 000
10 000
1000
100
1
10
100
1,000
10,000
100,000
India
UAE
France
Japan
Taiwan
Malaysia
Israel
Mexico
Pakistan
Nigeria
Myanmar
Rwanda
Netherlands
New Zealand
Bangladesh
Az...
Zim...
Ghana
Lithuania
Vietnam
South Sudan
Mali
Af...
Albania
Lesotho
Chad
Bahamas
Sao Tom...
Gabon
Saint Vincent and the Grenadines
Suriname
Mauritius


Scatter Plots & Correlation Examples
Y
X
0
Positive
Correlation
Y
X
0
Negative
Correlation
Y
X
0
No
Correlation


Perfect positive correlation
High positive correlation
Low positive correlation