

Universidade POSITIVO

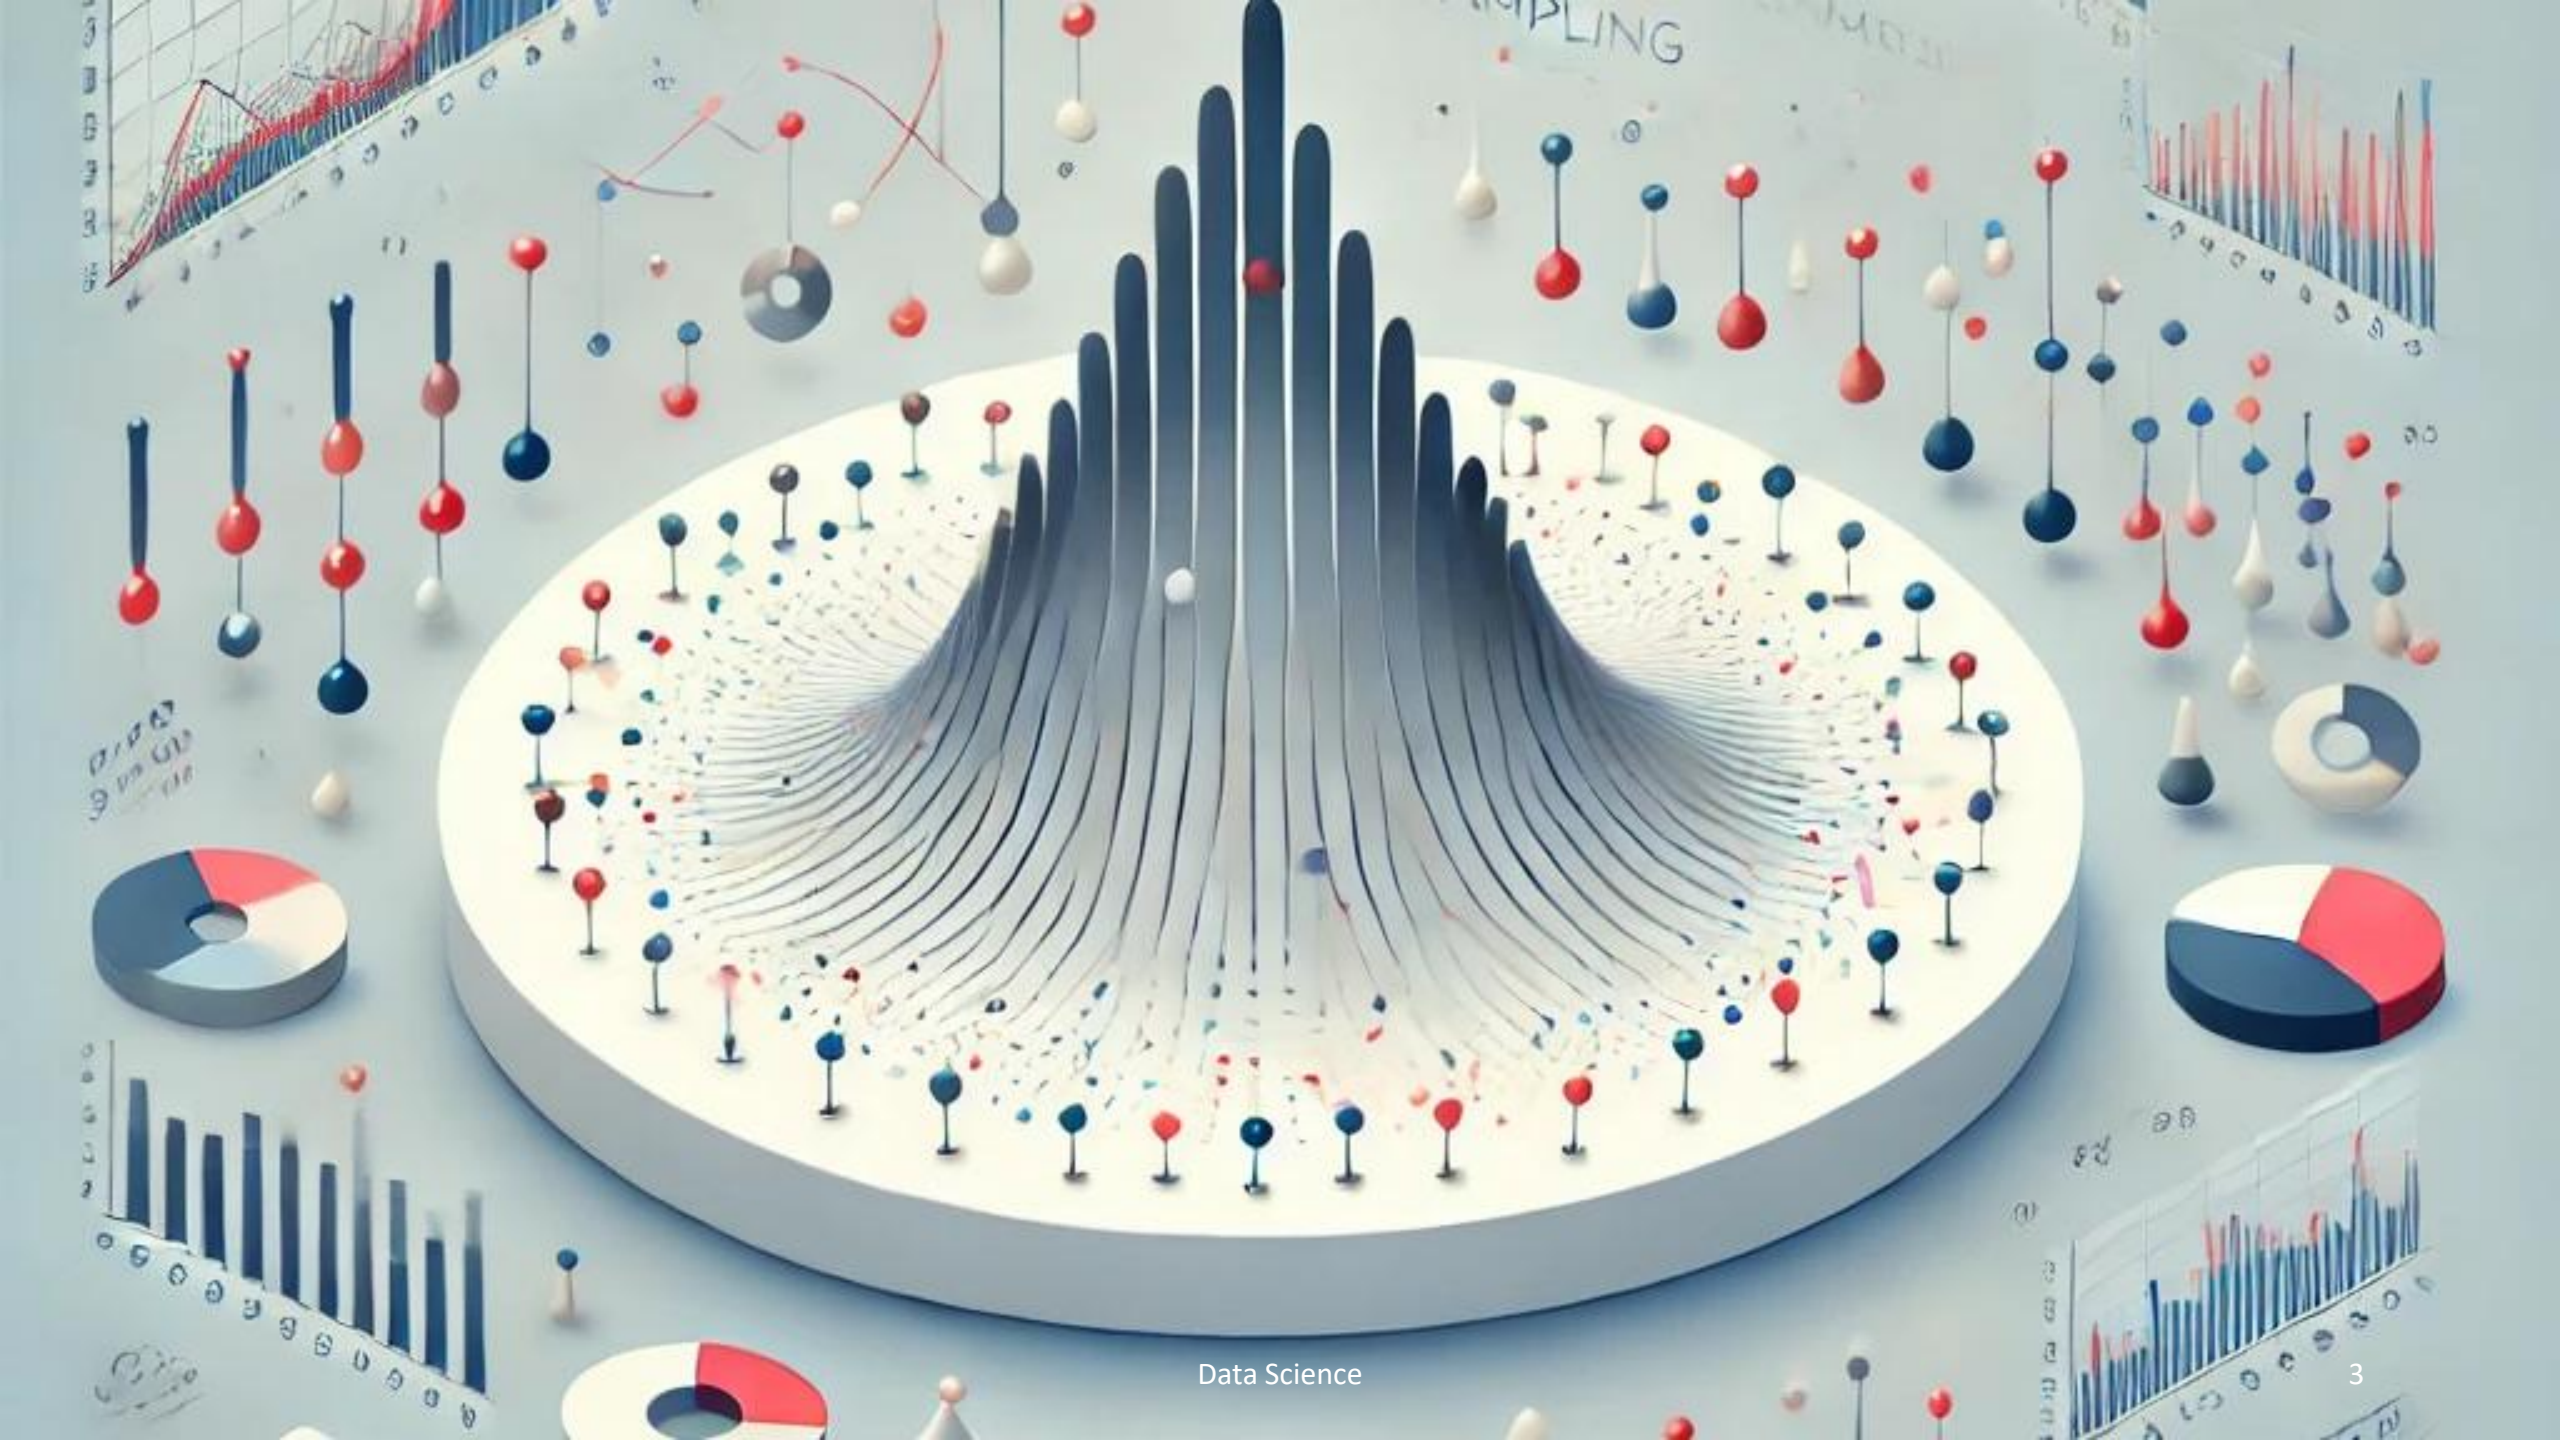
Data Science

Prof.: MSc. Alex Junior Nunes

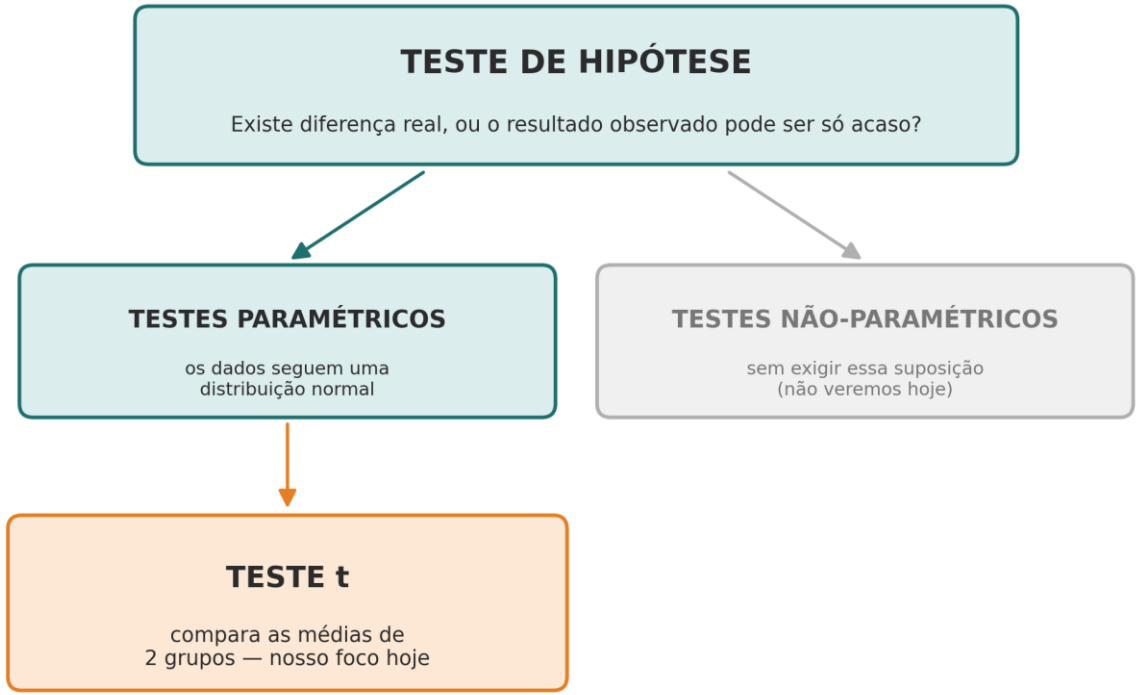
pfsalexnunes@gmail.com

Data Science

Testes de Hipótese Paramétricos, Gráficos de plot



Onde Estamos: Do Teste de Hipótese ao Teste t



Hoje vamos até o Teste t — guarde esse mapa, vamos voltar a ele.

Teste de Hipótese - Definição

- Um processo formal e estruturado que utiliza dados amostrais para avaliar a plausibilidade de uma afirmação ou crença sobre uma população.
- Permite tomar decisões informadas e embasadas em evidências, em vez de confiar apenas na intuição ou em observações casuais.

Teste de Hipótese – Conceitos Chave

- Hipótese Nula (H0)
  - A afirmação que se assume verdadeira até que haja evidência suficiente para rejeitá-la.
  - Geralmente representa o status quo, a ausência de efeito ou a igualdade entre grupos.
- Hipótese Alternativa (H1)
  - A afirmação que se deseja provar ou apoiar com base nos dados.
  - Representa a mudança, o efeito ou a diferença que se busca detectar.
- Pense como um julgamento
  - H0 é como a "presunção de inocência": assumimos que não há efeito até prova em contrário.
  - Os dados são as evidências — e o valor-p mede o quão fortes elas são contra H0.

Teste de Hipótese – Conceitos Chave

- **Nível de Significância (α):**

- A probabilidade máxima de rejeitar a hipótese nula quando ela é verdadeira (Erro Tipo I).
- Define o limite para considerar um resultado estatisticamente significativo.
- Limite para rejeitar H0.
- Valor comum: 0.05 (5%).

Teste de Hipótese – Conceitos Chave

- Valor-p (p-value):

- A probabilidade de obter um resultado tão extremo ou mais extremo do que o observado, assumindo que a hipótese nula é verdadeira.
- Quanto menor o valor-p, mais forte a evidência contra a hipótese nula.

Teste de Hipótese – Conceitos Chave

- Erros Tipo I e Tipo II:

- Erro Tipo I: Rejeitar a hipótese nula quando ela é verdadeira (falso positivo).
- Erro Tipo II: Não rejeitar a hipótese nula quando ela é falsa (falso negativo).

Teste de Hipótese – Conceitos Chave

- Decisão

- **Se valor-p ≤ α:** Rejeita-se a hipótese nula. O resultado é considerado estatisticamente significativo (há evidência de diferença significativa).

- **Se valor-p > α:** Falha-se em rejeitar a hipótese nula. O resultado não é considerado estatisticamente significativo (não há evidência suficiente de diferença).

Teste de Hipótese — Um Exemplo Para Guardar

- **Cenário:** Uma empresa farmacêutica desenvolveu uma nova medicação para reduzir a pressão arterial.
- **H0:** A nova medicação não tem efeito na pressão arterial (é igual ao placebo).
- **H1:** A nova medicação reduz a pressão arterial em comparação ao placebo.
- **Coleta de dados:** Um estudo clínico é realizado com dois grupos de pacientes: um recebe a nova medicação e o outro recebe um placebo.
- **Análise:** Um teste de hipótese é utilizado para comparar as médias da pressão arterial entre os dois grupos.
- **Decisão:** Com base no valor-p, decide-se se há evidência suficiente para rejeitar a hipótese nula e concluir que a nova medicação é eficaz.

Data Science

Testes Paramétricos

Dentro do Teste de Hipótese: escolhendo o tipo certo de teste

Testes Paramétricos: O Que São e Por Que Usar

- O que são?
  - Testes estatísticos que fazem suposições específicas sobre a distribuição dos dados — a mais comum é que os dados seguem uma distribuição normal.
- Por que usar quando possível
  - São geralmente mais poderosos que os não paramétricos: maior chance de detectar um efeito real, quando os pressupostos são atendidos.
  - Permitem inferências mais precisas sobre a população (média, desvio padrão) e cobrem uma ampla variedade de perguntas de pesquisa.

Principais Testes Paramétricos

- Teste t (o que veremos hoje)
  - Compara a média de uma amostra a um valor de referência, ou as médias de duas amostras (independentes ou pareadas).
- Outros testes da mesma família
  - ANOVA: compara as médias de três ou mais grupos ao mesmo tempo.
  - Regressão Linear: examina a relação entre uma variável dependente e uma ou mais variáveis independentes.

Pressupostos e Cuidados

- Os testes paramétricos são válidos apenas se seus pressupostos forem atendidos.
- Violar os pressupostos pode levar a resultados enganosos e conclusões incorretas.
- É essencial verificar os pressupostos antes de aplicar um teste paramétrico, utilizando métodos gráficos (como histogramas, gráficos Q-Q) e testes estatísticos (como o teste de Shapiro-Wilk para normalidade e o teste de Levene para homogeneidade de variâncias).
- Se os pressupostos não forem atendidos, pode ser necessário utilizar testes não paramétricos, que fazem menos suposições sobre a distribuição dos dados, mas geralmente são menos poderosos.

Data Science

Teste t

Dentro dos Testes Paramétricos: comparando as médias de dois grupos

Teste t

- O que é?
  - Uma ferramenta estatística para comparar médias de duas amostras.
  - Avalia se a diferença observada entre as médias é estatisticamente significativa ou se pode ser atribuída ao acaso.
- Quando usar?
  - Comparar médias de dois grupos (ex: tratamento vs. controle, antes vs. depois).
  - Amostras pequenas ou quando a variância populacional é desconhecida.
  - Dados normalmente distribuídos (ou próximos da normalidade).

Teste t - Hipóteses

- Mesma lógica de sempre, aplicada aqui
  - Lembra do H0 e H1 que vimos lá no início? Aqui usamos a mesma ideia — só que aplicada especificamente à comparação de médias de dois grupos.
- Hipótese Nula (H0)
  - Não há diferença significativa entre as médias dos grupos.
- Hipótese Alternativa (H1)
  - Há diferença significativa entre as médias dos grupos.
  - Pode ser unilateral (maior ou menor) ou bilateral (diferente).

Teste t – Fórmula e Erro Padrão

- **Fórmula:**
- t = (Média da amostra 1 - Média da amostra 2) / Erro padrão da diferença

- **Erro padrão:**
- Mede a variabilidade da diferença entre as médias amostrais.
- Depende dos desvios padrão e dos tamanhos das amostras.

Teste t – Valor-p e Decisão

- A mesma regra de decisão de antes
  - Já vimos que comparamos o valor-p com o nível de significância α (geralmente 0,05) — aqui não muda nada.
- Aplicando ao teste t
  - Se valor-p ≤ α: rejeitamos H0 — há diferença significativa entre as médias.
  - Se valor-p > α: não rejeitamos H0 — não há evidência suficiente de diferença.
- Voltando à analogia do julgamento
  - Um valor-p pequeno é uma evidência forte contra a "inocência" de H0 — por isso rejeitamos.

Teste t – Considerações

- **Normalidade:**
  - Verificar se os dados seguem (aproximadamente) uma distribuição normal.
  - Se não, considerar alternativas não paramétricas (ex: teste de Mann-Whitney).
- **Homogeneidade de Variâncias:**
  - Verificar se as variâncias dos grupos são iguais.
  - Se não, ajustar o cálculo do erro padrão.
- **Tamanho do Efeito:**
  - Avaliar a magnitude da diferença entre as médias, além da significância estatística.





Data Science

Exemplo de Teste t

Apresentação de um problema prático

- Cenário: Uma escola deseja comparar a eficácia de dois métodos de ensino (Método A e Método B) em uma determinada disciplina.
- Questão de pesquisa: O Método A leva a um desempenho significativamente melhor do que o Método B?

Passos para realizar o teste t

1. Formular as hipóteses nula e alternativa:

- **H0:** Não há diferença significativa no desempenho médio entre os alunos que utilizaram o Método A e o Método B (μA = μB).
- **H1:** O desempenho médio dos alunos que utilizaram o Método A é significativamente diferente do desempenho médio dos alunos que utilizaram o Método B (μA ≠ μB).

Passos para realizar o teste t

2. Coletar os dados:

- Selecionar aleatoriamente duas amostras de alunos, uma para cada método de ensino.
- Aplicar os métodos de ensino aos respectivos grupos.
- Avaliar o desempenho dos alunos em ambos os grupos, obtendo as notas ou pontuações.

Passos para realizar o teste t

3. Verificar os pressupostos:

- **Normalidade:** Utilizar histogramas ou gráficos Q-Q para verificar se as notas em cada grupo seguem aproximadamente uma distribuição normal.
- **Homogeneidade de variâncias:** Aplicar o teste de Levene para verificar se as variâncias das notas são iguais entre os dois grupos.
- **Independência:** Assegurar que as amostras foram selecionadas de forma independente e que as notas de um aluno não influenciam as notas de outro.

Passos para realizar o teste t

4. Calcular a estatística do teste e o valor-p:

- Utilizar um software estatístico ou uma calculadora para calcular a estatística t e o valor-p correspondente, considerando os pressupostos verificados.

Passos para realizar o teste t

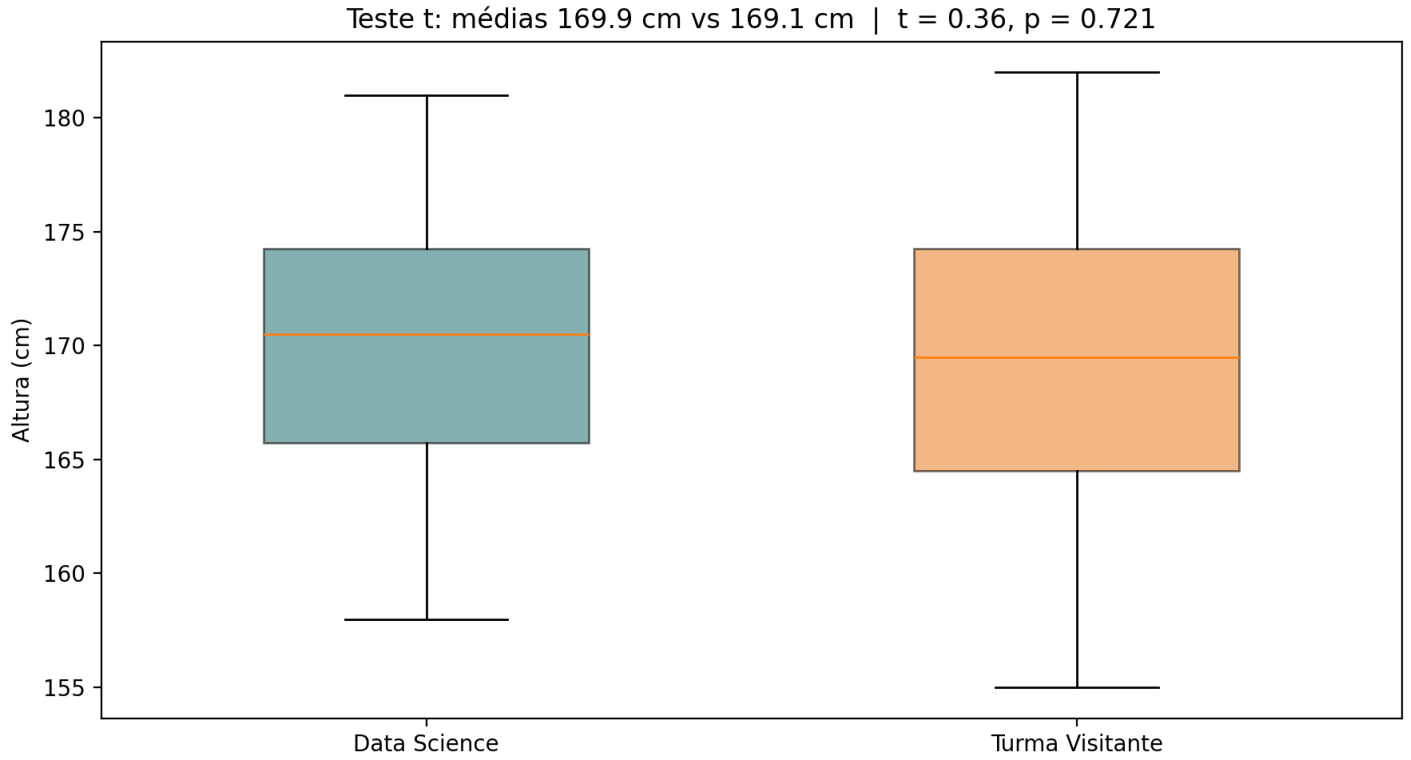
5. **Tomar a decisão e interpretar os resultados:**

- Comparar o valor-p com o nível de significância (α) escolhido (geralmente 0.05).
- Se o valor-p for menor que α, rejeitar a hipótese nula e concluir que há evidência suficiente para afirmar que existe uma diferença significativa no desempenho médio entre os dois métodos de ensino.
- Se o valor-p for maior que α, não rejeitar a hipótese nula e concluir que não há evidência suficiente para afirmar que existe uma diferença significativa.
- Interpretar os resultados no contexto do problema, considerando a magnitude da diferença observada e sua relevância prática.

Dinâmica: A Turma Visitante Tem Altura Diferente da Nossa?

- O desafio
  - Nas Aulas 4 e 5 coletamos as alturas dos 20 alunos da nossa turma de Data Science.
  - Uma turma visitante de outro curso também tem 20 alunos medidos.
- Nossa pergunta
  - As médias de altura das duas turmas são estatisticamente diferentes, ou a diferença é só acaso?
- Como vamos responder
  - Vamos aplicar um teste t para duas amostras independentes nos dados de altura.
  - Hipótese nula (H0): as médias das duas turmas são iguais.
  - Hipótese alternativa (H1): as médias são diferentes.

Resultado: Teste t Aplicado às Nossas Turmas



p = 0,721 > 0,05 → não rejeitamos H0: não há diferença estatisticamente significativa entre as médias das duas turmas.

Data Science

Gráficos de Plot em Testes de Hipótese

Importância dos gráficos

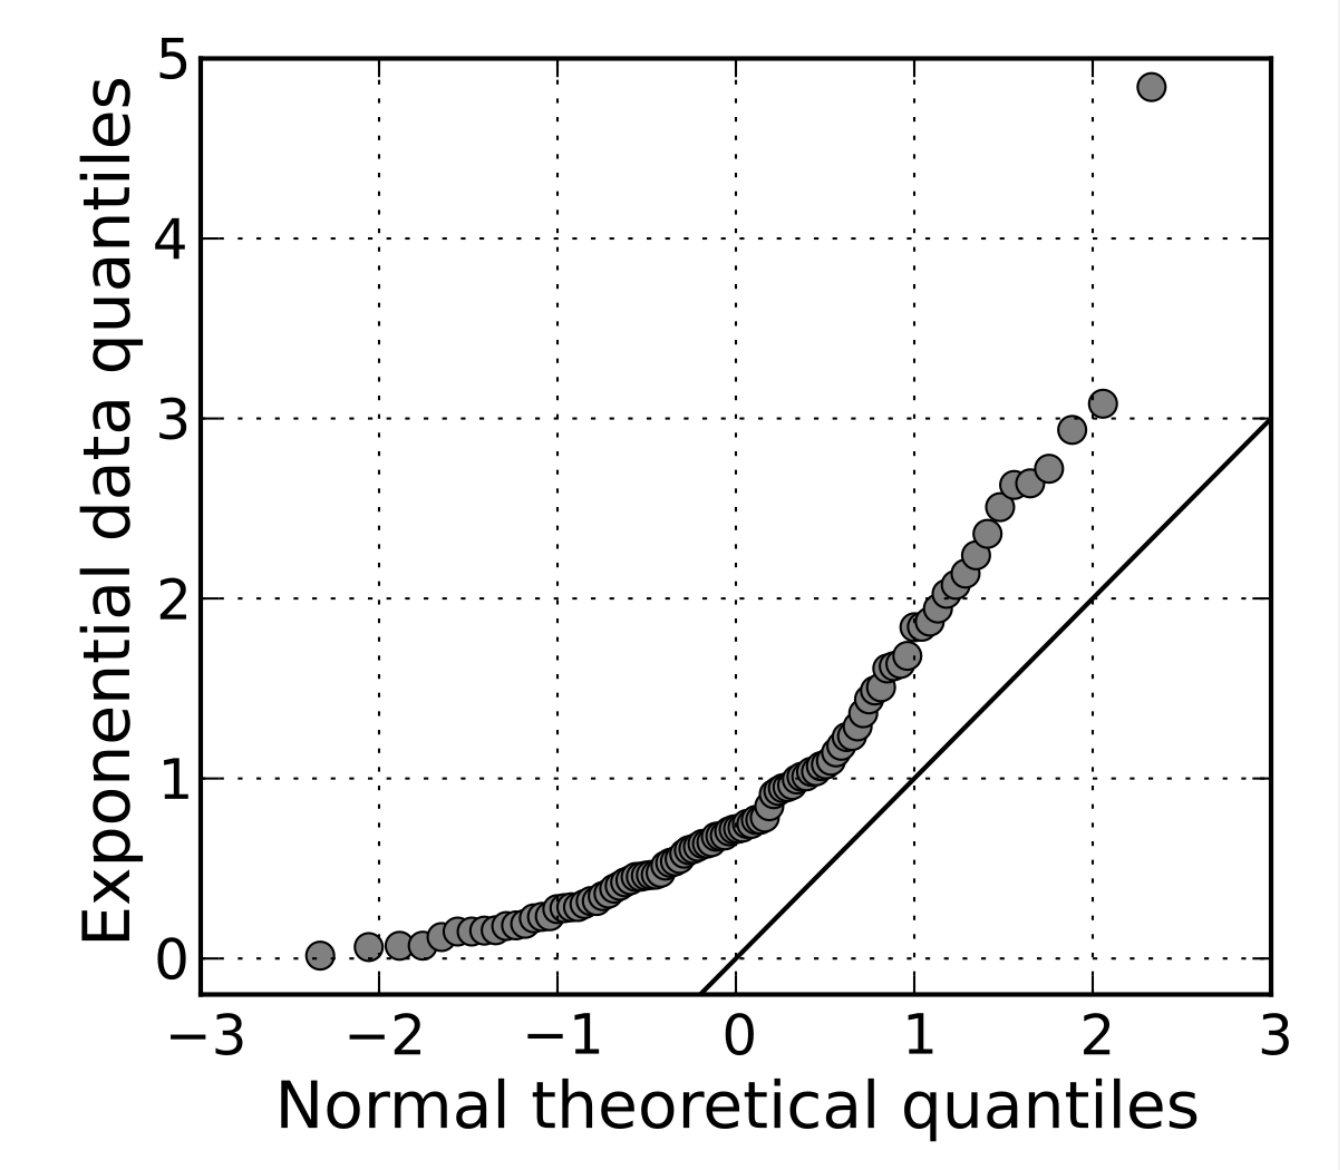
- Os gráficos fornecem uma representação visual dos dados, permitindo identificar padrões, tendências, outliers e relações entre variáveis de forma rápida e intuitiva.
- São essenciais para verificar os pressupostos dos testes de hipótese, como a normalidade dos dados e a homogeneidade de variâncias, antes de aplicar um teste paramétrico.
- Ajudam a interpretar os resultados dos testes, visualizando a magnitude do efeito, a sobreposição entre grupos e a distribuição dos resíduos.
- Facilitam a comunicação dos resultados para um público não técnico, tornando a análise mais acessível e compreensível.

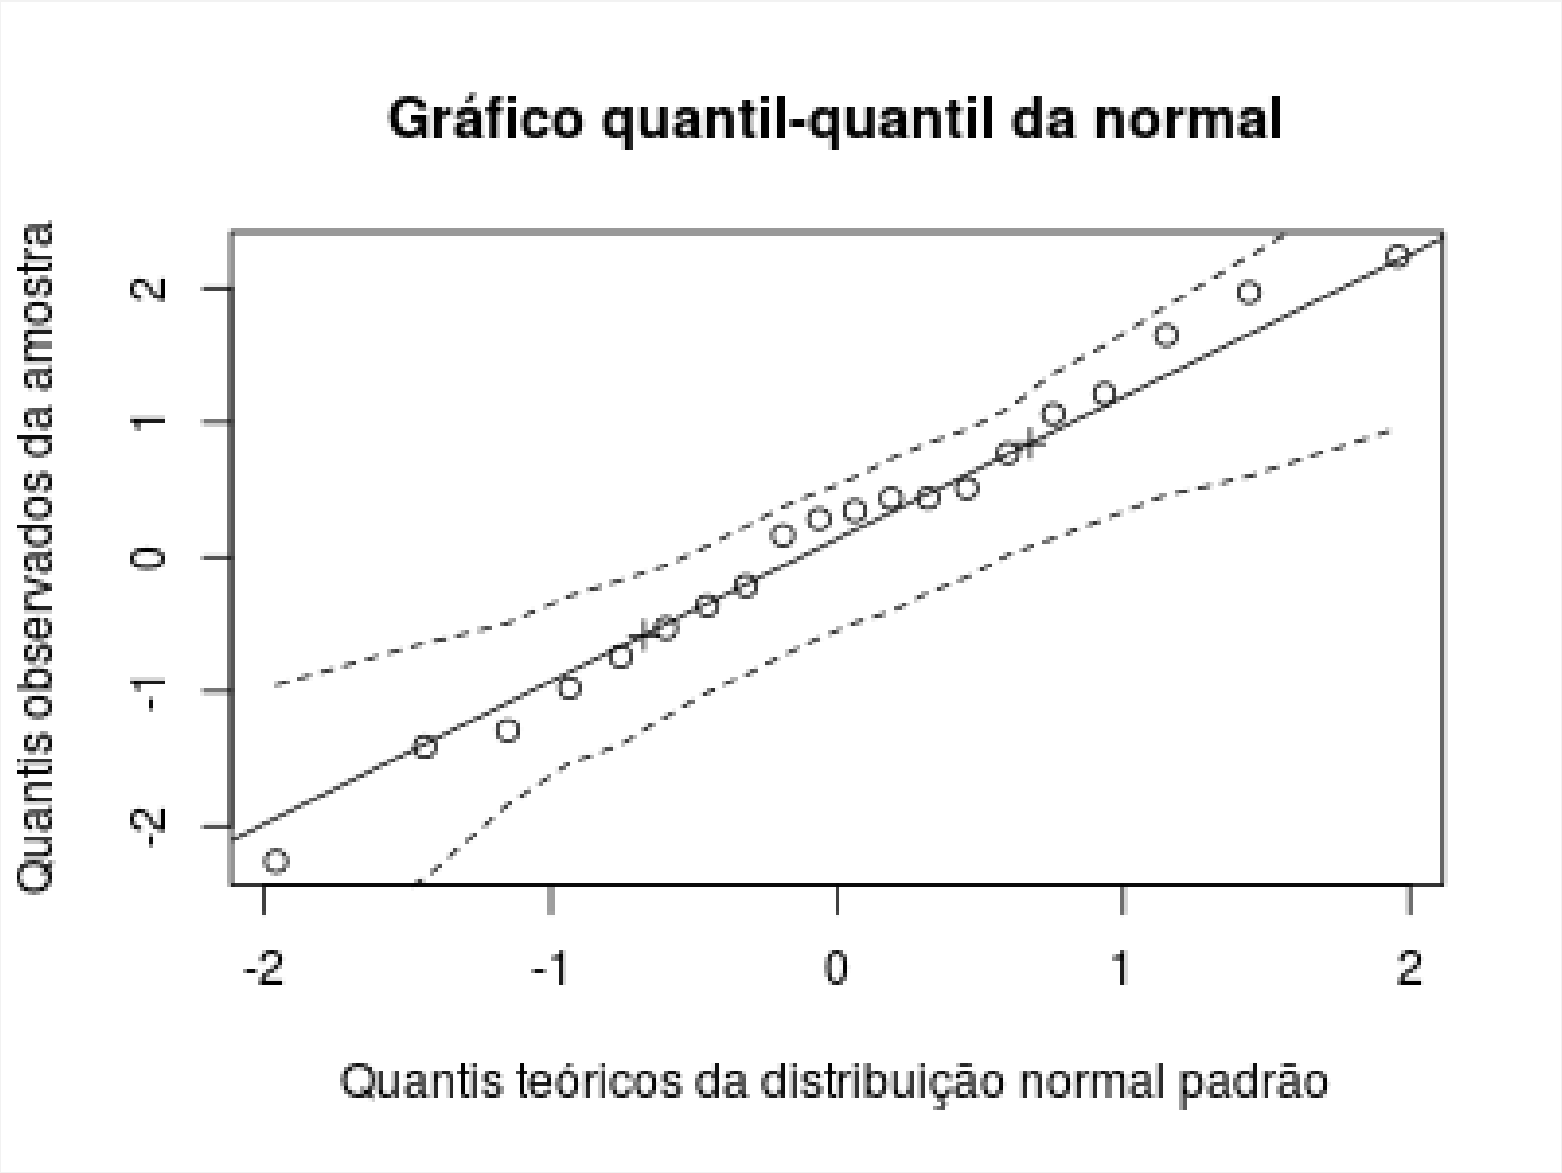
Exemplo dos gráficos

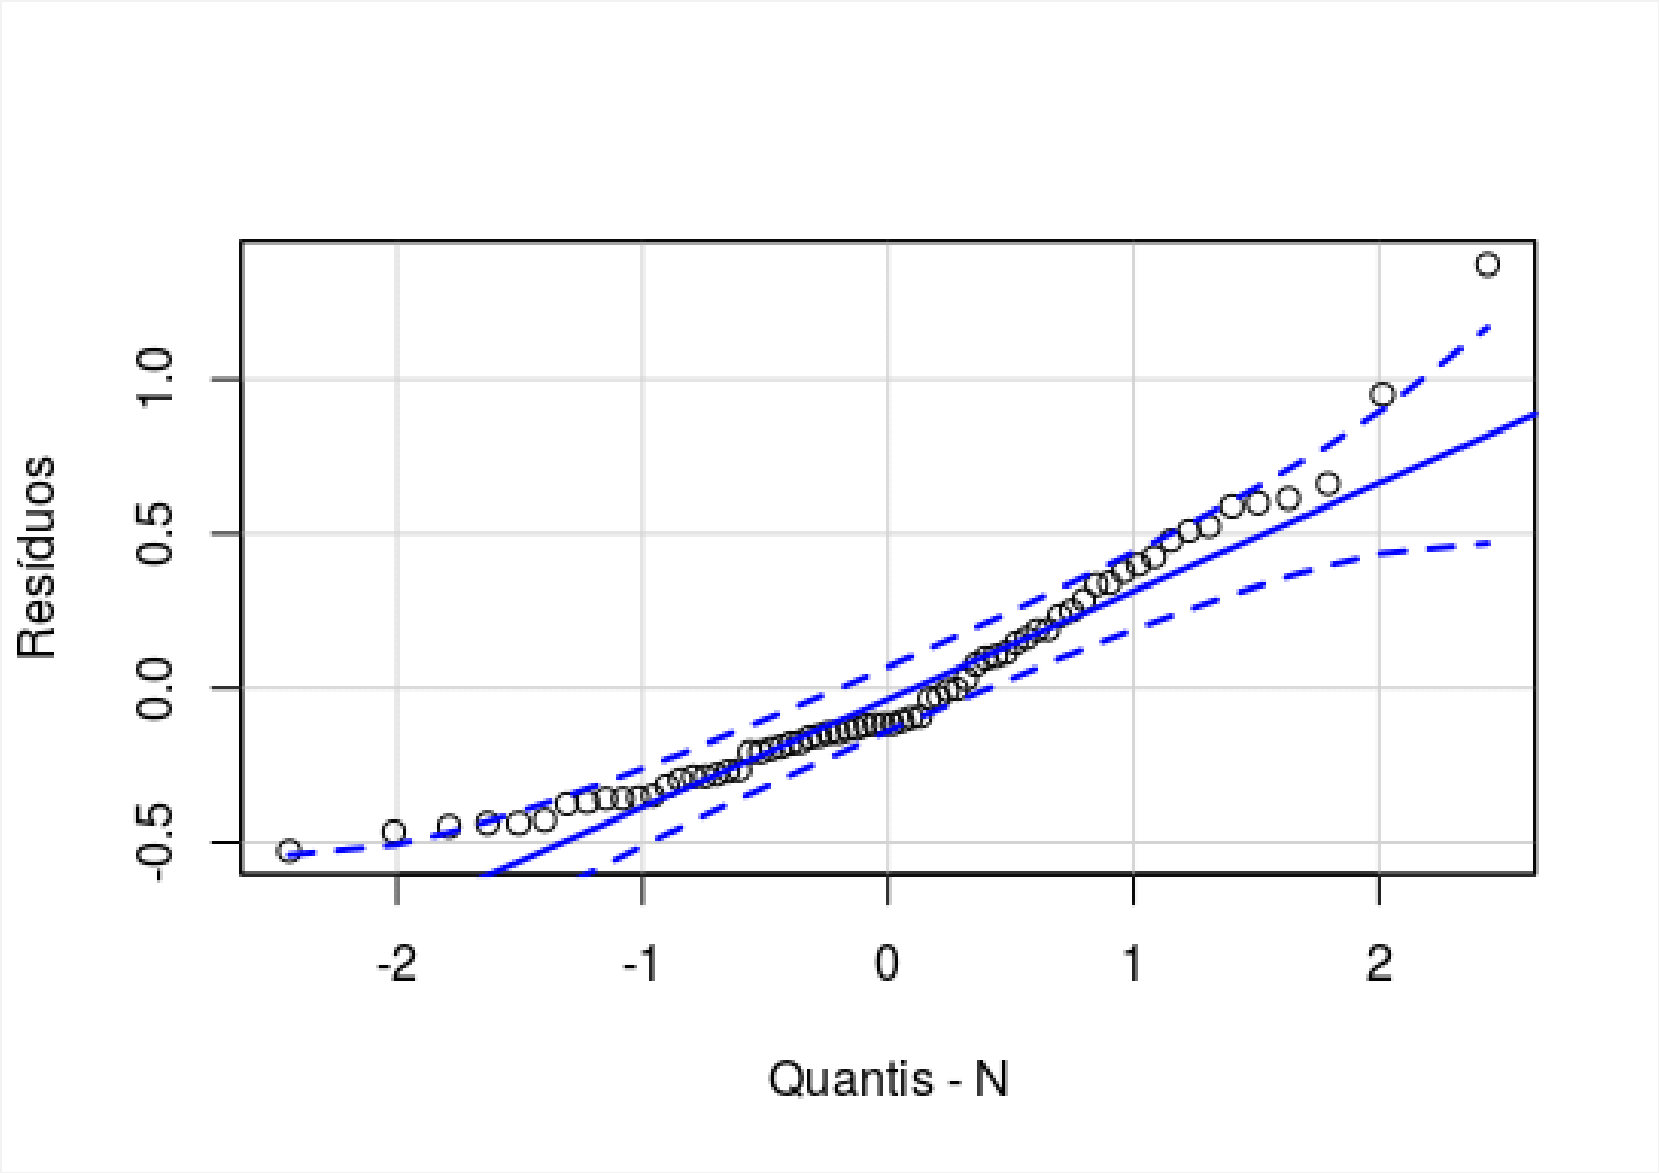
- Histogramas:
  - Representam a distribuição de frequência de uma variável contínua, mostrando a forma, a centralidade e a dispersão dos dados.
  - Úteis para verificar a normalidade dos dados, comparando a forma do histograma com a curva normal teórica.
- Boxplots (diagramas de caixa):
  - Exibem a mediana, os quartis, os valores máximo e mínimo e os outliers de uma variável contínua.
  - Permitem comparar a distribuição de uma variável entre diferentes grupos ou categorias.
  - Úteis para identificar a presença de outliers e avaliar a simetria da distribuição.

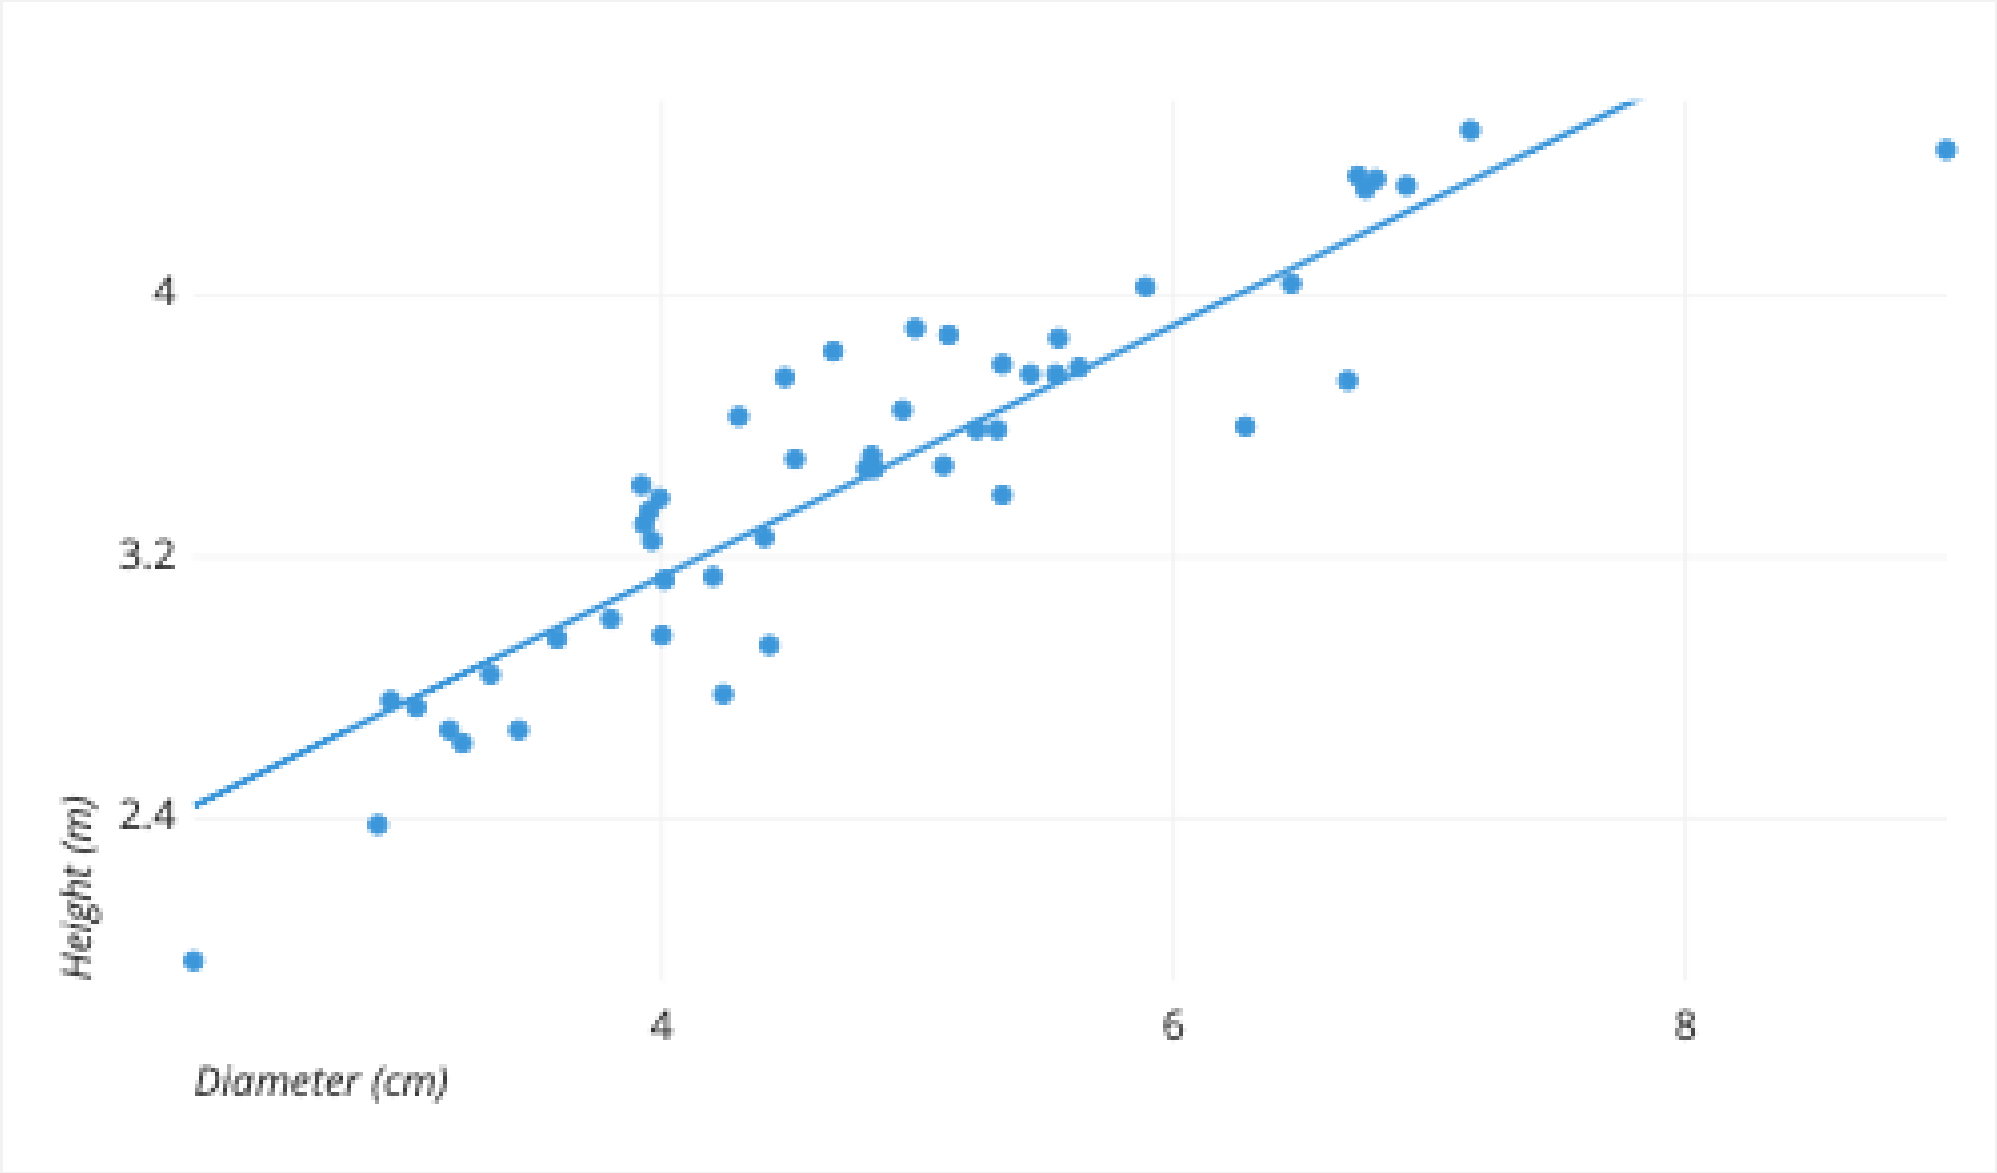
Exemplo dos gráficos

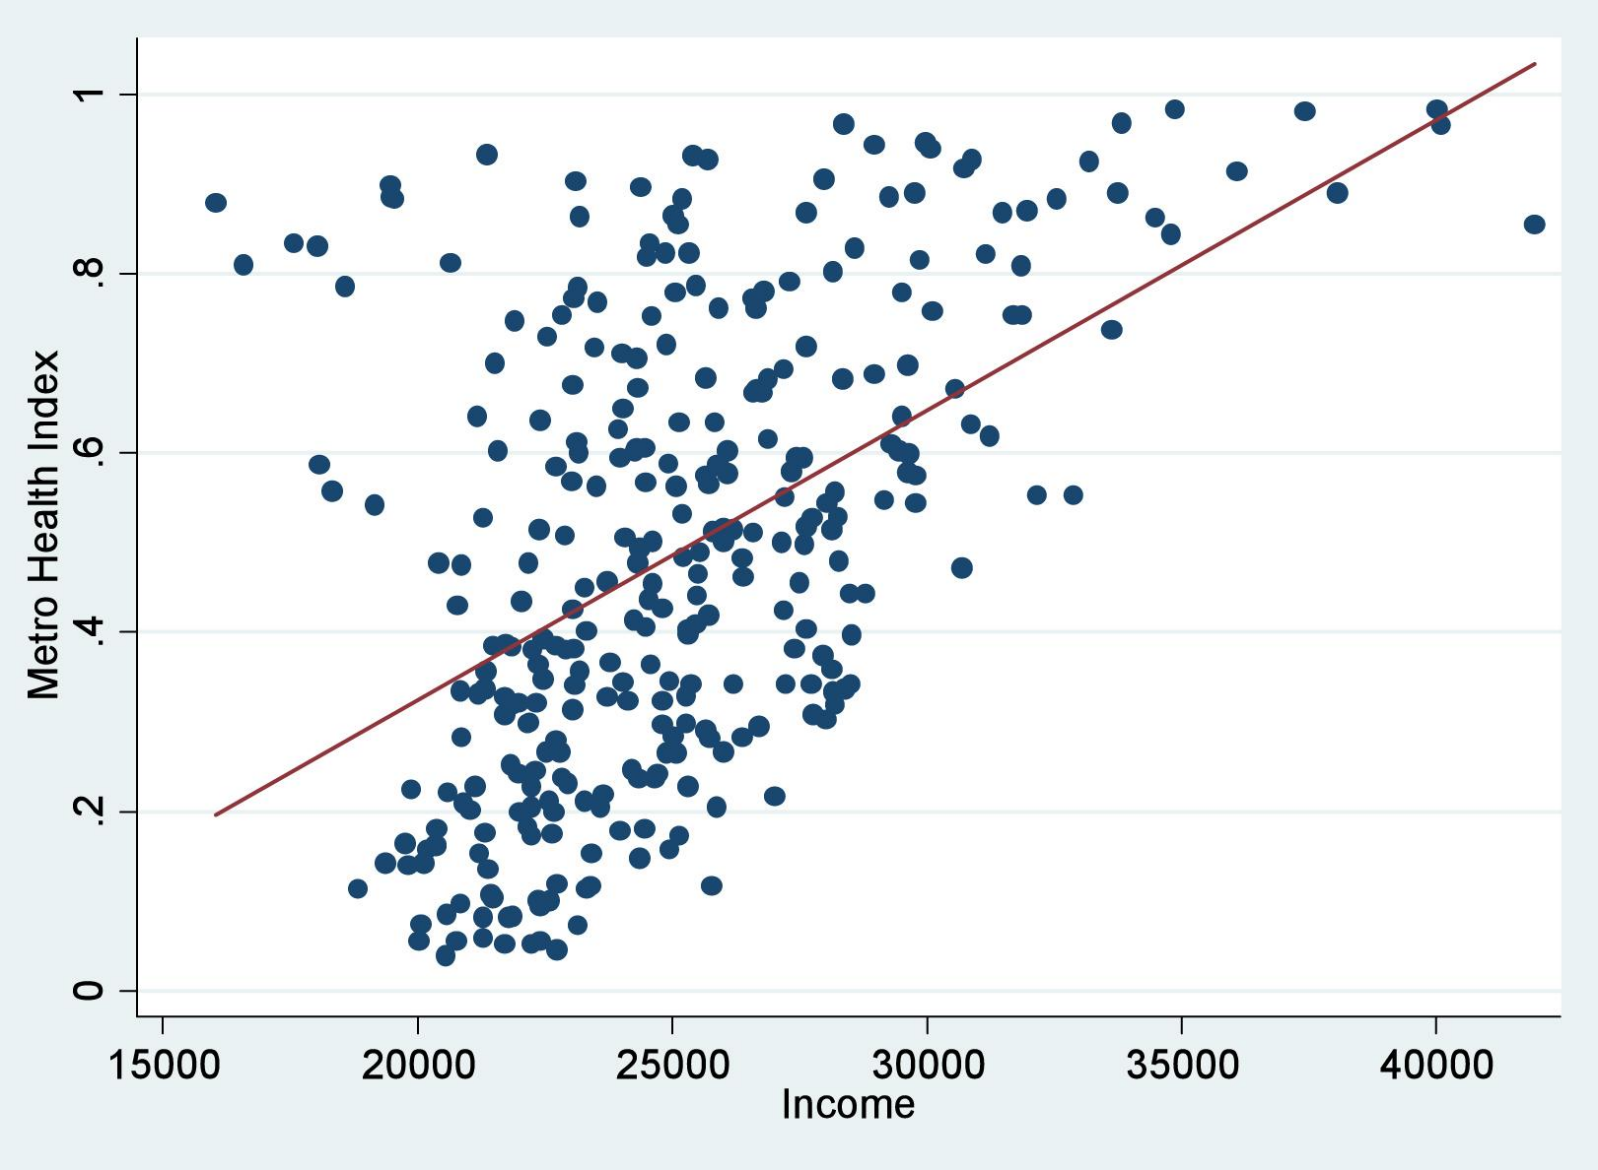
- Gráficos Q-Q (quantil-quantil):
  - Comparam a distribuição empírica dos dados com uma distribuição teórica, geralmente a normal.
  - Se os dados seguirem a distribuição teórica, os pontos no gráfico Q-Q se alinharão em uma linha reta.
  - Desvios da linha reta indicam afastamentos da normalidade.
- Scatterplots (gráficos de dispersão):
  - Mostram a relação entre duas variáveis contínuas, plotando cada observação como um ponto no plano cartesiano.
  - Permitem visualizar a direção (positiva ou negativa), a força (linear ou não linear) e a presença de outliers na relação entre as variáveis.
  - Úteis para verificar a suposição de linearidade na regressão linear e identificar possíveis relações entre variáveis independentes.

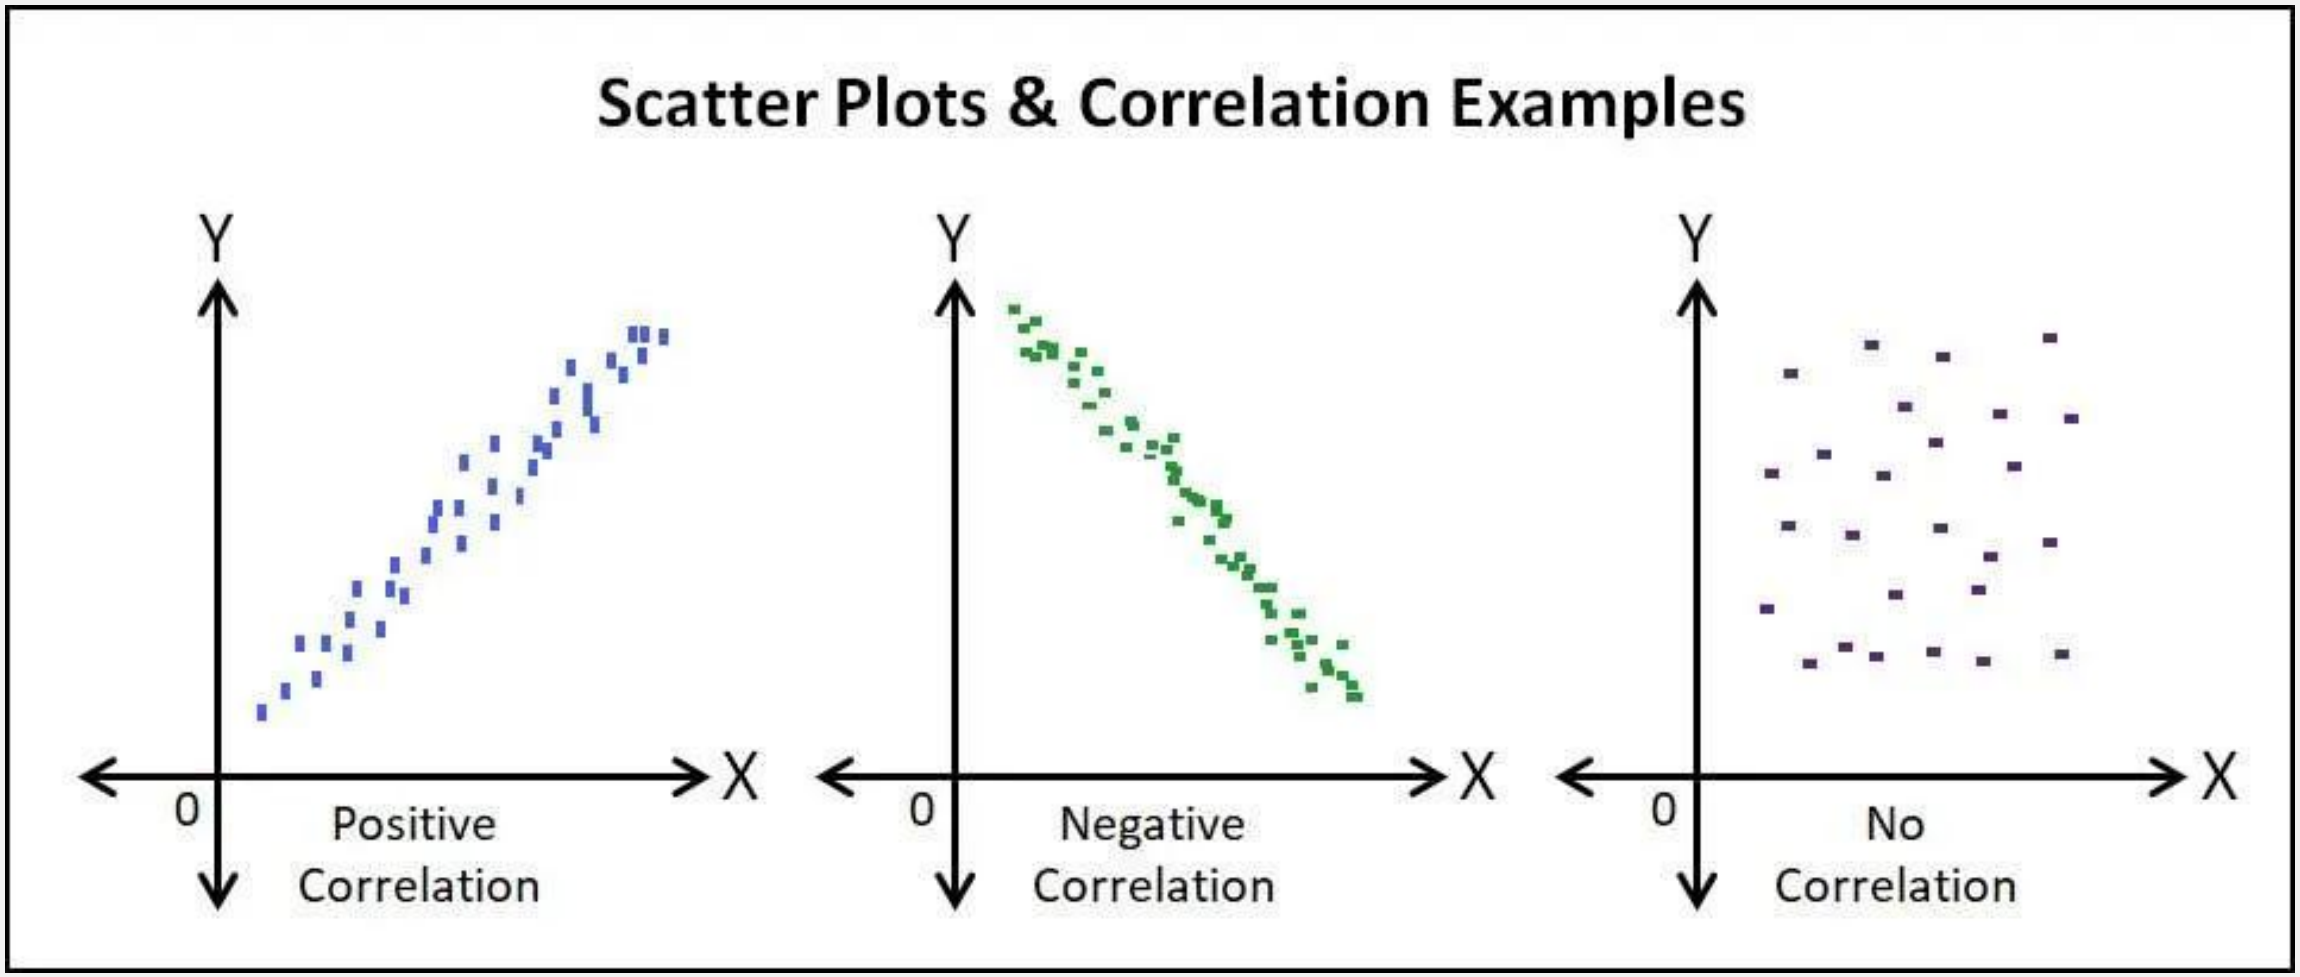

Exponential data quantiles
Normal theoretical quantiles
5
4
3
2
1
0
−3
−2
−1
0
1
2
3

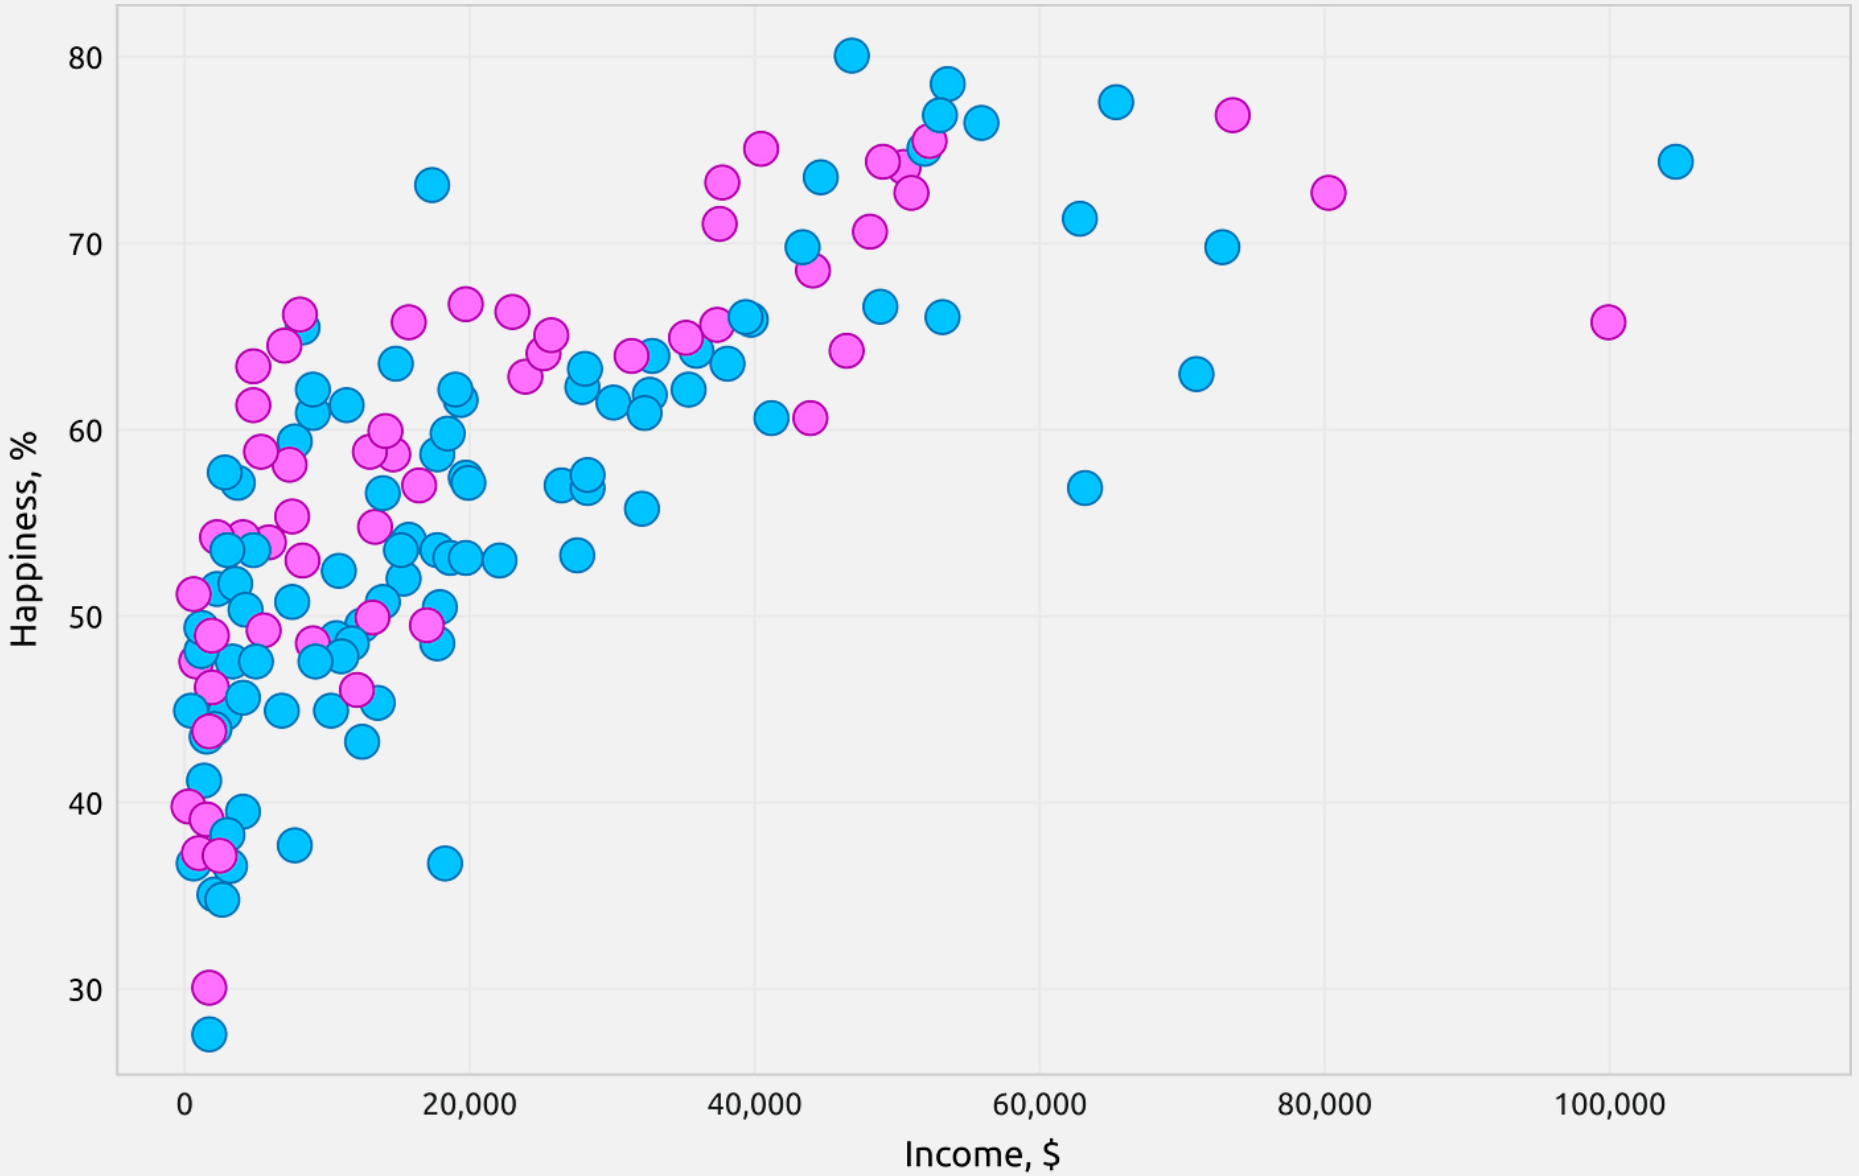

Gráfico quantil-quantil da normal
Quantis observados da amostra
-2
-1
0
1
2
Quantis teóricos da distribuição normal padrão

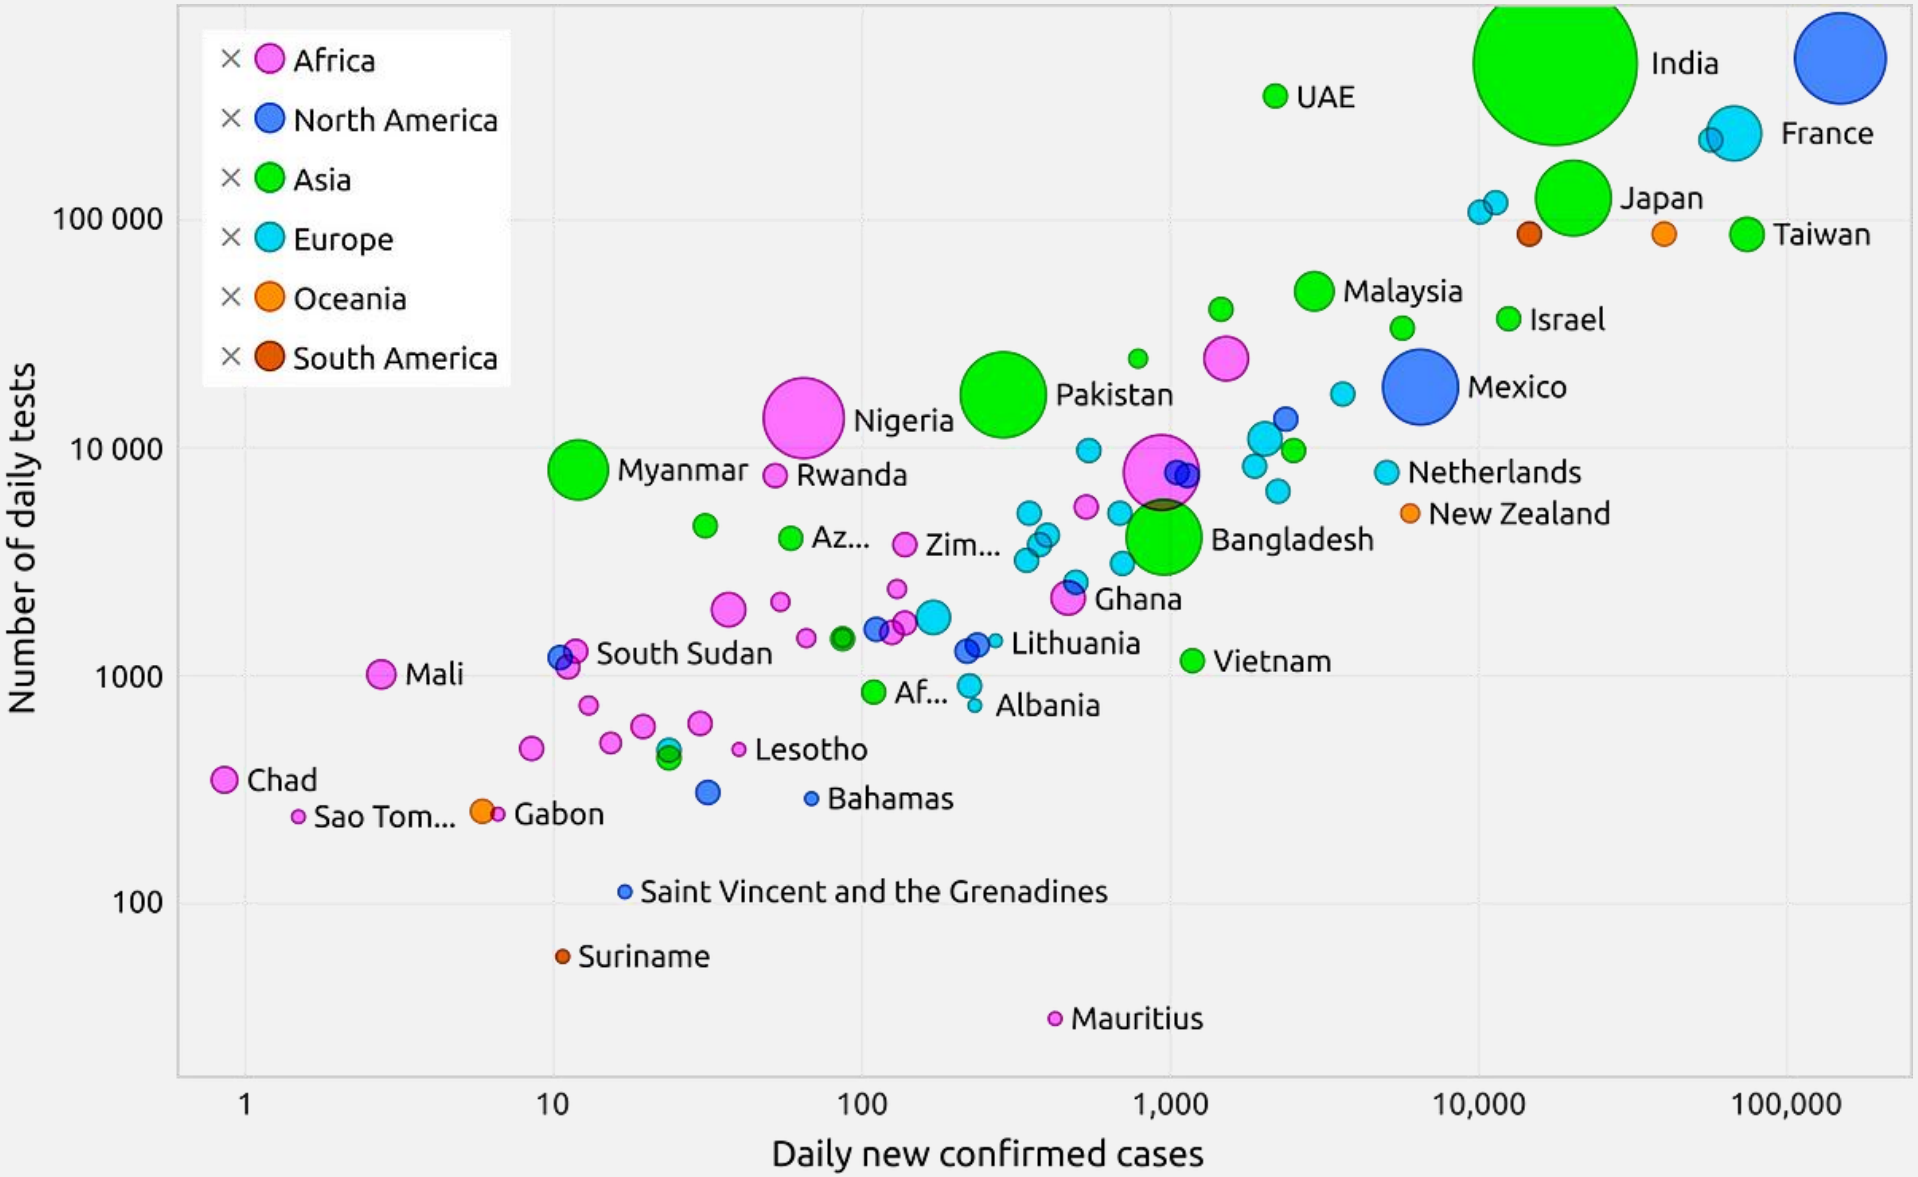

Resíduos
-0.5
0.0
0.5
1.0
-2
-1
0
1
2
Quantis - N


4
3.2
2.4
Height (m)
4
6
8
Diameter (cm)


Metro Health Index
0
.2
.4
.6
.8
1
15000
20000
25000
30000
35000
40000
Income


Scatter Plots & Correlation Examples
Y
X
0
Positive
Correlation
Y
X
0
Negative
Correlation
Y
X
0
No
Correlation


80
70
60
50
40
30
Happiness, %
0
20,000
40,000
60,000
80,000
100,000
Income, $


Africa
North America
Asia
Europe
Oceania
South America
Number of daily tests
100 000
10 000
1000
100
1
10
100
1,000
10,000
100,000
Daily new confirmed cases
India
UAE
France
Japan
Taiwan
Malaysia
Israel
Mexico
Pakistan
Nigeria
Myanmar
Rwanda
Netherlands
New Zealand
Az...
Zim...
Bangladesh
Ghana
Lithuania
Vietnam
South Sudan
Mali
Af...
Albania
Lesotho
Chad
Bahamas
Sao Tom...
Gabon
Saint Vincent and the Grenadines
Suriname
Mauritius


Ground living area partially explains sale price of apartments
Sale price (k$)
600
400
200
0
1000
2000
3000
4000
5000
Ground living area

Data Science

Correlação de Pearson e Covariância

Relação entre Variáveis

- O que estudamos agora
  - Depois de comparar médias de grupos com o teste t, vamos investigar como duas variáveis numéricas se relacionam entre si.
- Exemplos do dia a dia
  - Altura e peso, horas de estudo e nota da prova, temperatura e venda de sorvete.
- Duas perguntas centrais
  - Direção: quando uma variável aumenta, a outra também aumenta (positiva) ou diminui (negativa)?
  - Força: essa relação é forte, fraca ou praticamente inexistente?

Covariância

- O que é?
  - Medida que indica se duas variáveis variam juntas: aumentam juntas, diminuem juntas, ou uma aumenta enquanto a outra diminui.
- Como interpretar o sinal
  - Covariância positiva: as variáveis tendem a aumentar juntas.
  - Covariância negativa: quando uma aumenta, a outra tende a diminuir.
  - Covariância próxima de zero: não há tendência linear clara entre elas.
- Limitação importante
  - O valor depende da escala das variáveis (cm, kg, R$...), por isso é difícil comparar covariâncias de pares diferentes de variáveis.

Coeficiente de Correlação de Pearson (r)

- O que é?
  - Uma versão padronizada da covariância, que sempre varia entre -1 e +1 — por isso é mais fácil de interpretar e comparar.
- Como ler o valor de r
  - r = +1: correlação linear positiva perfeita.
  - r = -1: correlação linear negativa perfeita.
  - r = 0: nenhuma correlação linear entre as variáveis.
- Por que usamos tanto
  - Permite comparar a força de relações entre pares diferentes de variáveis, o que a covariância sozinha não permite.

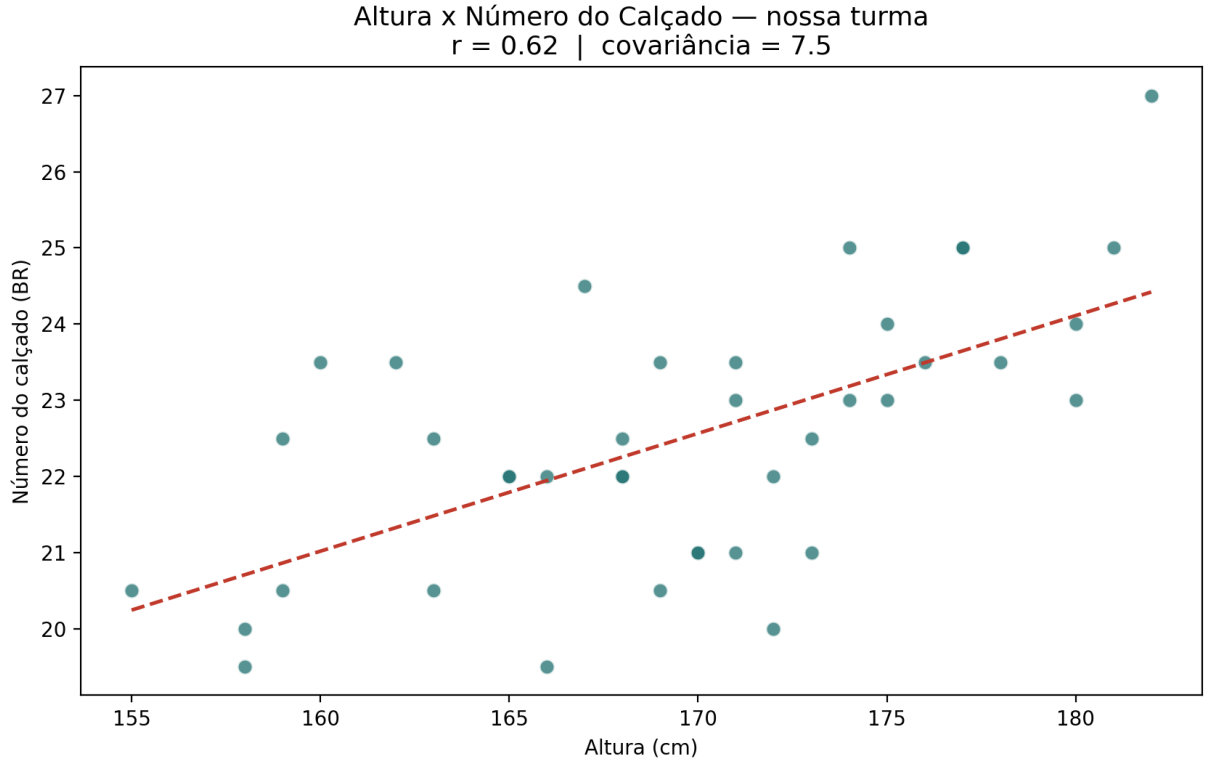
Interpretação da Correlação de Pearson

- Faixas de referência (regra prática)
  - |r| entre 0,7 e 1,0: correlação forte.
  - |r| entre 0,3 e 0,7: correlação moderada.
  - |r| entre 0,0 e 0,3: correlação fraca ou inexistente.
- Cuidado essencial
  - Correlação não implica causalidade: duas variáveis podem estar correlacionadas sem que uma cause a outra.
  - r mede apenas relações lineares — uma relação forte em curva pode ter r próximo de zero.

Dinâmica: Altura Prevê o Número do Calçado?

- O desafio
  - Vamos usar as alturas das duas turmas (Data Science + turma visitante), agora juntas em uma base de 40 pessoas.
  - Também coletamos o número do calçado de cada pessoa.
- Nossa pergunta
  - Existe relação entre a altura de uma pessoa e o número do seu calçado? Ela é forte? É positiva ou negativa?
- Como vamos responder
  - Vamos calcular a covariância e o coeficiente de correlação de Pearson (r) entre as duas variáveis e visualizar num gráfico de dispersão.

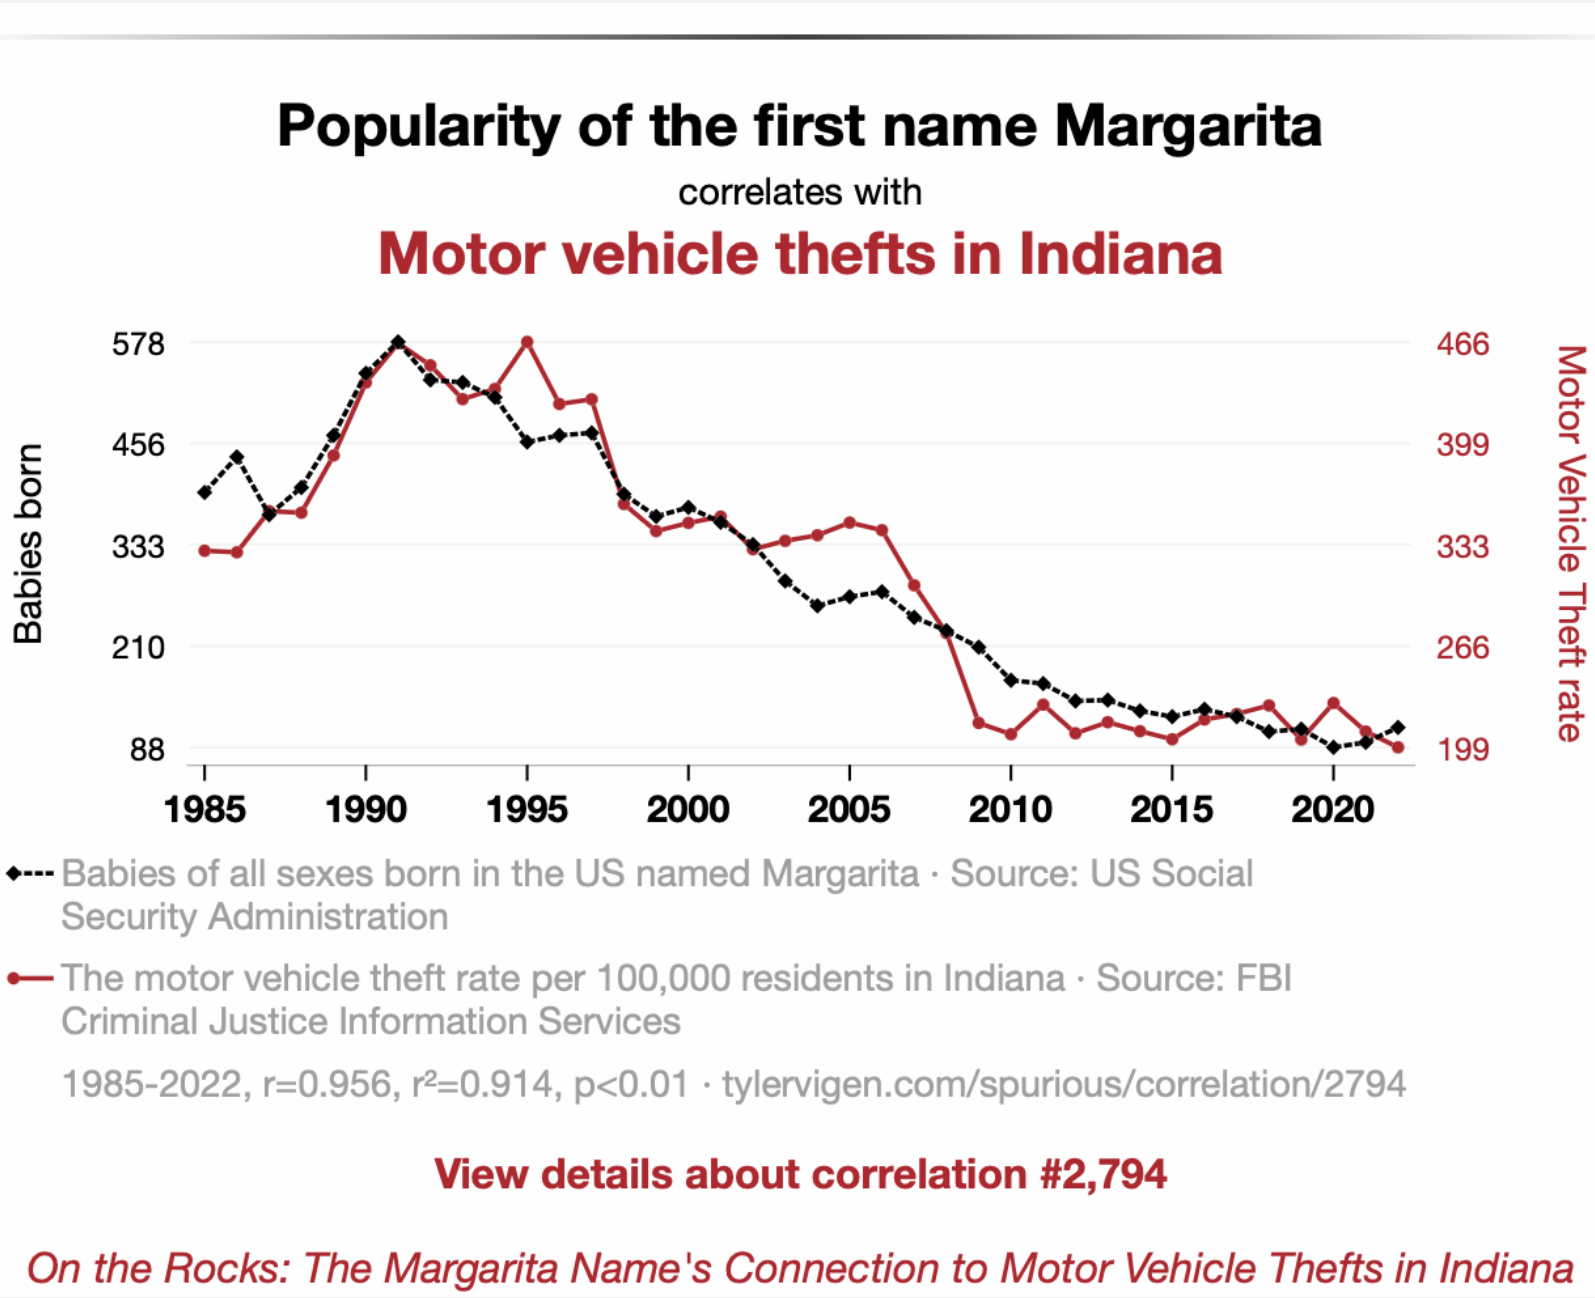
Resultado: Altura x Número do Calçado



r = 0,62 → correlação moderada e positiva: pessoas mais altas tendem a calçar números maiores.

Cuidado: Correlação Não É Causalidade

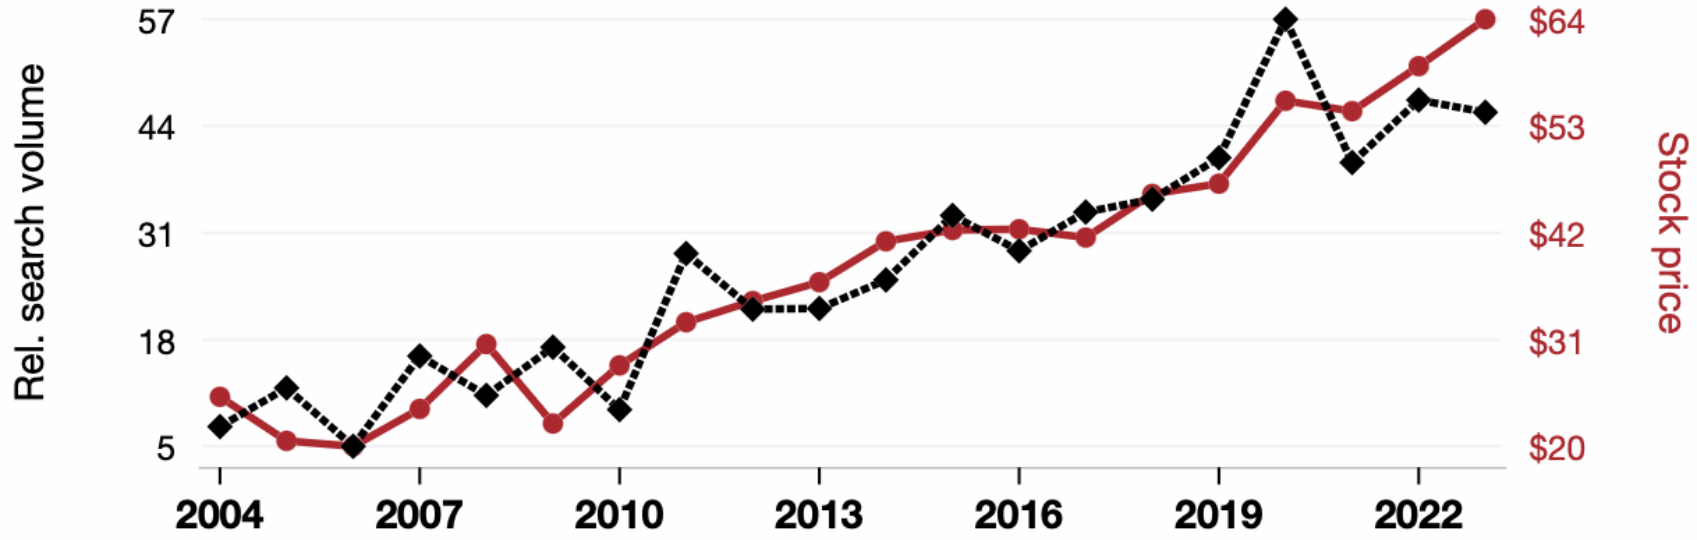
- O site Spurious Correlations
  - tylervigen.com reúne correlações estatisticamente fortes entre variáveis sem nenhuma relação lógica entre si.
- Por que isso acontece
  - Coincidência estatística, uma terceira variável escondida (fator de confusão), ou tendências que crescem juntas ao longo do tempo sem se relacionarem de fato.
- A lição para Data Science
  - Um r alto é só o começo da investigação — sempre pergunte "isso faz sentido no mundo real?" antes de tirar conclusões.


Popularity of the first name Margarita
correlates with
Motor vehicle thefts in Indiana
Babies born
578
456
333
210
88
466
399
333
266
199
Motor Vehicle Theft rate
1985
1990
1995
2000
2005
2010
2015
2020
Babies of all sexes born in the US named Margarita · Source: US Social Security Administration
The motor vehicle theft rate per 100,000 residents in Indiana · Source: FBI Criminal Justice Information Services
1985-2022, r=0.956, r²=0.914, p<0.01 · tylervigen.com/spurious/correlation/2794
View details about correlation #2,794
On the Rocks: The Margarita Name's Connection to Motor Vehicle Thefts in Indiana

Google searches for 'who is jk rowling'

correlates with

The Coca-Cola Company's stock price (KO)



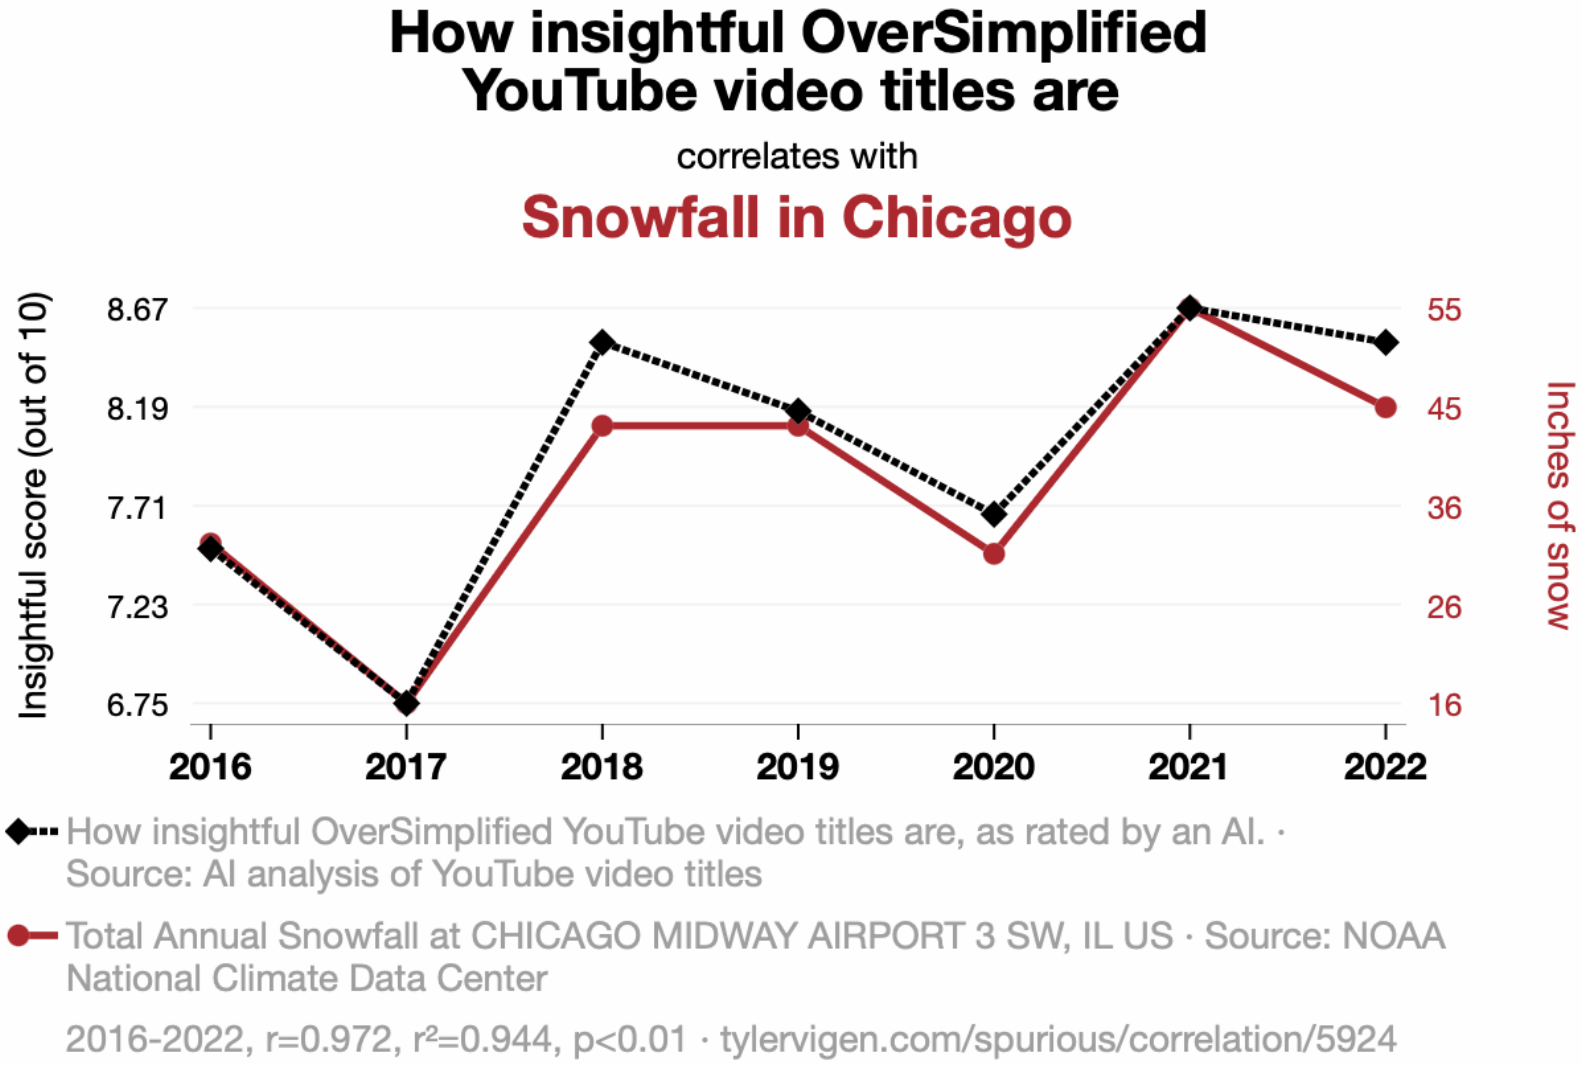
Relative volume of Google searches for 'who is jk rowling' (Worldwide, without quotes) · Source: Google Trends

Opening price of The Coca-Cola Company (KO) on the first trading day of the year · Source: LSEG Analytics (Refinitiv)

2004-2023, r=0.926, r^2=0.857, p<0.01 · tylervigen.com/spurious/correlation/1104

View details about correlation #1,104

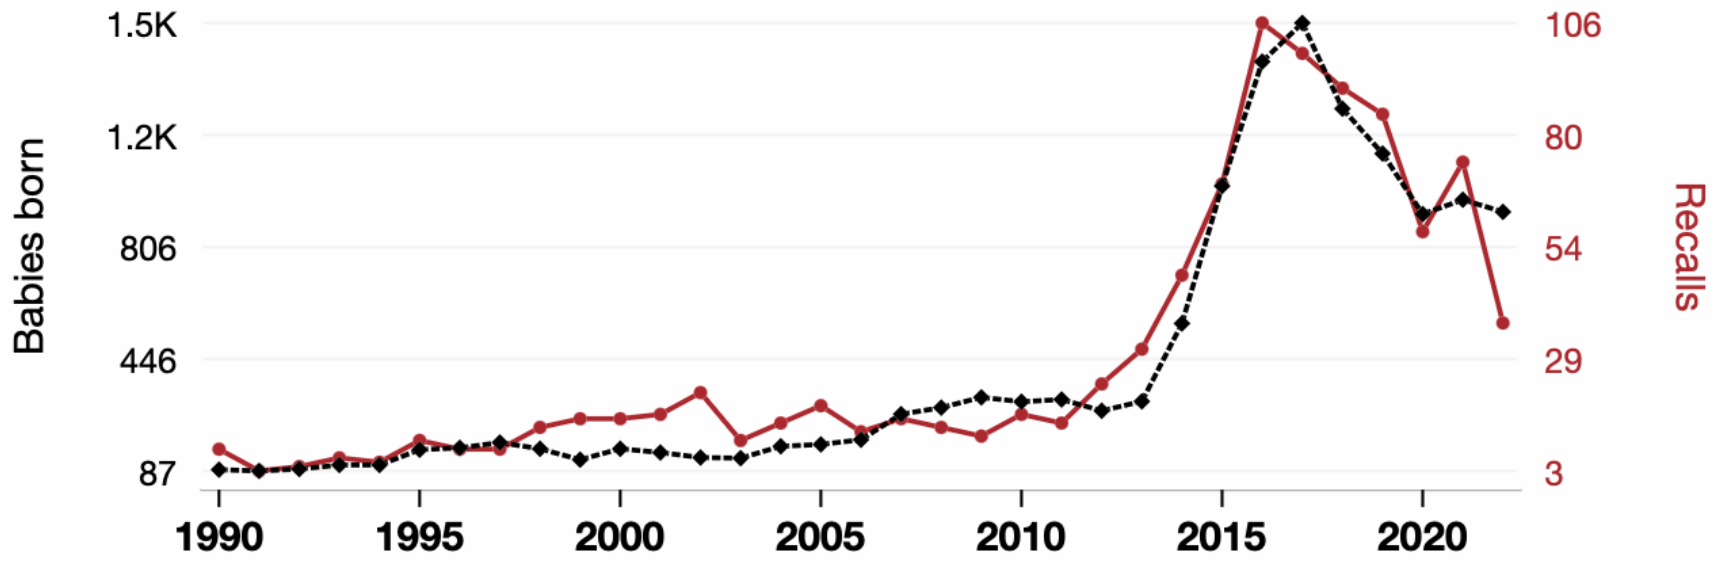
Fizzing Up the Search: The Curious Case of 'Who is J.K. Rowling' and Coca-Cola Stock Prices


How insightful OverSimplified YouTube video titles are
correlates with
Snowfall in Chicago
Insightful score (out of 10)
8.67
8.19
7.71
7.23
6.75
55
45
36
26
16
Inches of snow
2016
2017
2018
2019
2020
2021
2022
How insightful OverSimplified YouTube video titles are, as rated by an AI. · Source: AI analysis of YouTube video titles
Total Annual Snowfall at CHICAGO MIDWAY AIRPORT 3 SW, IL US · Source: NOAA National Climate Data Center
2016-2022, r=0.972, r²=0.944, p<0.01 · tylervigen.com/spurious/correlation/5924
View details about correlation #5,924
SnowWay! The Chilling Influence of OverSimplified YouTube Video Titles on Snowfall i
Chicago

Popularity of the first name Killian

correlates with

Automotive recalls for issues with the Air Bags



Babies of all sexes born in the US named Killian · Source: US Social Security Administration

Automotive recalls for issues with the Air Bags · Source: US DOT

1990-2022, r=0.969, r^2=0.939, p<0.01 · tylervigen.com/spurious/correlation/2599

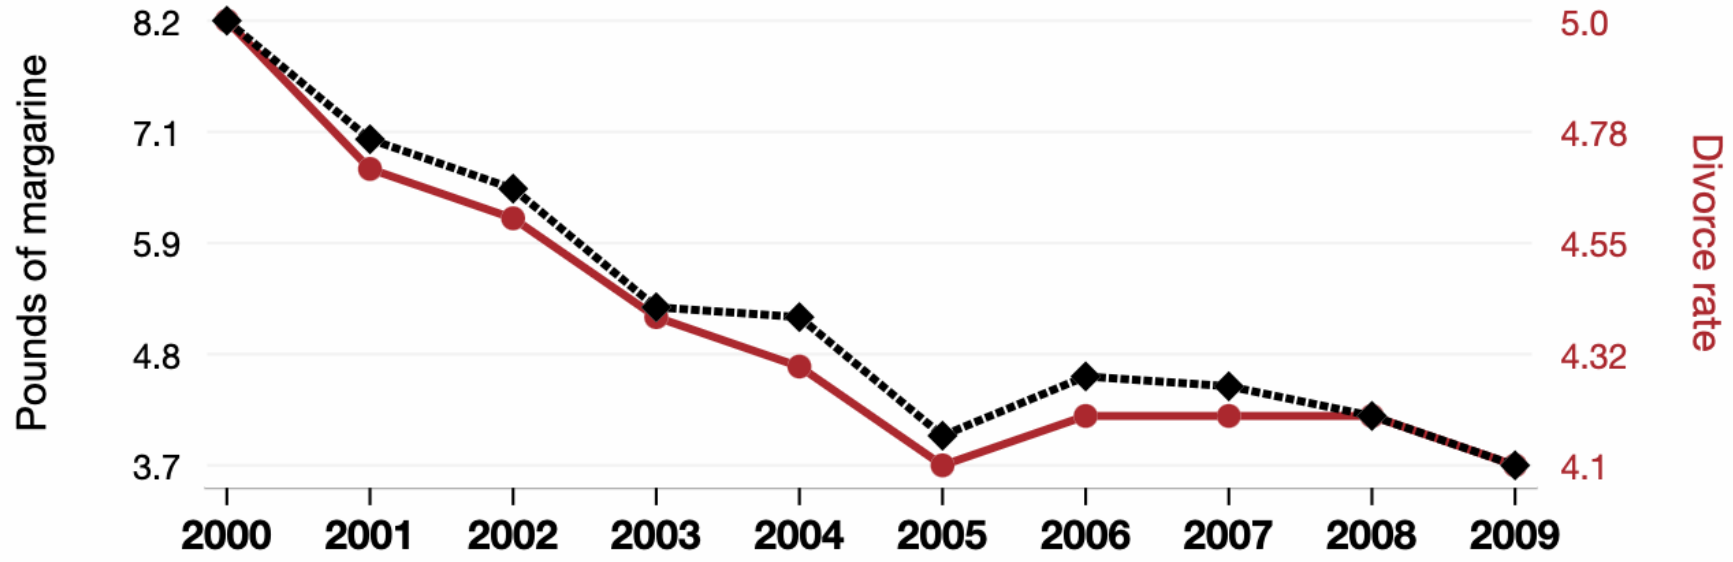
View details about correlation #2,599

The Air Bag Flair and the Name Affair: Exploring the Correlation Between Killian and Recalls

Per capita consumption of margarine

correlates with

The divorce rate in Maine



Per capita consumption of margarine in the United States · Source: US Department of Agriculture

The divorce rate in Maine · Source: CDC National Vital Statistics

2000-2009, r=0.993, r^2=0.985, p<0.01 · tylervigen.com/spurious/correlation/5920

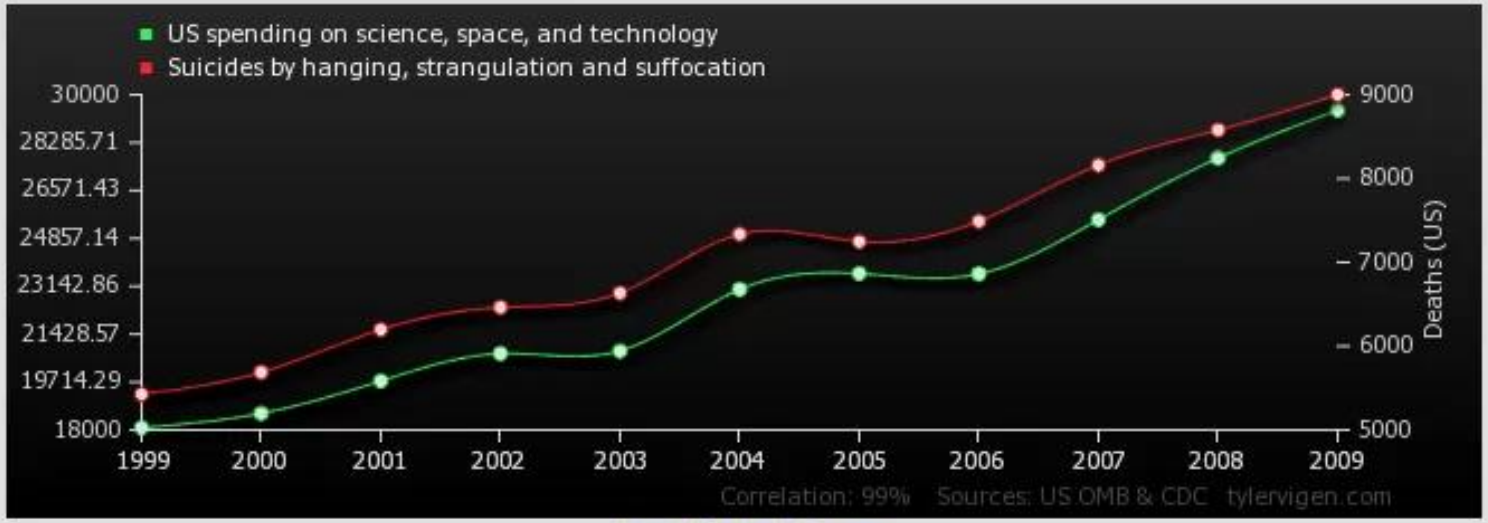
View details about correlation #5,920

Spreading Love and Margarine: An Examination of the Butter-Splitter Correlation in Maine

US spending on science, space, and technology

correlates with

Suicides by hanging, strangulation and suffocation



Upload this chart to imgur

	1999	2000	2001	2002	2003	2004	2005	2006	2007	2008	2009
US spending on science, space, and technology *Millions of todays dollars (US OMB)*	18,079	18,594	19,753	20,734	20,831	23,029	23,597	23,584	25,525	27,731	29,449
Suicides by hanging, strangulation and suffocation *Deaths (US) (CDC)*	5,427	5,688	6,198	6,462	6,635	7,336	7,248	7,491	8,161	8,578	9,000

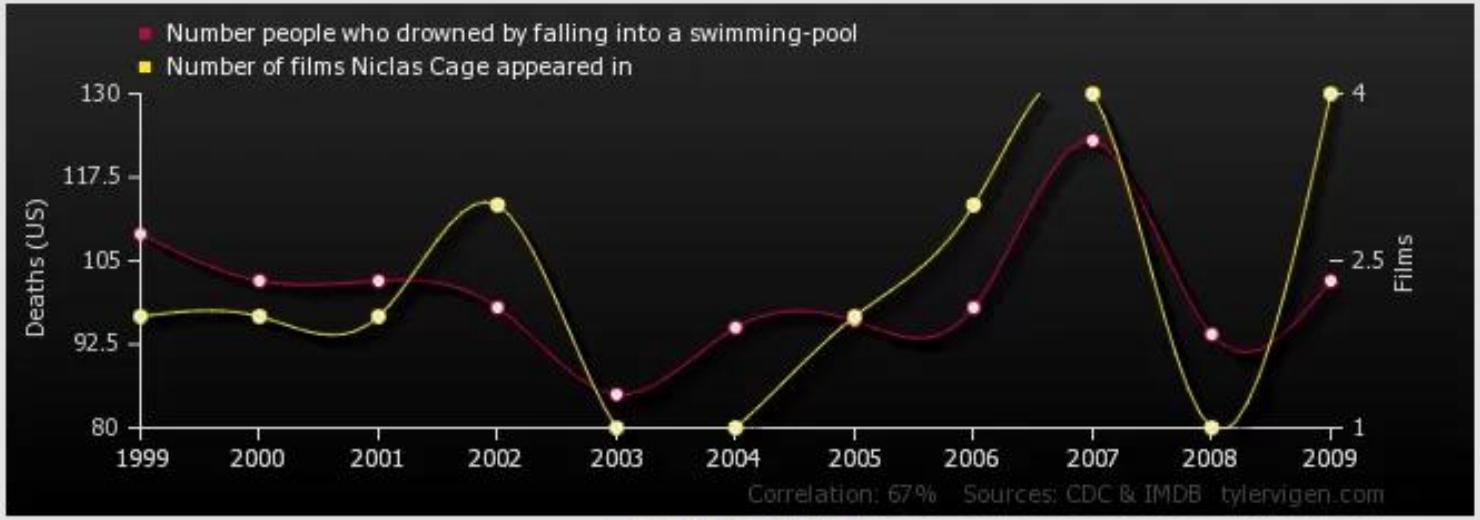
Correlation: 0.992082

Permalink - Mark as interesting - Not interesting

Number people who drowned by falling into a swimming-pool

correlates with

Number of films Nicolas Cage appeared in



Upload this chart to imgur

	1999	2000	2001	2002	2003	2004	2005	2006	2007	2008	2009
Number people who drowned by falling into a swimming-pool *Deaths (US) (CDC)*	109	102	102	98	85	95	96	98	123	94	102
Number of films Nicolas Cage appeared in *Films (IMDB)*	2	2	2	3	1	1	2	3	4	1	4

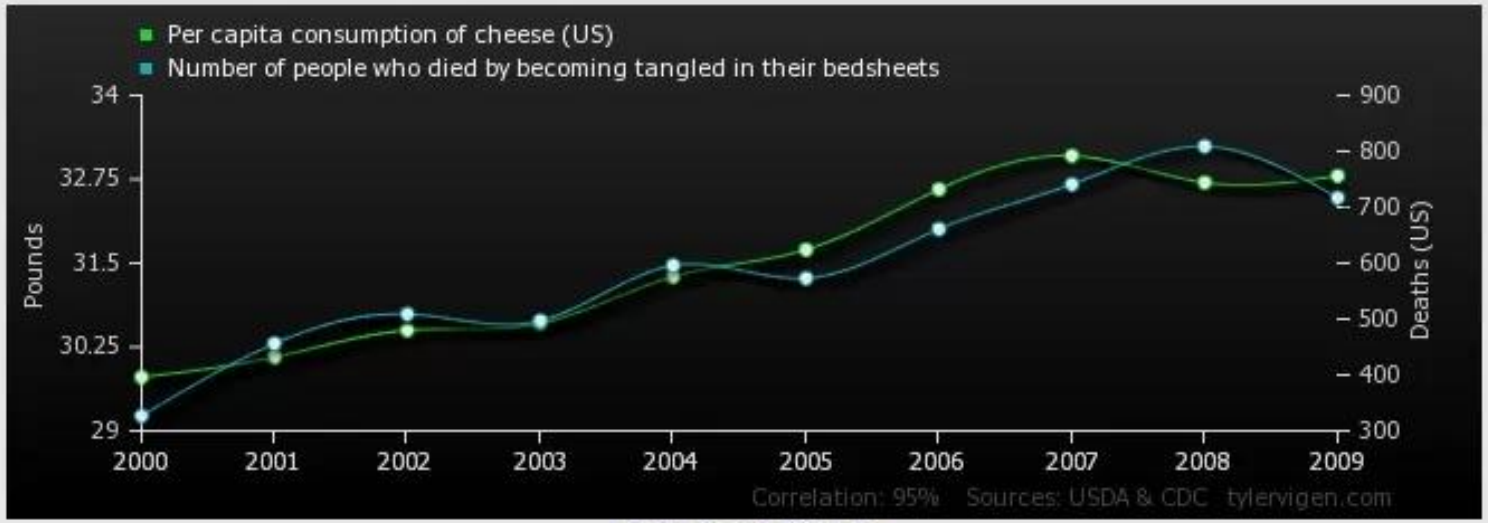
Correlation: 0.666004

Permalink - Mark as interesting - Not interesting

Per capita consumption of cheese (US)

correlates with

Number of people who died by becoming tangled in their bedsheets



Upload this chart to imgur

	2000	2001	2002	2003	2004	2005	2006	2007	2008	2009
Per capita consumption of cheese (US) *Pounds (USDA)*	29.8	30.1	30.5	30.6	31.3	31.7	32.6	33.1	32.7	32.8
Number of people who died by becoming tangled in their bedsheets *Deaths (US) (CDC)*	327	456	509	497	596	573	661	741	809	717

Correlation: 0.947091

Permalink - Mark as interesting - Not interesting

Aplicações em Data Science

- Nos negócios
  - Identificar quais variáveis influenciam vendas, churn de clientes ou desempenho de campanhas de marketing.
- Nos modelos preditivos
  - A correlação ajuda a escolher quais variáveis (features) fazem sentido incluir em um modelo de machine learning.
- Na ciência e na saúde
  - Investigar relações entre hábitos, exposições e desfechos — sempre com cautela para não confundir correlação com causa.

Limitações e Cuidados com a Correlação de Pearson

- Só mede relações lineares
  - Relações em forma de curva podem ter r baixo mesmo sendo relações fortes.
- É sensível a outliers
  - Um único valor extremo pode inflar ou distorcer bastante o valor de r.
- Correlação ≠ causalidade
  - Sempre existe a possibilidade de uma terceira variável explicar a relação observada.

Prática: Explore Você Mesmo

- Bases sugeridas no Kaggle
  - Titanic: kaggle.com/c/titanic
  - Iris: kaggle.com/datasets/uciml/iris
- O que fazer
  - Calcule a correlação de Pearson entre pares de variáveis numéricas dessas bases e visualize com gráficos de dispersão.
  - Pergunte-se: os resultados fazem sentido? Existe alguma correlação espúria escondida ali?

Revisão Relâmpago 1: LGPD, Amostragem e Medidas Centrais

- LGPD
  - Dado sensível: inclui dados de saúde e dados biométricos, entre outros.
  - Titular: a pessoa física a quem os dados se referem.
- Amostragem e Inferência
  - Usar uma amostra para generalizar conclusões sobre toda a população.
- Tendência central x dispersão
  - Mediana e moda são mais indicadas que a média quando há outliers (ex: salários).
  - Dispersão: variância, desvio padrão e amplitude medem o quanto os dados se espalham.

Revisão Relâmpago 2: Distribuições

- Distribuição de frequências
  - Organiza dados brutos em classes (intervalos) e conta quantos valores caem em cada uma — a Regra de Sturges ajuda a decidir o número de classes.
- Distribuição normal
  - Distribuição simétrica em forma de sino, onde média, mediana e moda coincidem no centro.
  - Exemplos reais: alturas de uma população, erros de medição, notas de uma turma grande.

Revisão Relâmpago 3: Quartis e Boxplot

- Quartis
  - Q1 (25%), Q2/mediana (50%) e Q3 (75%) dos dados estão abaixo desses pontos.
- Boxplot
  - Mostra Q1, mediana (Q2), Q3, os bigodes (limites) e os outliers (pontos fora dos limites).
  - IQR (intervalo interquartil) = Q3 − Q1, usado para calcular os limites e identificar outliers.