

Universidade POSITIVO

Data Science

Prof.: MSc. Alex Junior Nunes

pfsalexnunes@gmail.com

Data Science

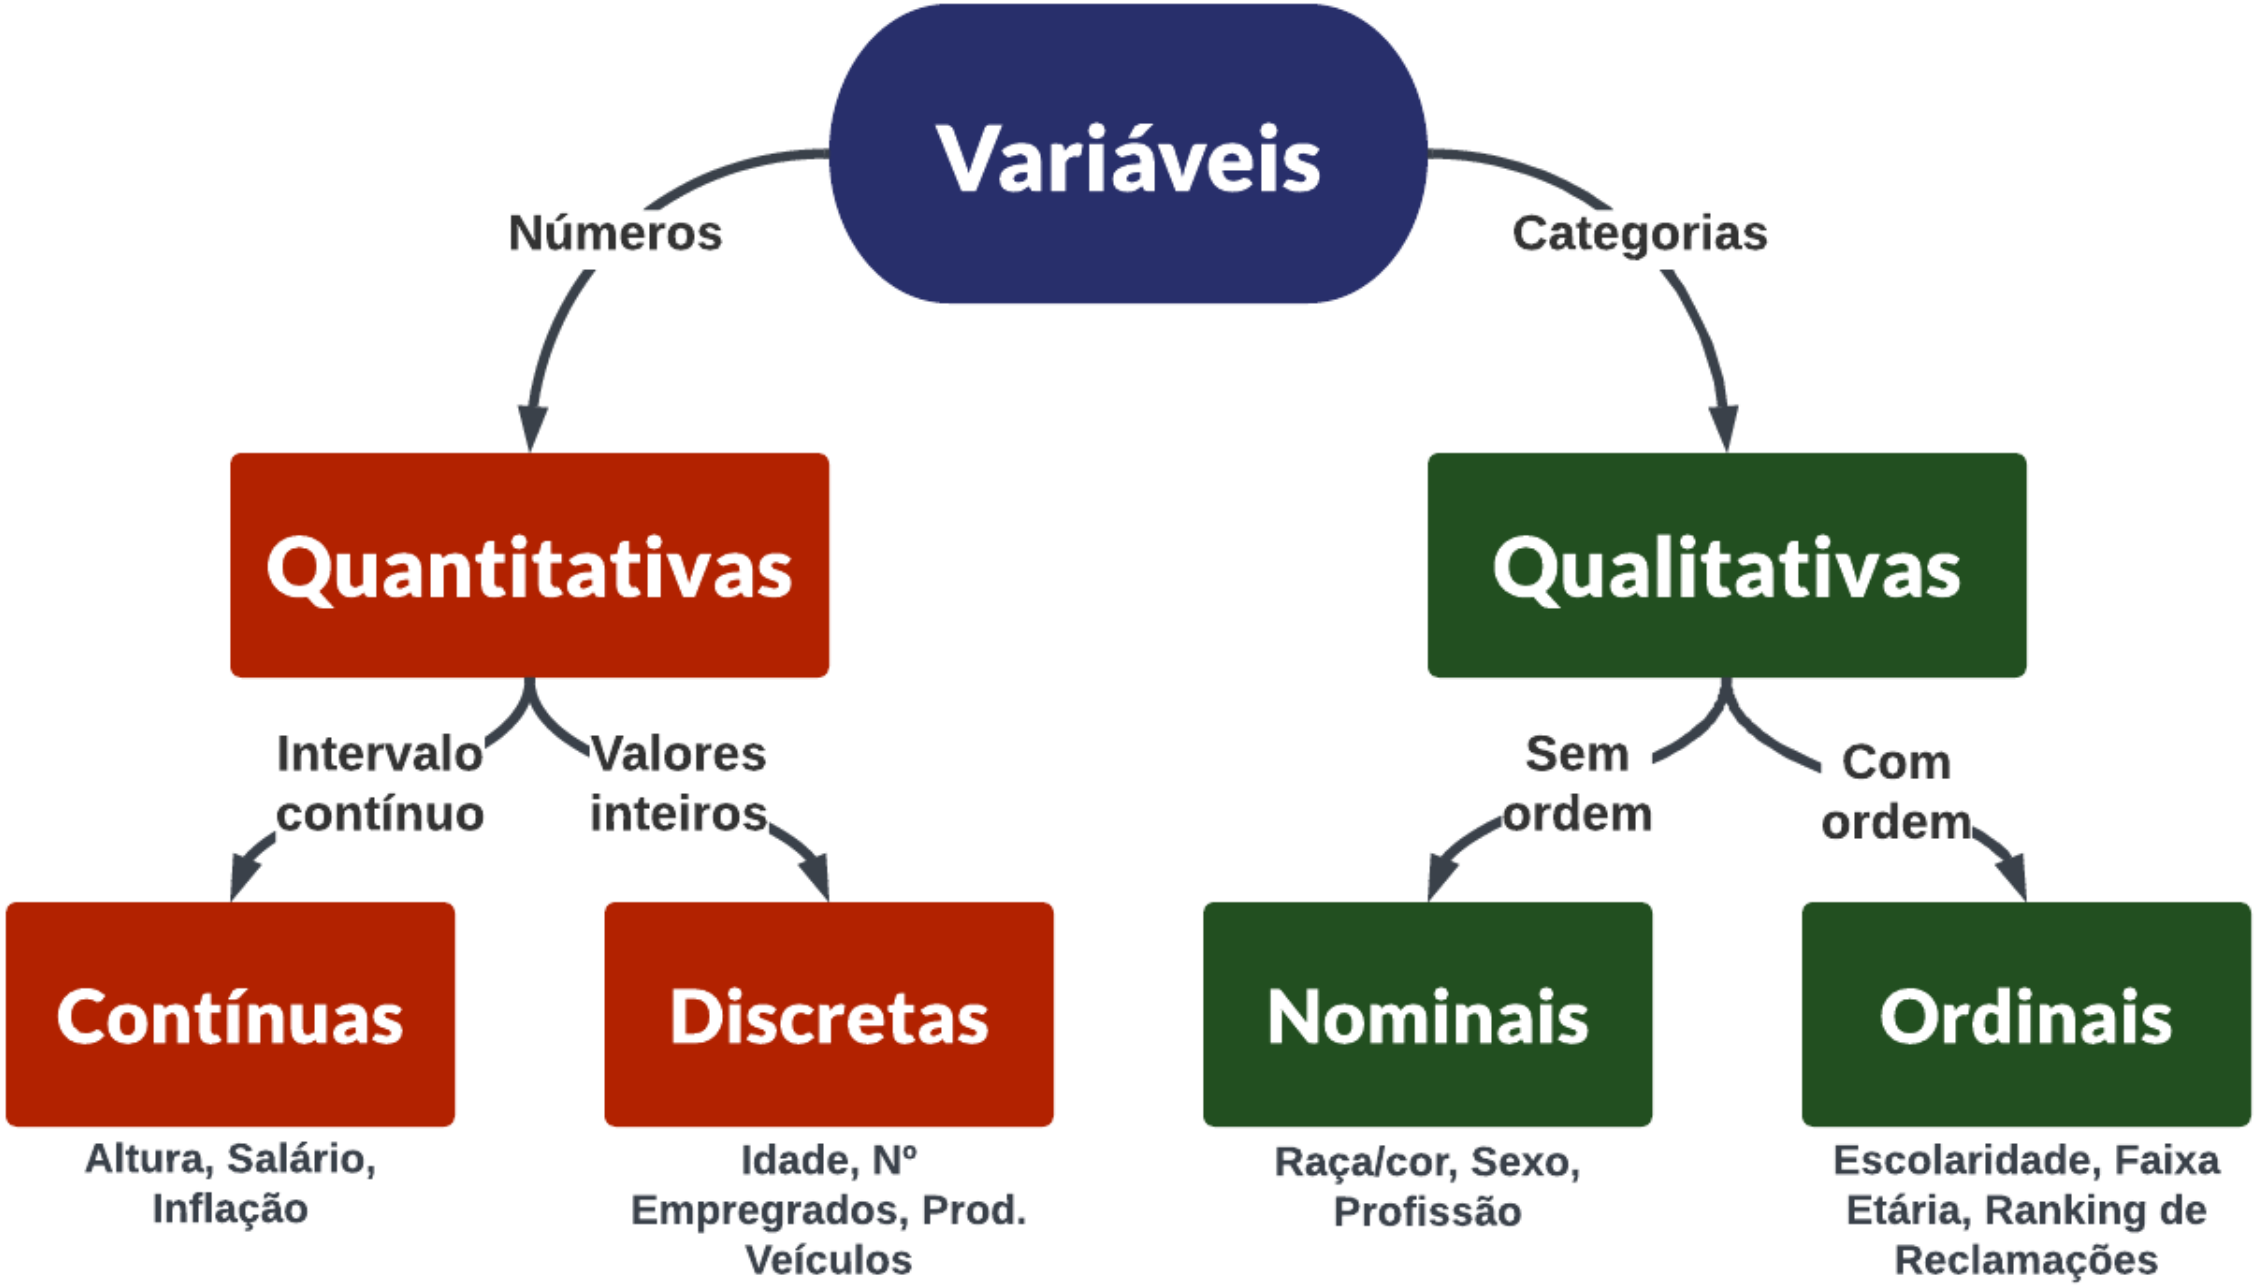
Modelos Lineares Generalizados - GLM

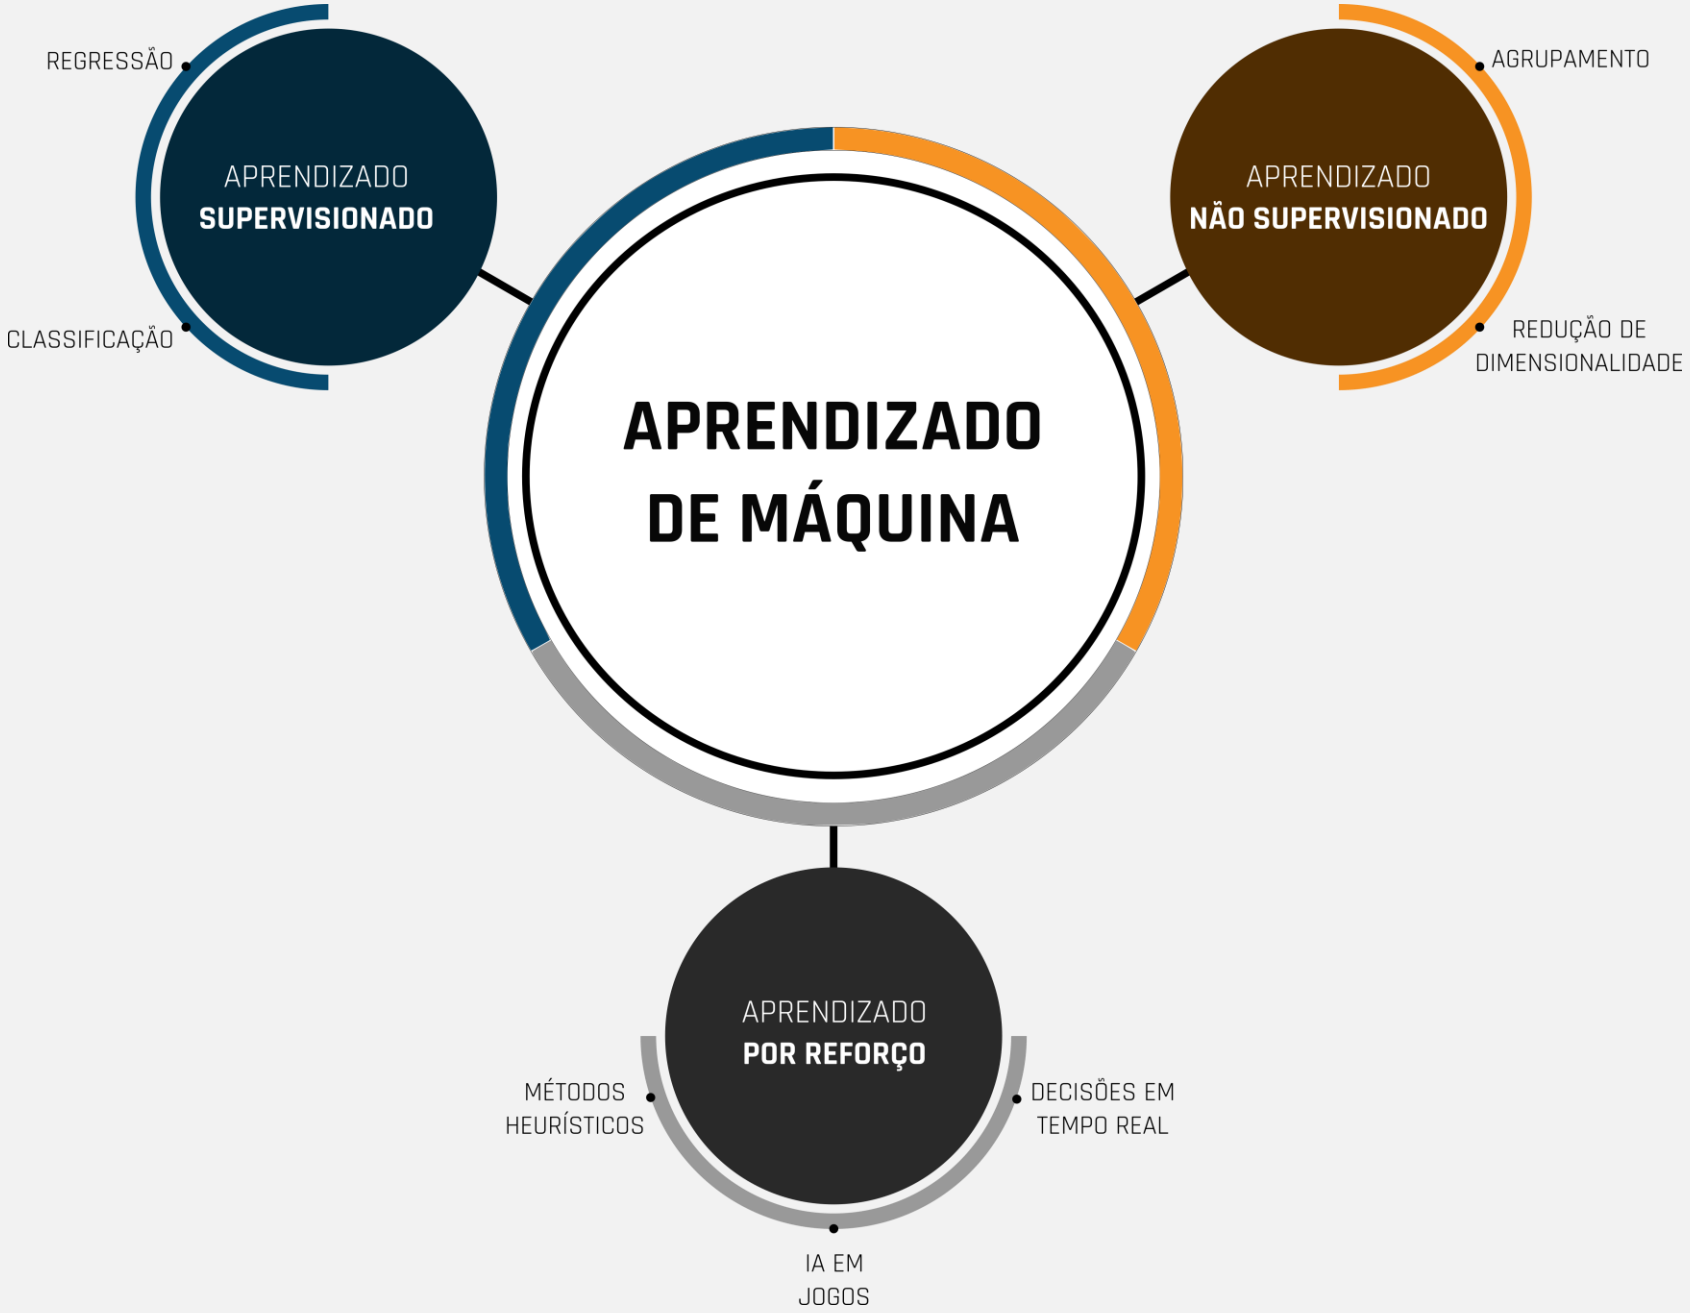
Modelos Lineares Generalizados - GLM

Abrindo a caixa preta



Relembrando alguns termos


Variáveis
Números
Categorias
Quantitativas
Qualitativas
Intervalo contínuo
Valores inteiros
Sem ordem
Com ordem
Contínuas
Discretas
Nominais
Ordinais
Altura, Salário, Inflação
Idade, Nº Empregados, Prod. Veículos
Raça/cor, Sexo, Profissão
Escolaridade, Faixa Etária, Ranking de Reclamações


REGRESSÃO
APRENDIZADO
SUPERVISIONADO
CLASSIFICAÇÃO
AGRUPAMENTO
APRENDIZADO
NÃO SUPERVISIONADO
REDUÇÃO DE
DIMENSIONALIDADE
APRENDIZADO
DE MÁQUINA
APRENDIZADO
POR REFORÇO
MÉTODOS
HEURÍSTICOS
DECISÕES EM
TEMPO REAL
IA EM
JOGOS

Aprendizado supervisionado

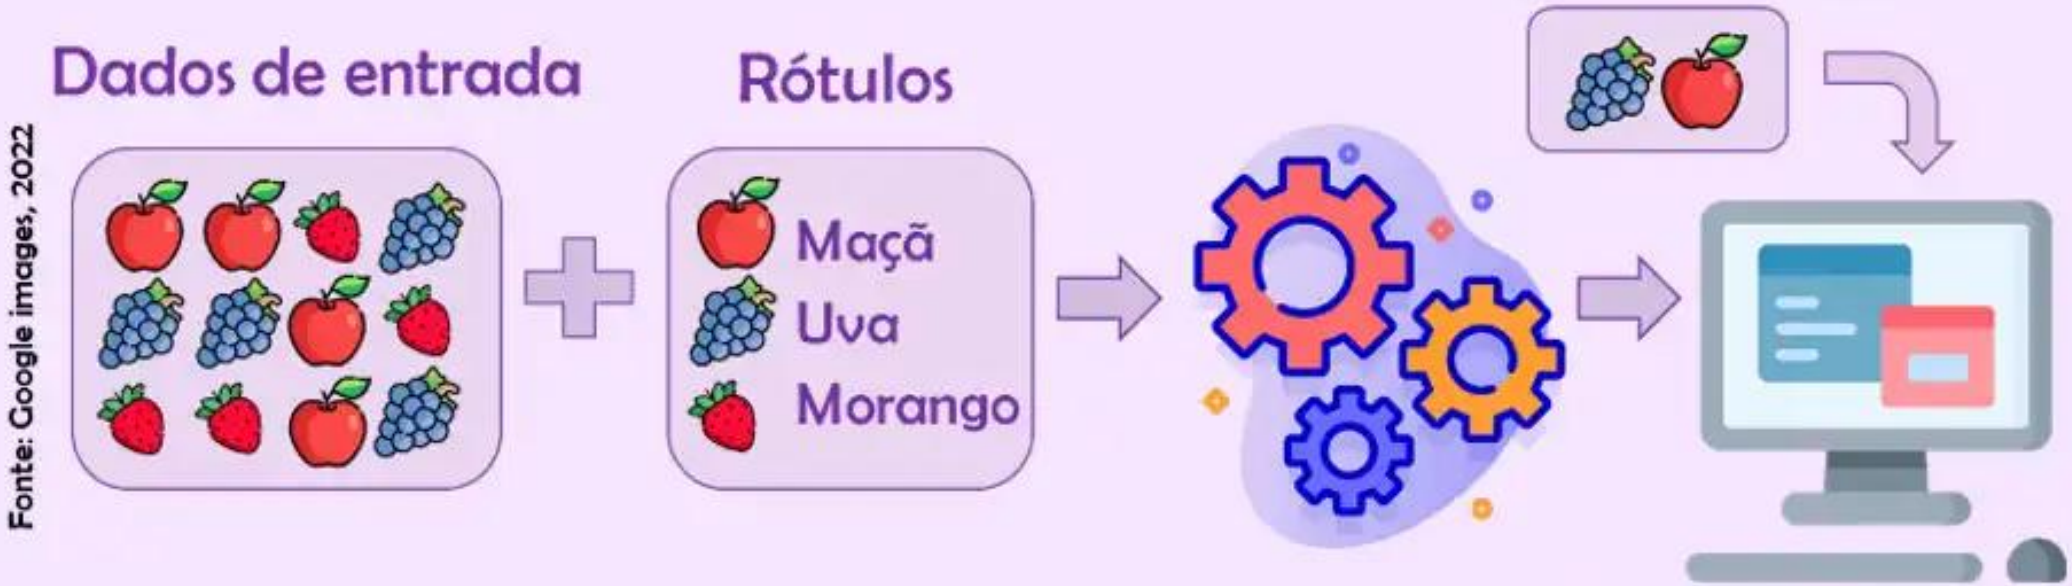
Experiência adquirida:

Dados de entrada

Rótulos

Maçã
Uva
Morango

Dados de teste
(não rotulados)



Fonte: Google images, 2022

Predição

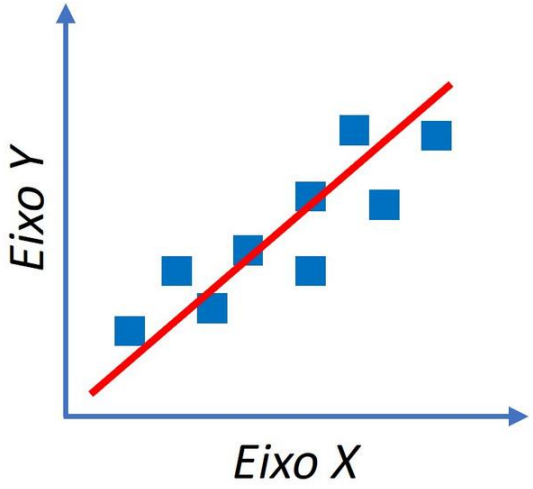
Uva Maçã

- Predição: tolerância à estresses abióticos e bióticos;
- Produtividade;
- Potencial: futuras cultivares.

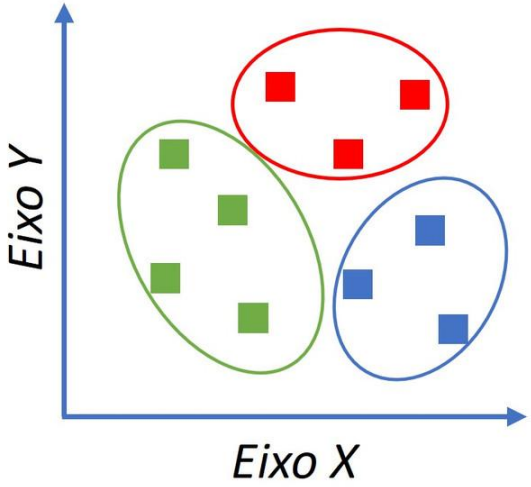
(MOHRI *et al.*, 2018; PARMLEY *et al.*, 2019; RAD & RAFEZI, 2020; JO, 2021)

TIPOS DE APRENDIZADO DE MACHINE LEARNING

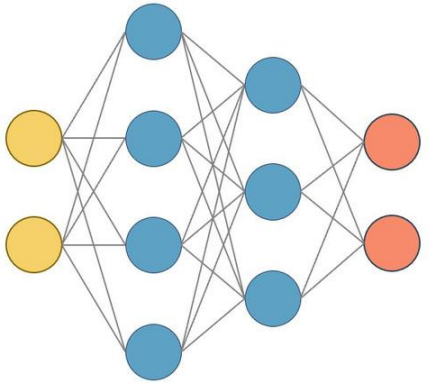
Aprendizado Supervisionado



Aprendizado Não Supervisionado

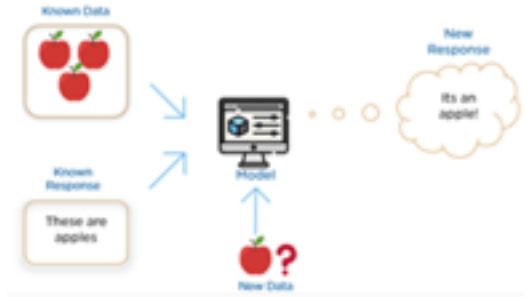


Aprendizado por Reforço



1

Supervisionado



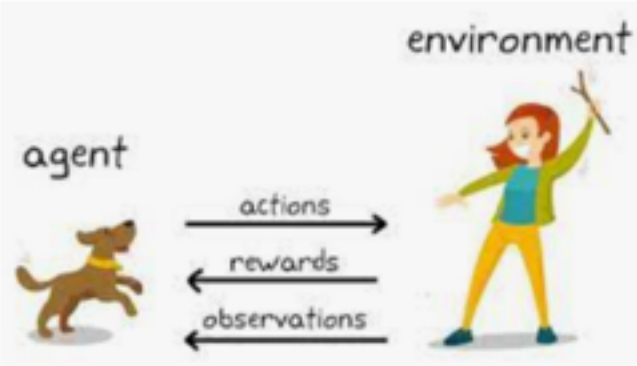
2

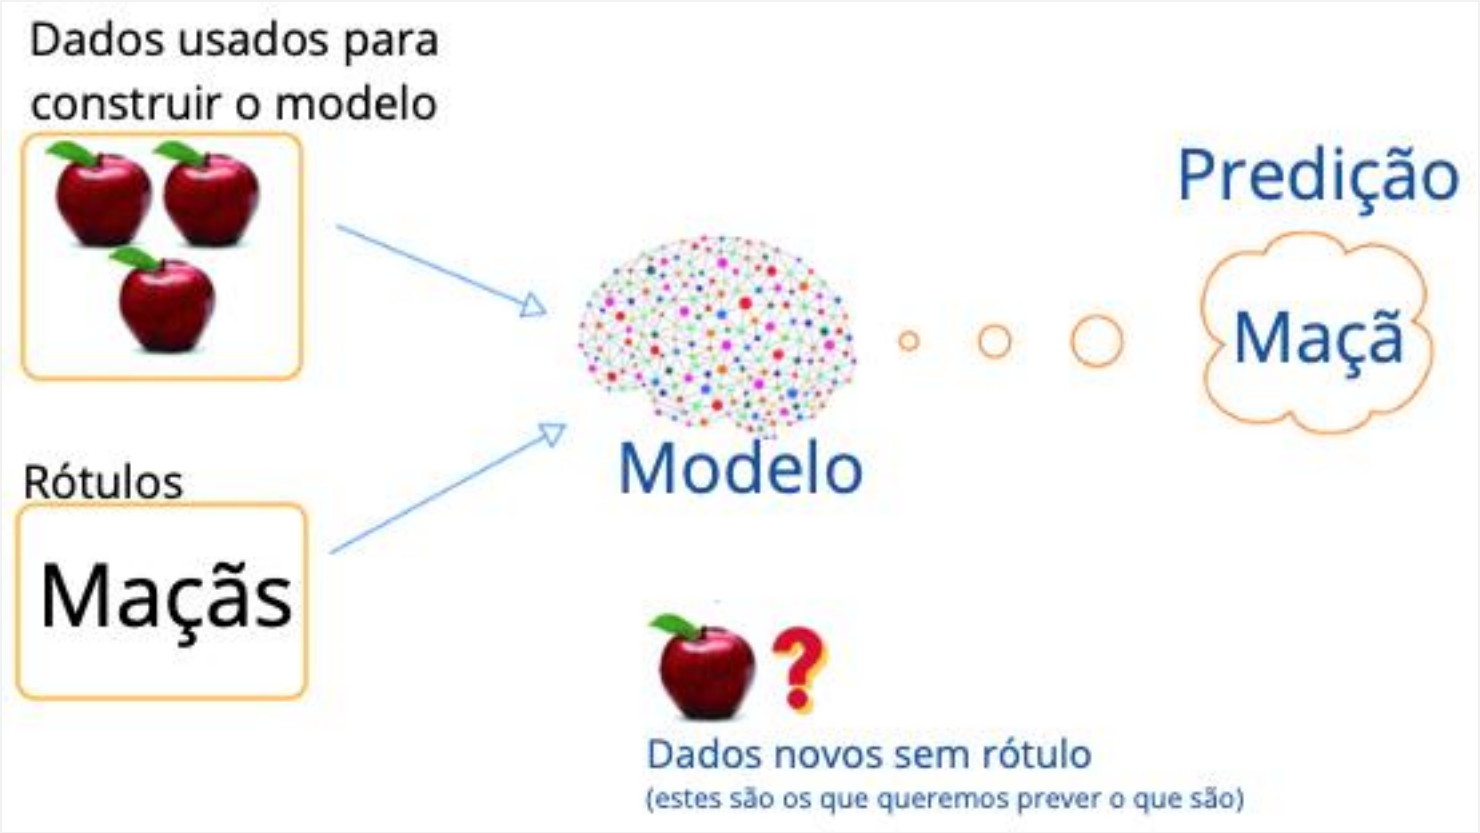
Não Supervisionado



3

Por Reforço



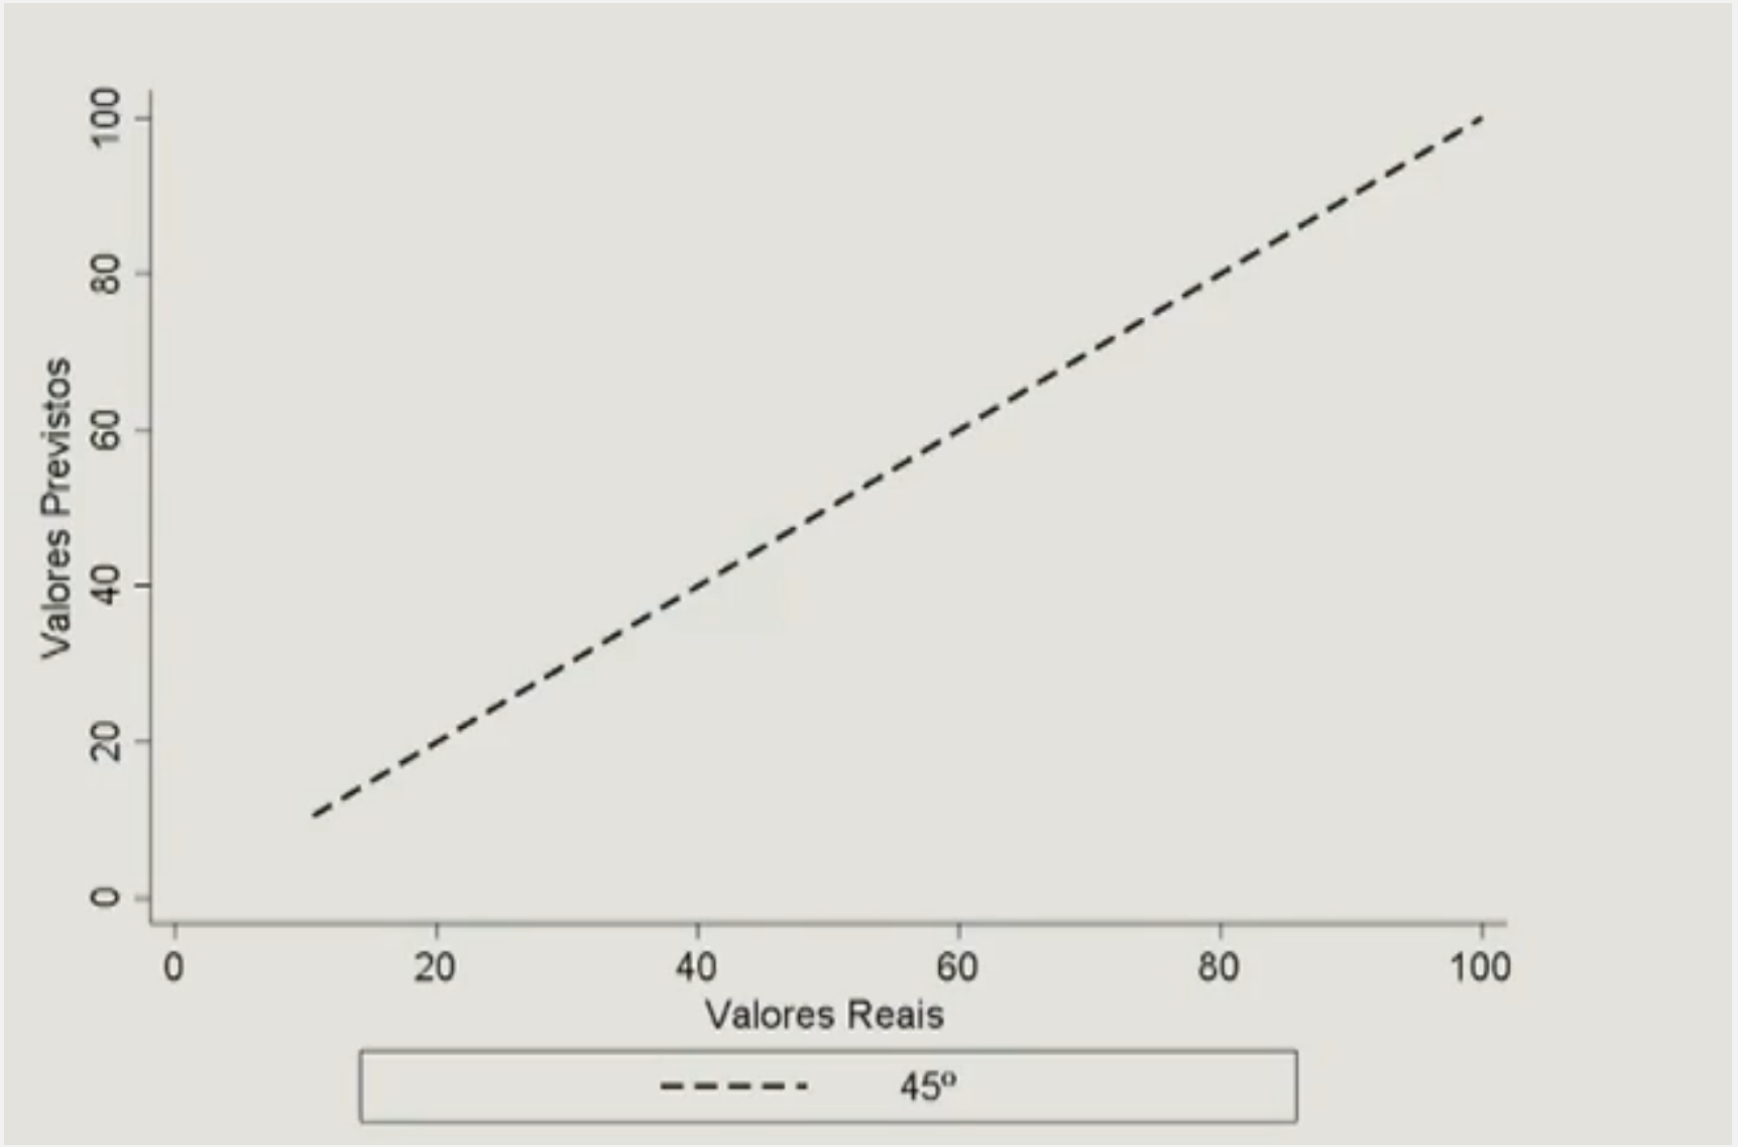

Dados usados para
construir o modelo
Rótulos
Maçãs
Modelo
Predição
Maçã
Dados novos sem rótulo
(estes são os que queremos prever o que são)


Livra

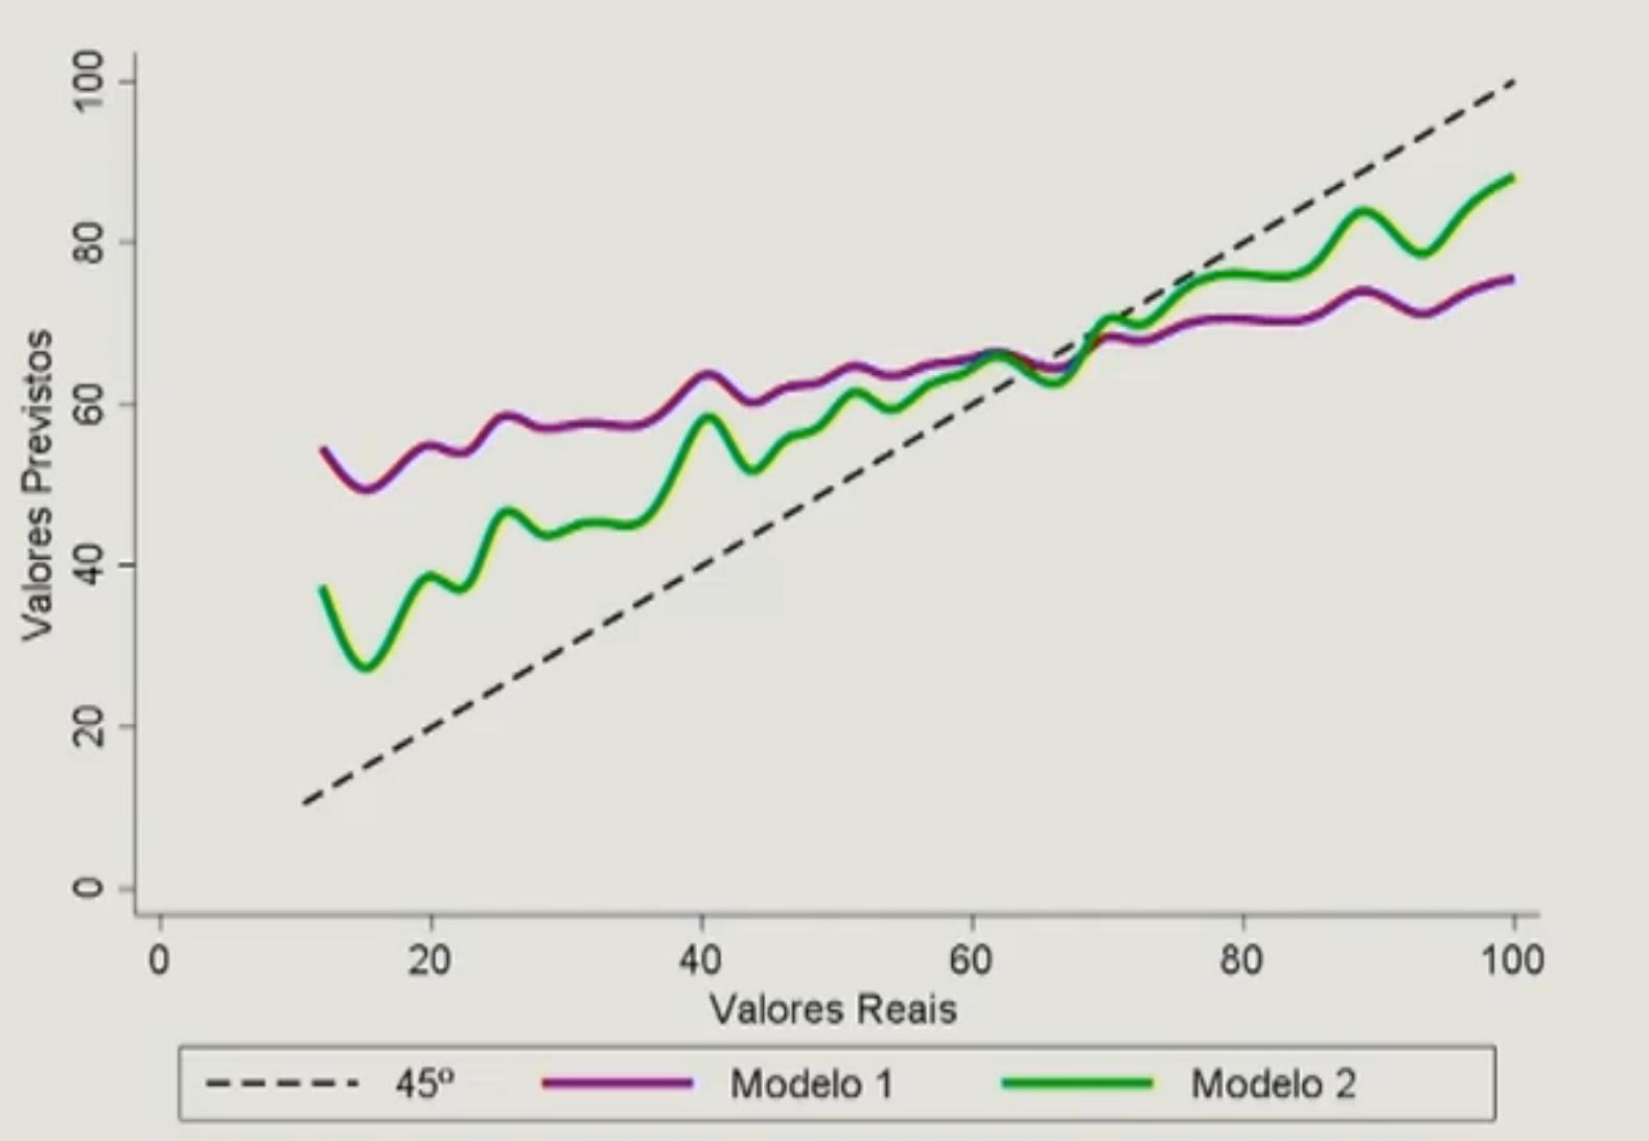


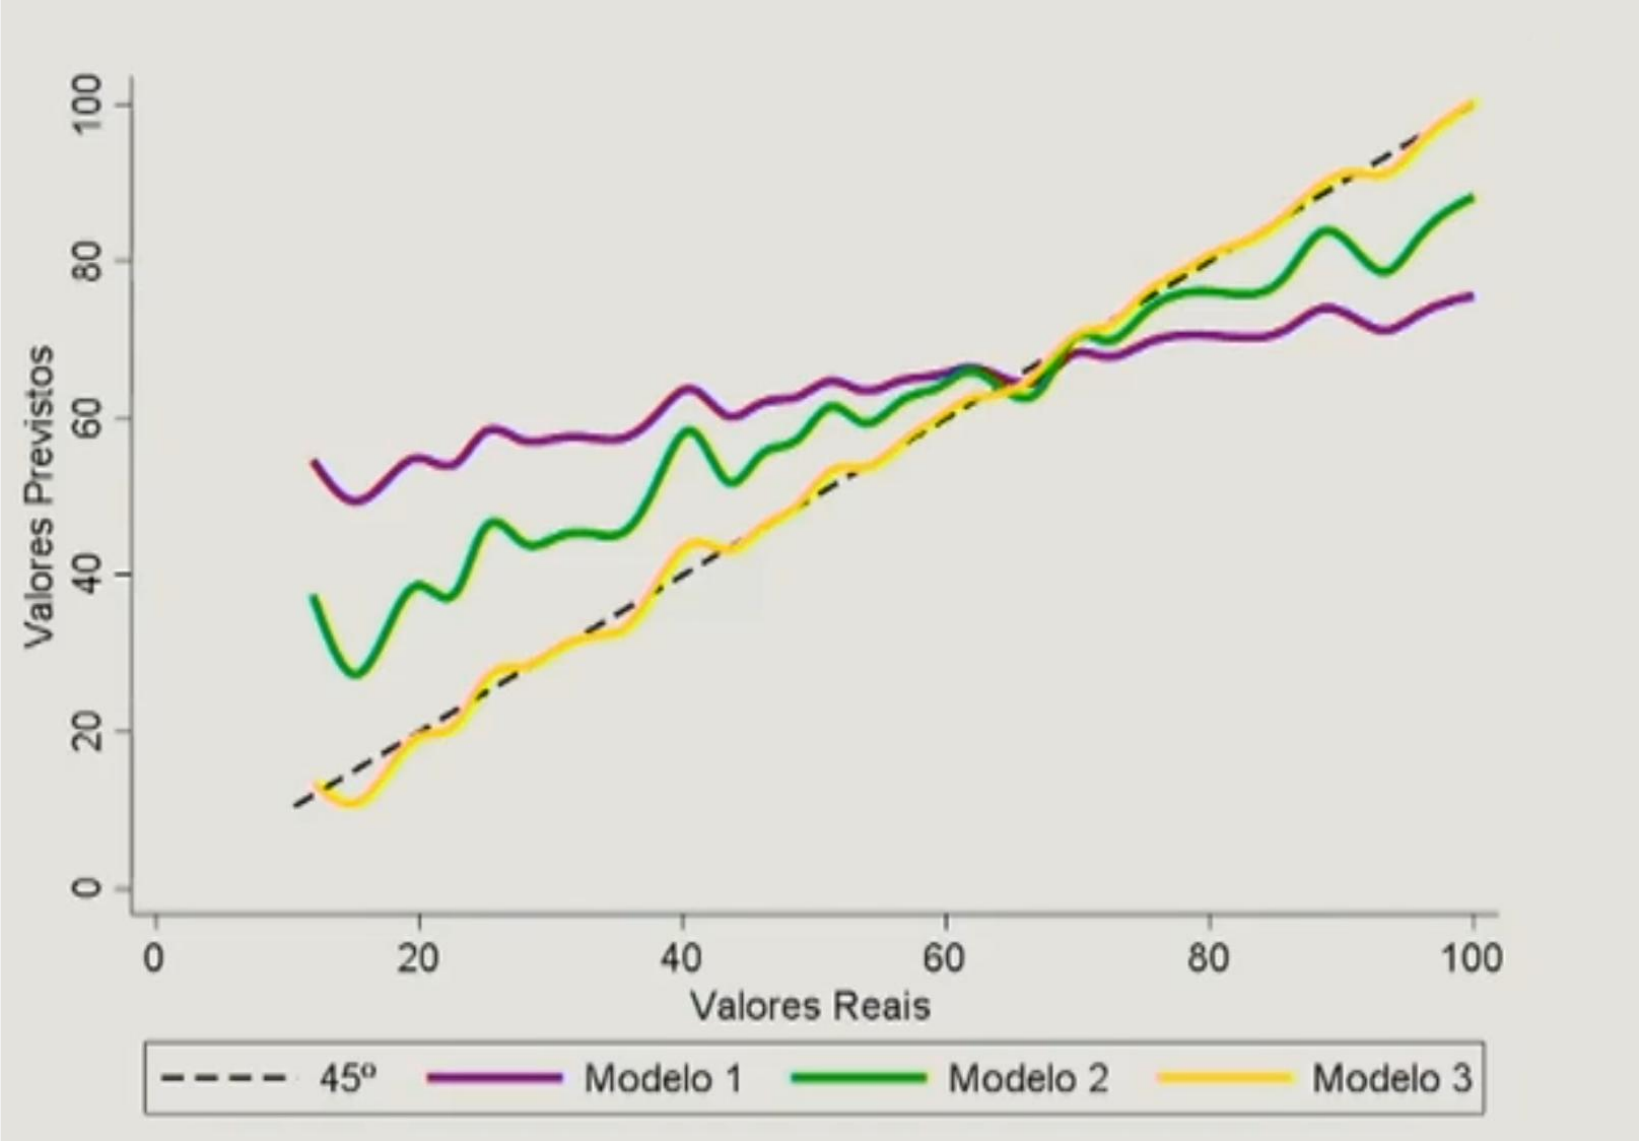
"Diferentes pesquisadores, a partir de uma mesma base de dados, podem estimar diferentes modelos e, consequentemente, obter diferentes valores previstos do fenômeno em estudo. O objetivo é estimar modelos que, embora simplificações da realidade, apresentem a melhor aderência possível entre os valores reais e os valores previstos".

Silberzahn, R.; Uhlmann, E. L. Many hands make tight work. **Nature**, v. 526, p. 189-191, Out 2015.


Valores Previstos
0
20
40
60
80
100
0
20
40
60
80
100
Valores Reais
45º


Valores Previstos
0
20
40
60
80
100
0
20
40
60
80
100
Valores Reais
45º
Modelo 1


Valores Previstos
0
20
40
60
80
100
Valores Reais
0
20
40
60
80
100
45º
Modelo 1
Modelo 2


Valores Previstos
0
20
40
60
80
100
Valores Reais
0
20
40
60
80
100
45º
Modelo 1
Modelo 2
Modelo 3

Modelos Lineares Generalizados (GLM)

$$\eta_i = \alpha + \beta_1 . X_{1i} + \beta_2 . X_{2i} + \ldots \beta_k . X_{ki}$$

Modelos lineares generalizados, características da variável dependente e funções de ligação canônica.

Modelo de Regressão	Característica da Variável Dependente	Distribuição	Função de Ligação Canônica (η)
Linear	Quantitativa	Normal	$\hat{Y}$
Com Transformação de Box-Cox	Quantitativa	Normal Após a Transformação	$\frac{\hat{Y}^{\lambda} - 1}{\lambda}$
Logística Binária	Qualitativa com 2 Categorias (*Dummy*)	Bernoulli	$\ln\left(\frac{p}{1-p}\right)$
Logística Multinomial	Qualitativa M ($M > 2$) Categorias	Binomial	$\ln\left(\frac{p_m}{1-p_m}\right)$
Poisson	Quantitativa com Valores Inteiros e Não Negativos (Dados de Contagem)	Poisson	$\ln\left(\lambda_{poisson}\right)$
Binomial Negativo	Quantitativa com Valores Inteiros e Não Negativos (Dados de Contagem)	Poisson-Gama	$\ln\left(\lambda_{bneg}\right)$

Regressão Linear Simples

Objetivo:

Desenvolver uma equação linear que apresente a relação entre uma variável dependente e uma variável explicativa.

Equação linear de uma reta num plano cartesiano:

$$Y_i = \alpha + \beta . X_i + u_i$$



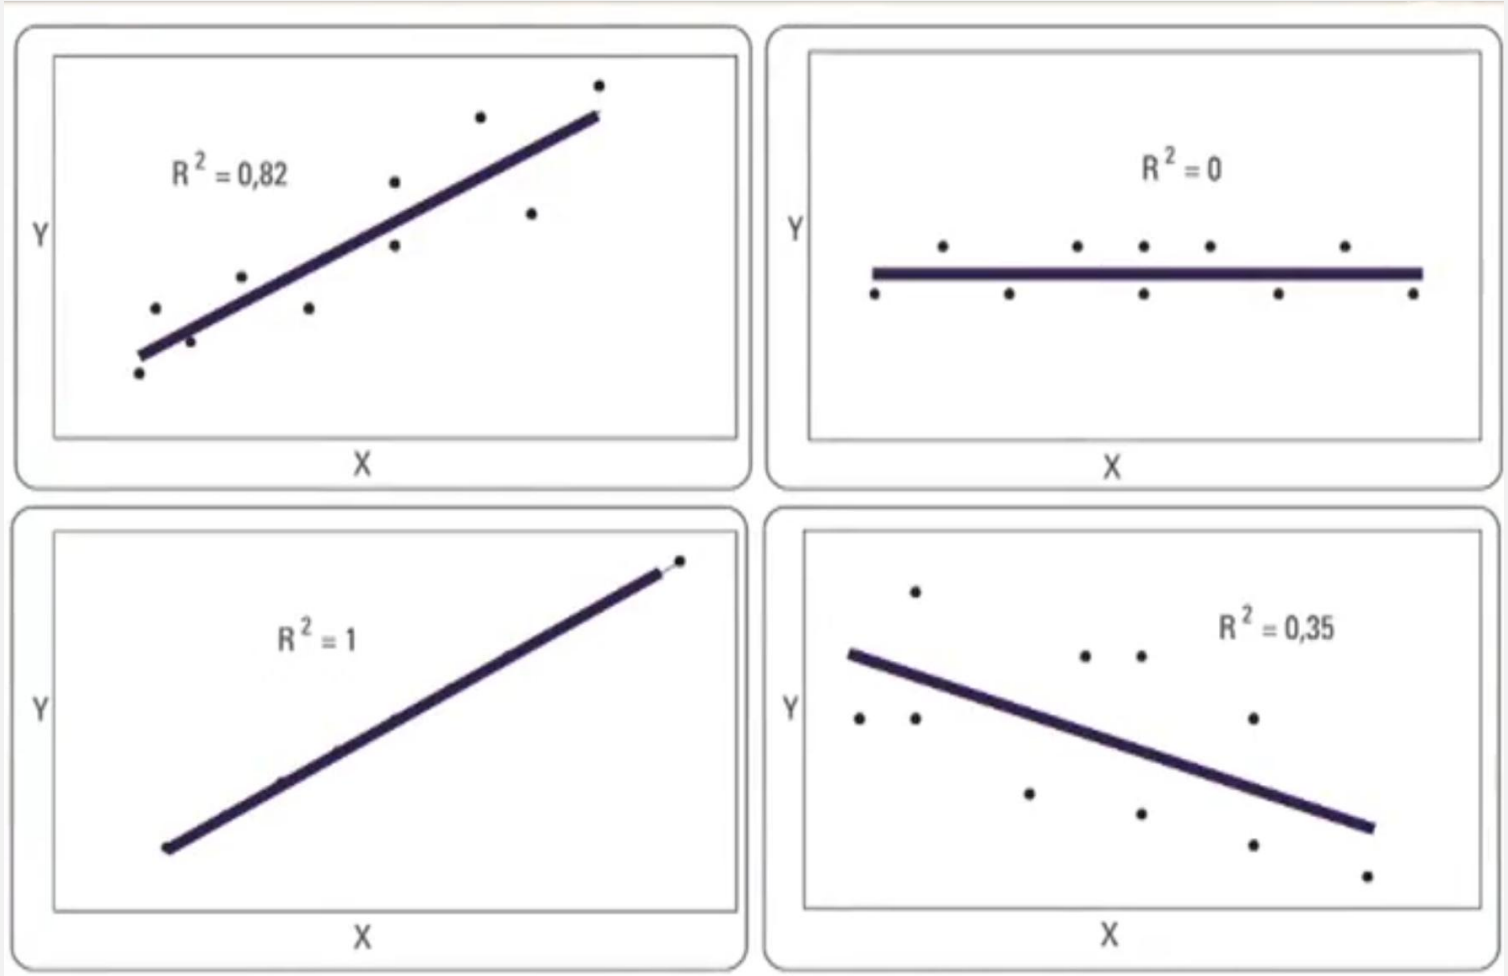


em que temos um intercepto (α), um coeficiente de inclinação da reta (β), uma variável explicativa X e um termo de erro u.

Coeficiente de Ajuste do modelo (R^2)

- Indica o percentual de variância da variável Y que é devido ao comportamento de variação conjunta da(s) variável(is) explicativa(s) X.
- Varia de 0 a 1 e, quanto maior o coeficiente, maior o poder preditivo do modelo de regressão, ou seja, maior o poder de explicação do comportamento da variável dependente frente ao comportamento da(s) variável(is) explicativas(s)

Coeficiente de Ajuste do modelo (R^2)



Comportamento do R^2 para diferentes regressões lineares simples.

Estimação do Parâmetros

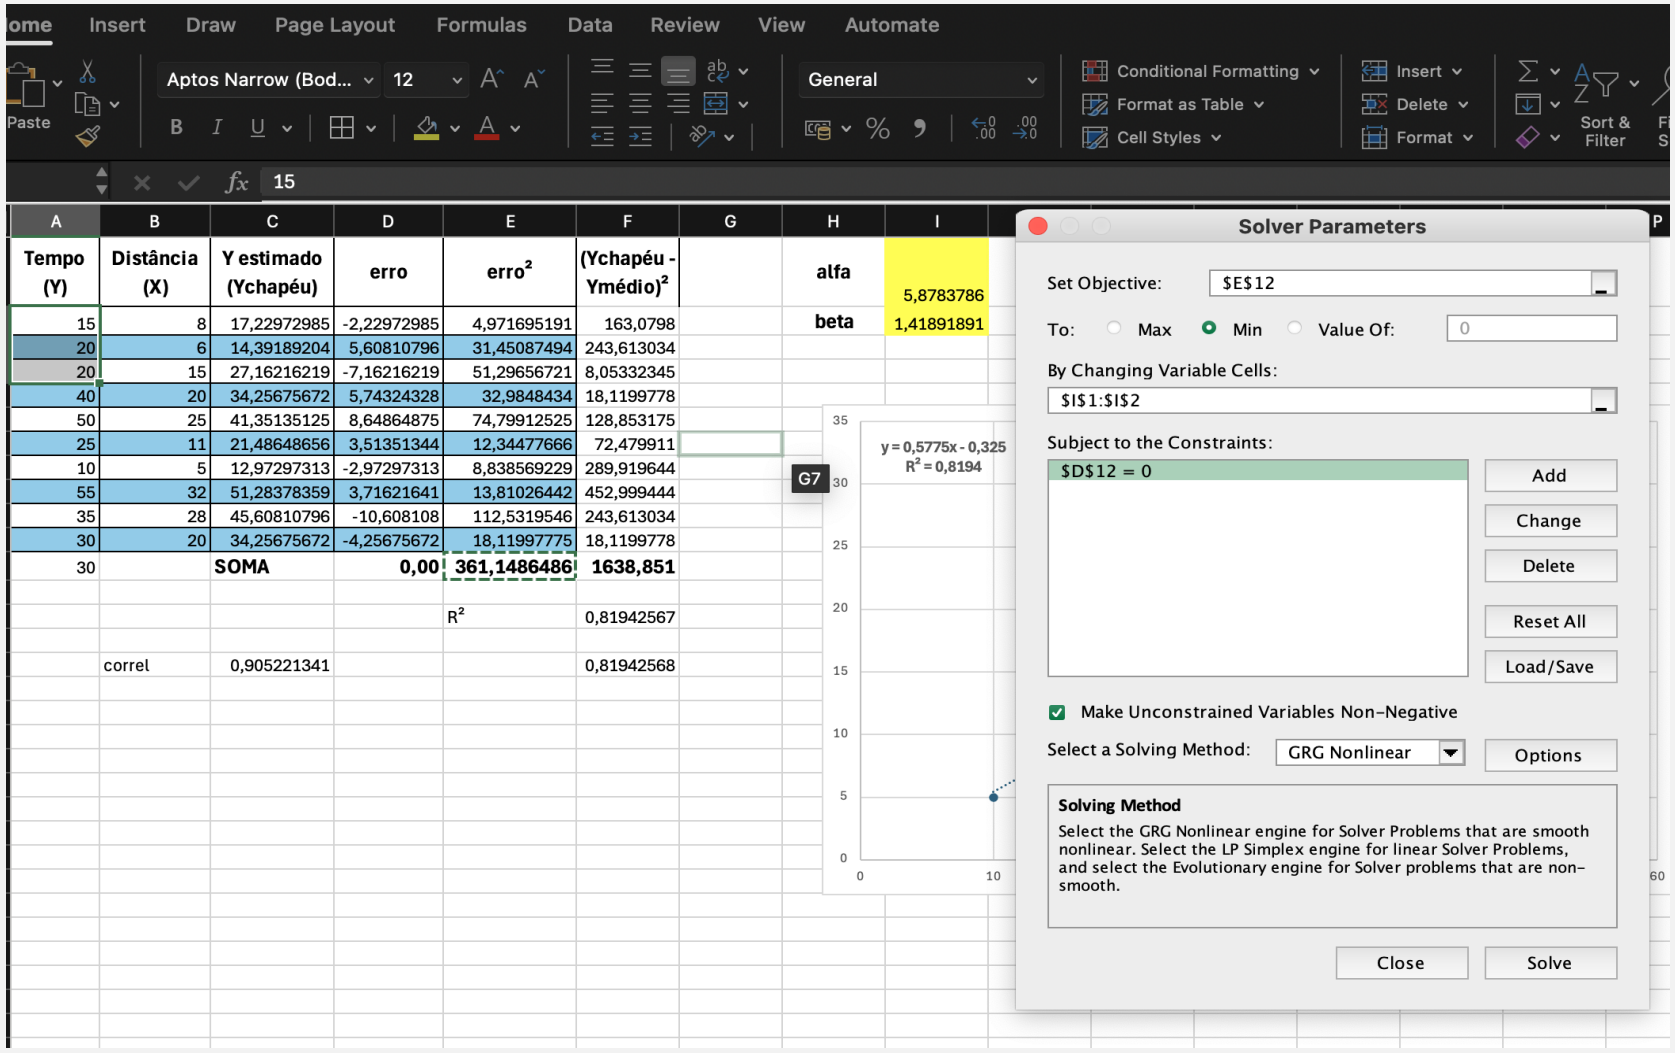
Critérios:

1 – Soma dos erros igual a zero: $\sum_{i=1}^{n} u_i = 0$

2 – Soma dos erros ao quadrado sendo a mínima possível: $\sum_{i=1}^{n} u_i^2 = \text{mín}$

Parâmetros α e β podem ser estimados por meio do método dos mínimos quadrados ordinários (MQO), em que a somatória dos quadrados dos termos de erro é minimizada.

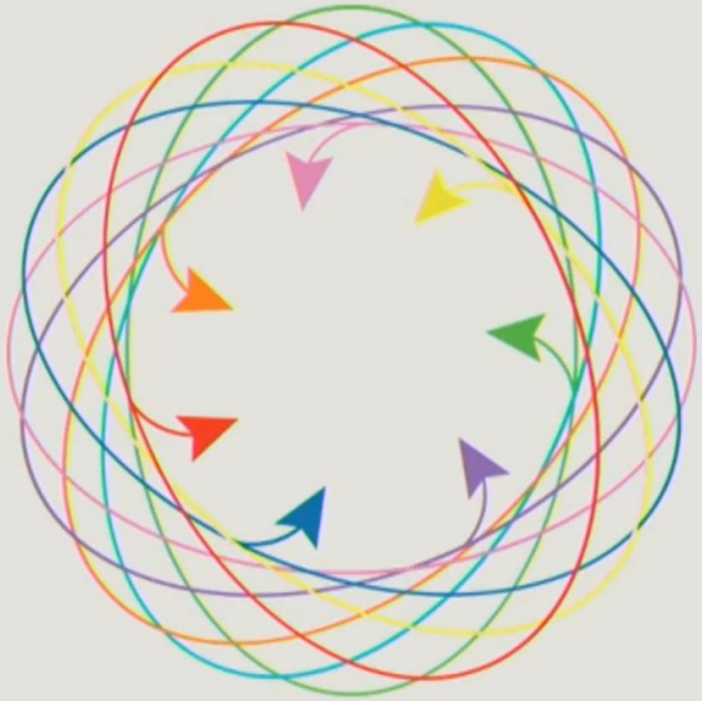
Estimação do Parâmetros



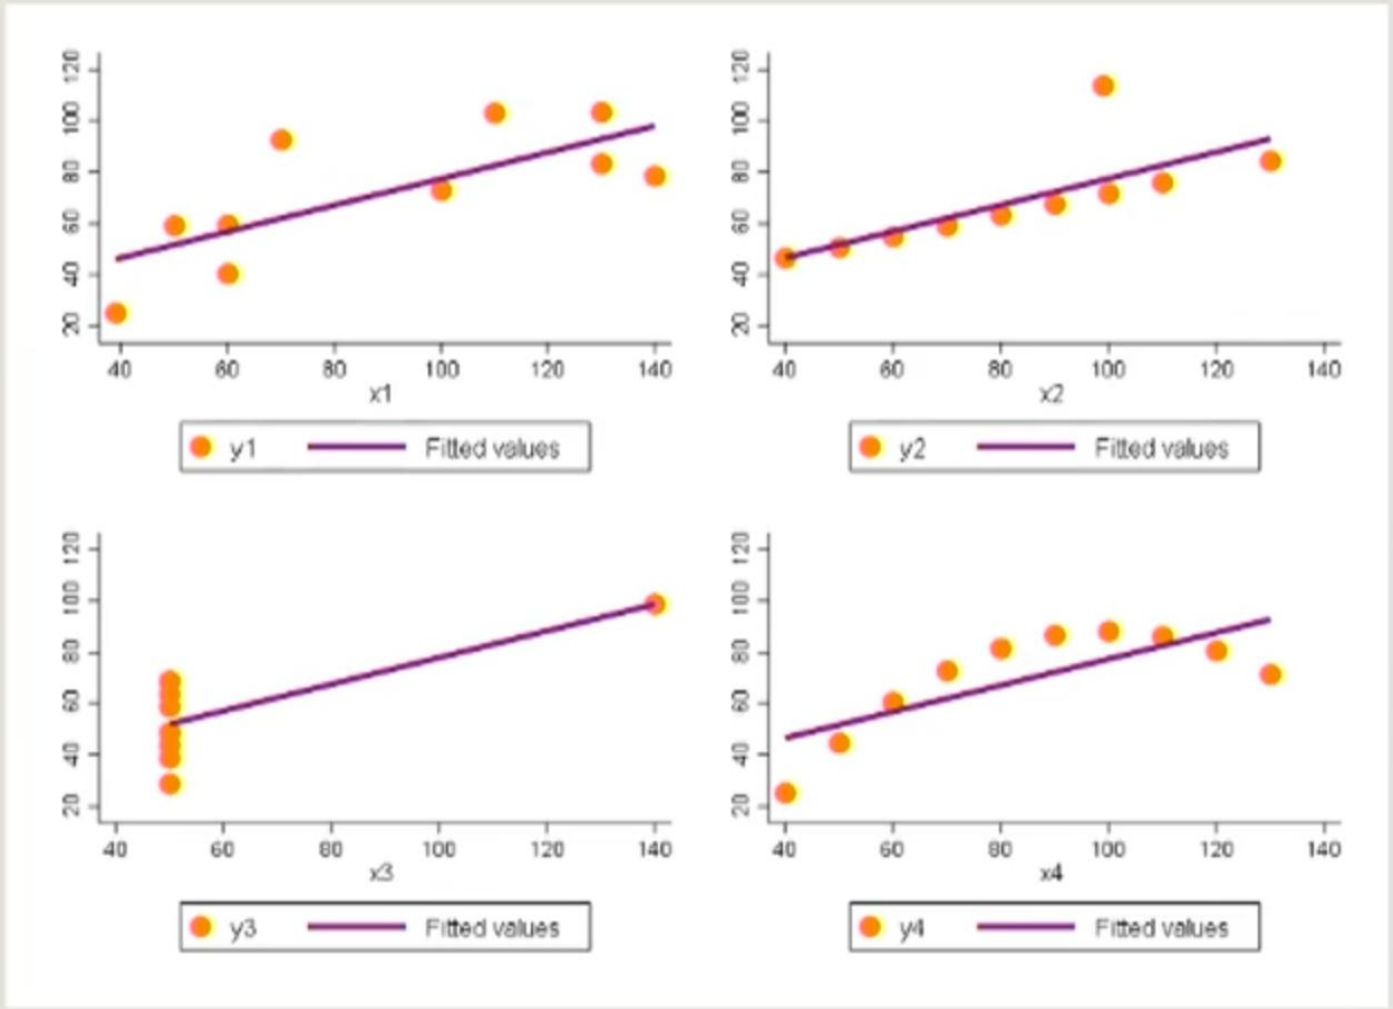
Tempo (Y)	Distância (X)	Y estimado (Ychapéu)	erro	erro²	(Ychapéu - Ymédio)²		alfa	5,8783786
15	8	17,22972985	-2,22972985	4,971695191	163,0798		beta	1,41891891
20	6	14,39189204	5,60810796	31,45087494	243,613034			
20	15	27,16216219	-7,16216219	51,29656721	8,05332345			
40	20	34,25675672	5,74324328	32,9848434	18,1199778			
50	25	41,35135125	8,64864875	74,79912525	128,853175			
25	11	21,48648656	3,51351344	12,34477666	72,479911			
10	5	12,97297313	-2,97297313	8,838569229	289,919644			
55	32	51,28378359	3,71621641	13,81026442	452,999444			
35	28	45,60810796	-10,608108	112,5319546	243,613034			
30	20	34,25675672	-4,25675672	18,11997775	18,1199778			
30		**SOMA**	**0,00**	**361,1486486**	**1638,851**			
				R^2	0,81942567			
	correl	0,905221341			0,81942568			

Coeficiente de Ajuste do modelo (R^2)

$$R^2 = \frac{\sum_{i=1}^{n} \left(\hat{Y}_i - \bar{Y}\right)^2}{\sum_{i=1}^{n} \left(\hat{Y}_i - \bar{Y}\right)^2 + \sum_{i=1}^{n} (u_i)^2}$$

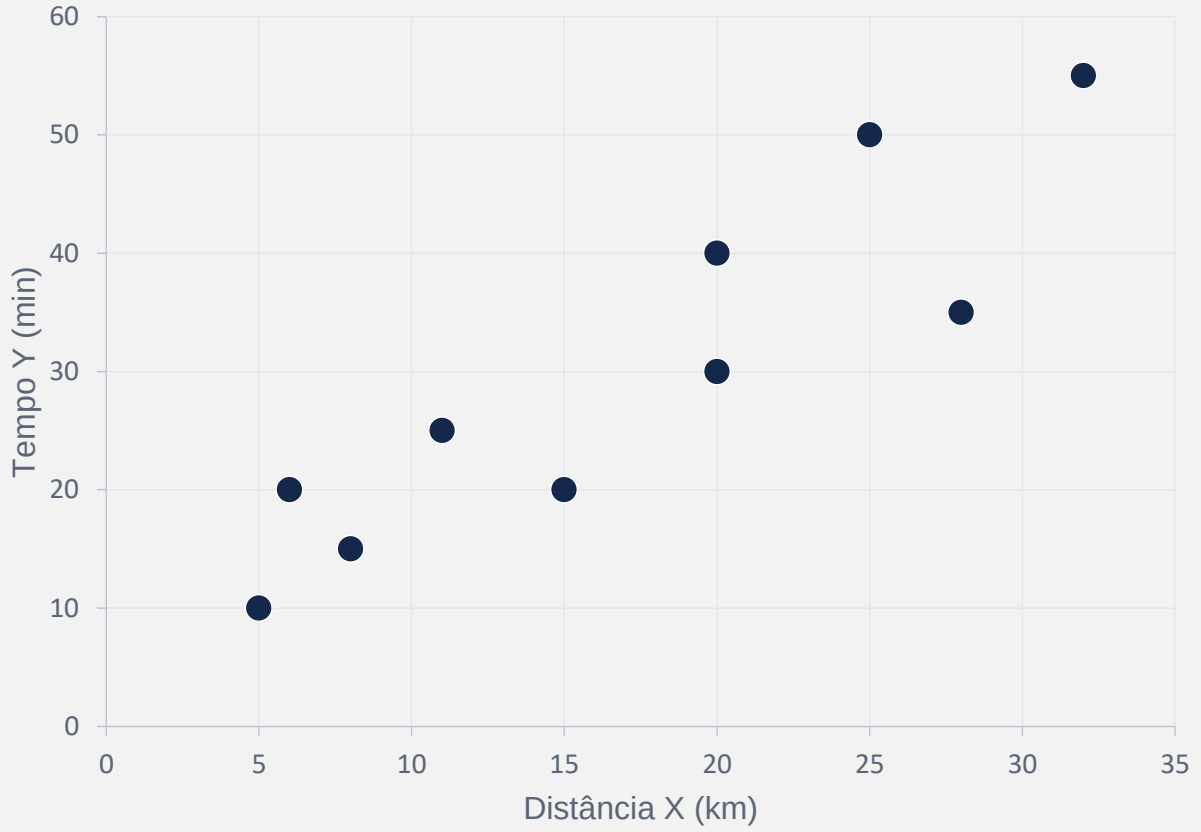


Apenas Parâmetros e R^2 ?



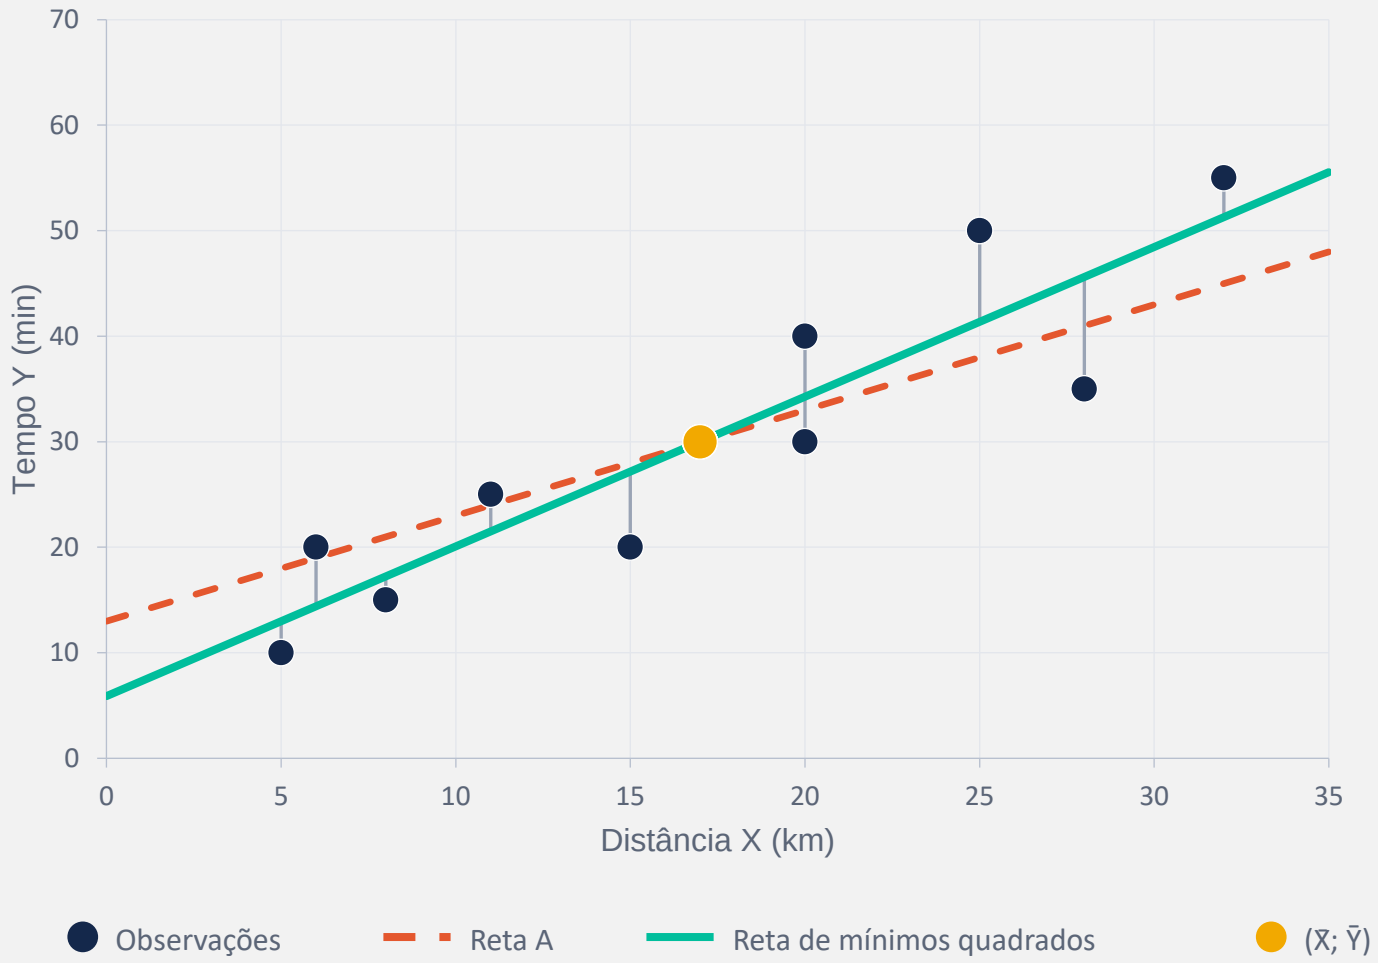
Nosso exemplo: tempo × distância

Obs.	X: distância (km)	Y: tempo (min)
1	8	15
2	6	20
3	15	20
4	20	40
5	25	50
6	11	25
7	5	10
8	32	55
9	28	35
10	20	30
Média	**17**	**30**



Pergunta do dia: um aluno mora a 18 km. Quanto tempo de deslocamento devemos esperar?

Qual é a melhor reta? Olhe para os erros



Erro (resíduo): $u = Y - \hat{Y}$

É a distância vertical (segmentos cinza) entre o valor real e o valor previsto pela reta.

Reta	α	β	Σu	Σu²
A (coral)	13,0	1,00	0	504,0
MQO (verde)	5,88	1,42	0	**361,1**

Soma zero não basta. Qualquer reta que passa por (X̄; Ȳ) = (17; 30) zera Σu.

O MQO escolhe a reta com o menor Σu²: ao quadrado, erros positivos e negativos não se cancelam e erros grandes pesam mais.

Solver passo a passo (e 3 armadilhas)

1 — Parâmetros

Células I1 (α) e I2 (β) com um chute inicial

`α = 0  e  β = 1`

2 — Previsão

Em C2, copiando até C11:

`=$I$1+$I$2*B2` (Ŷ = α + β·X)

3 — Erros e soma

D = A − C, E = D², F = (Ŷ − Ȳ)² e linha 12 com SOMA:

`=A2-C2` `=D2^2` `=(C2-MÉDIA($A$2:$A$11))^2`

4 — Solver

Dados > Solver: minimize E12 mudando I1:I2

`Objetivo $E$12 → Min · Variáveis $I$1:$I$2`

Janela do Solver

```
Set Objective:  $E$12
To:  Min
By Changing:  $I$1:$I$2
Constraint:  $D$12 = 0
Method:  GRG Nonlinear
```

3 armadilhas

Desmarque "Make Unconstrained Variables Non-Negative": com ela marcada, α e β nunca ficam negativos.

A restrição Σu = 0 é redundante: o mínimo de Σu² já a satisfaz (liga com o critério 1).

Diferença na 7ª casa decimal é normal: o Solver é numérico.

Resultado: o que significam α e β?

$$\hat{Y} = 5{,}88 + 1{,}42 \cdot X$$

β = 1,42 (inclinação)

Cada km a mais de distância está associado a, em média, 1,42 min a mais de tempo.

α = 5,88 (intercepto)

Valor esperado de Y quando X = 0. Aqui X = 0 está fora de 5–32 km: não leia ao pé da letra.

Fórmula fechada: $\beta = \Sigma(X-\bar{X})(Y-\bar{Y}) / \Sigma(X-\bar{X})^2 = 1.155 / 814 = 1{,}4189$

$\alpha = \bar{Y} - \beta \cdot \bar{X} = 30 - 1{,}4189 \cdot 17 = 5{,}878$

Conferindo o Solver com funções do Excel

Item	Valor	Função (PT) · (EN)
α	5,8784	`=INTERCEPÇÃO(A2:A11;B2:B11)`
β	1,4189	`=INCLINAÇÃO(A2:A11;B2:B11)`
R^2	0,8194	`=RQUAD(A2:A11;B2:B11)`
r	0,9052	`=CORREL(A2:A11;B2:B11)`

EN: INTERCEPT, SLOPE, RSQ, CORREL. Atenção à ordem dos argumentos: primeiro o Y (tempo), depois o X (distância).

Bônus: o Solver só procura, passo a passo, o que a fórmula fechada entrega direto. Os dois chegam ao mesmo α e β.

Como é feita a previsão

Exemplo: aluno a 18 km

$$\hat{Y} = \alpha + \beta \cdot X$$

$$\hat{Y} = 5{,}88 + 1{,}42 \cdot 18$$

$$\hat{Y} \approx 31{,}4 \text{ min}$$

Substituir o X novo na equação estimada.

X novo (km)	Ŷ (min)	Situação
10	20,1	dentro de 5–32 km
18	31,4	dentro de 5–32 km
25	41,4	dentro de 5–32 km
32	51,3	dentro de 5–32 km
60	91,0	extrapolação ⚠

Faixa observada de X: 5 a 32 km. Fora dela, a reta é só uma aposta.

Quanto confiar na previsão?

Erro padrão da estimativa: $s = \sqrt{(\Sigma u^2 / (n-2))} = \sqrt{(361{,}15 / 8)} = 6{,}72$ min

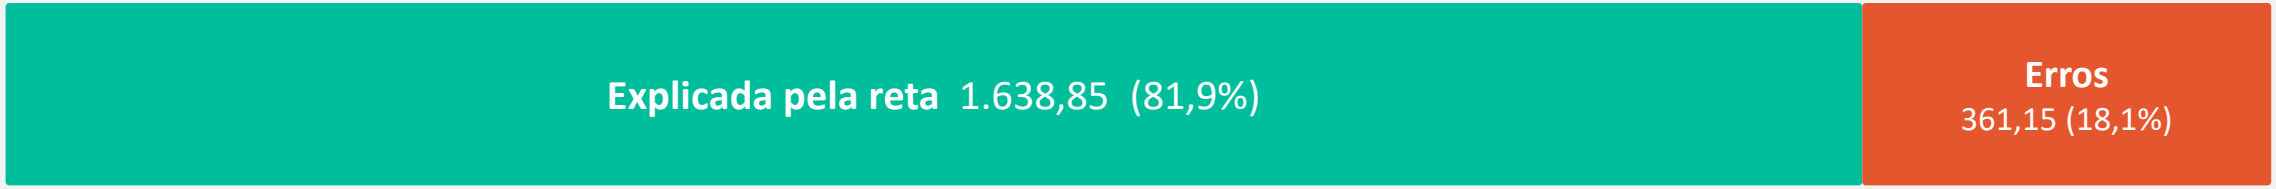
Regra de bolso: $\hat{Y} \pm 2s$ → 18 km: 31 ± 13 min

Intervalo de previsão 95%: ≈ 15 a 48 min (t de Student, 8 g.l.)

```
=PREVISÃO.LINEAR(18;A2:A11;B2:B11)   → 31,42
=TENDÊNCIA(A2:A11;B2:B11;18)         → 31,42
=EPADYX(A2:A11;B2:B11)               → 6,72
EN: FORECAST.LINEAR · TREND · STEYX
```

R^2 na prática: de onde vem o 0,8194?

Variação total de Y: $\Sigma(Y - \bar{Y})^2 = \mathbf{2.000}$



Explicada pela reta

$\Sigma(\hat{Y} - \bar{Y})^2 = 1.638,85$

soma da coluna F da planilha

Não explicada (erros)

$\Sigma u^2 = 361,15$

soma da coluna E (o que o Solver minimizou)

Total

$\Sigma(Y - \bar{Y})^2 = 2.000$

explicada + não explicada

R^2 = explicada / total = 1.638,85 / 2.000 = **0,8194**

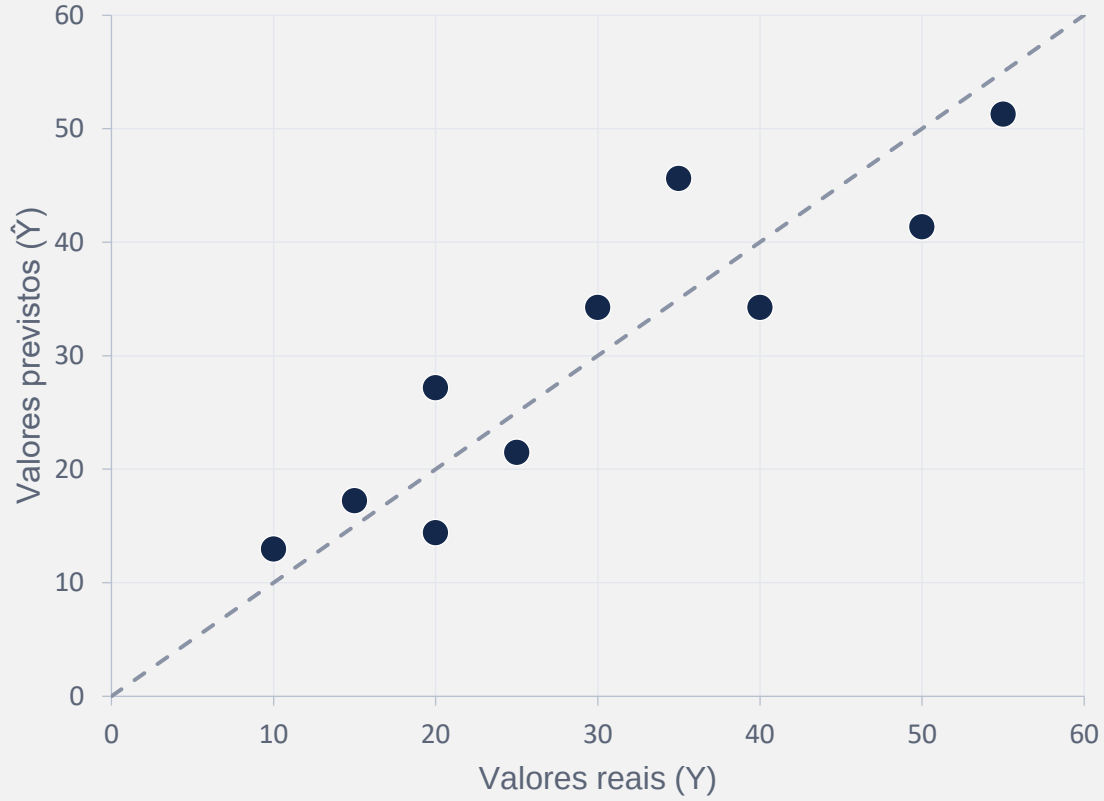
$R^2 = 1 - \text{erros} / \text{total} = 1 - 361,15 / 2.000$

Regressão simples: $R^2 = r^2 = 0,9052^2 = 0,8194$

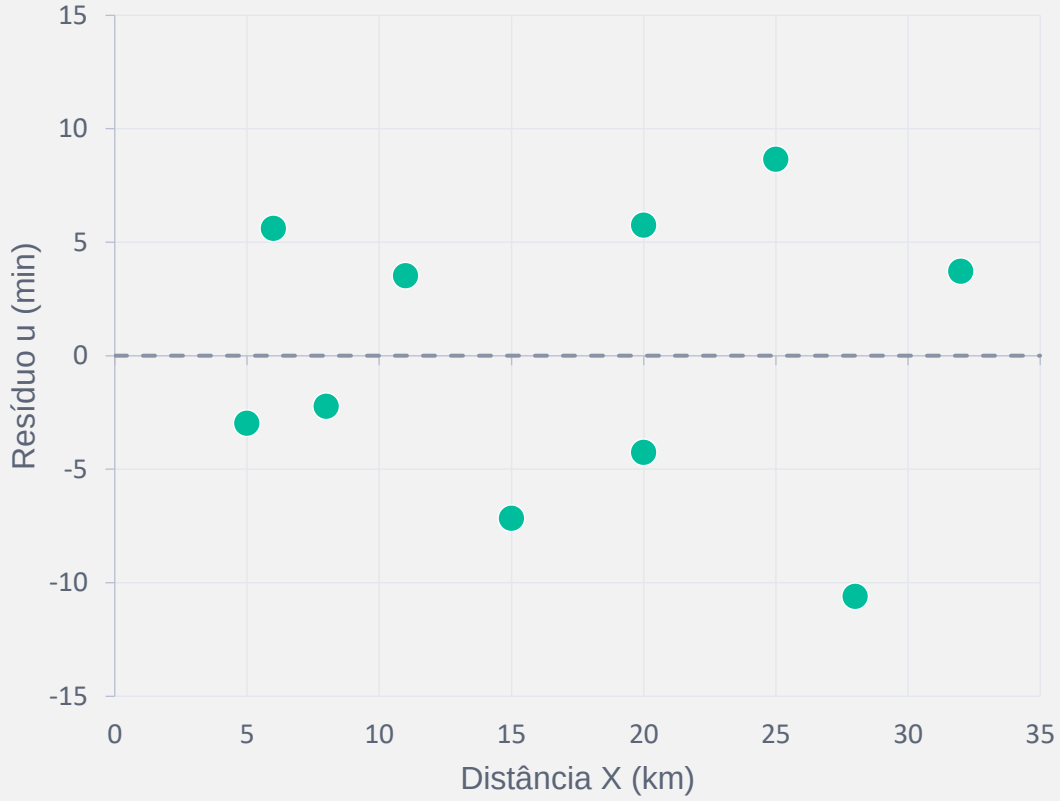
Leitura: 82% da variação do tempo é explicada pela distância. Os outros 18% vêm de outros fatores (trânsito, meio de transporte...).

Real × previsto e resíduos

Real × previsto (linha de 45°)



Resíduos × distância



Boa regra: pontos perto da diagonal e resíduos espalhados sem padrão em torno de zero.

Pressupostos e armadilhas

5 pressupostos do modelo (MQO)

1. **Linearidade**
   A relação entre X e Y é aproximadamente uma reta. Cheque o gráfico de dispersão.

2. **Independência**
   Um erro não depende do outro (atenção a séries no tempo).

3. **Variância constante**
   A dispersão dos erros é parecida ao longo de X. Funil nos resíduos = problema.

4. **Erros ~ normais**
   Importante para testes e intervalos. Cheque histograma ou QQ-plot dos resíduos.

5. **Sem pontos influentes**
   Um outlier pode puxar a reta sozinho.

3 armadilhas clássicas

Mesma reta, dados diferentes

No quarteto de Anscombe (slide 24) os 4 conjuntos têm a mesma reta e R^2 parecido. Sempre faça o gráfico.

Correlação ≠ causalidade

A regressão mede associação. Distância explica o tempo, mas sorvete "explica" afogamentos.

Extrapolar é arriscado

O modelo só vale perto da faixa observada (5 a 32 km). Prever 100 km (148 min) é aposta.

Dinâmica: a regressão da nossa turma

1 **Coletar** — 3 min

Cada aluno diz a distância (km) e o tempo (min) até a faculdade.

2 **Rodar** — 4 min

Cole os dados nas colunas A e B da planilha e rode o Solver (ou INCLINAÇÃO e INTERCEPÇÃO).

3 **Interpretar** — 3 min

Quanto vale o β da turma? Quanto custa cada km extra? Qual o R^2?

4 **Prever** — 2 min

Qual o tempo previsto para a sua distância? O modelo acertou?

Opcional: pode ser feito em casa, se faltar tempo.

Para discutir

- O β da turma é maior ou menor que 1,42 min/km? Por quê?
- Quem vem de trem, moto ou bicicleta vira outlier? O que ele faz com a reta?
- Quanto o R^2 da turma explica? O que mais influencia o tempo?
- Prever 60 km é seguro?

Para levar: regressão linear e a ponte com o GLM

MQO

Minimiza Σu^2, a soma dos erros ao quadrado. O Solver faz isso numericamente; a fórmula fechada, direto.

α e β

β: variação média de Y por unidade de X. α: valor de Y quando X = 0 (nem sempre faz sentido).

Previsão

$\hat{Y} = \alpha + \beta \cdot X$, dentro da faixa observada. Sempre acompanhe de um erro (s, intervalo).

R^2 e gráficos

R^2 mede o ajuste, não a causa. Olhe sempre dispersão e resíduos.

A ponte: a regressão linear é um GLM

$\eta = \alpha + \beta \cdot X$ distribuição **Normal** · ligação **identidade** ($\hat{Y} = \eta$)

Mudando a distribuição e a função de ligação (tabela do slide 17): Y binário → regressão logística (logit); Y de contagem → Poisson (log). Mesma ideia, outro modelo.